

II

텍스트 데이터 처리



집합과 벡터를 이용하여
텍스트 데이터를 목적에 맞게
표현하고 이를 특성에 따라
분석한다.



💡 데이터! 데이터! 데이터!

진흙이 없으면 벽돌을 만들 수 없지 않소. 💡


(출처: Doyle, A. C., 『Adventures of Sherlock Holmes』)



아서 코난 도일(Doyle, A. C., 1859~1930)
영국의 의사이자 설록 홈즈 시리즈로 유명한 작가

이 글은 ‘너도밤나무 집’에 얹힌 비밀을 풀어 달라는 의뢰인의 정보를 받은 홈즈가 조수인 왓슨에게 비밀의 단서를 찾으려면 데이터가 필요하다면서 답답한 마음을 드러내는 장면에서 한 말이다.

- 1 텍스트 데이터 표현
- 2 텍스트 데이터 처리
- 3 텍스트 데이터 분석



준비 학습



| 중학교 수학 3 | 삼각비

- 1 다음 표를 완성하고, 괄호 안의 알맞은 내용에 ○표를 하시오.

삼각비 \ A	0°	30°	45°	60°	90°
cos A					

위의 표에서 $\angle A$ 의 크기가 커질수록 $\cos A$ 의 값은 (커진다, 작아진다).

| 공통수학2 | 두 점 사이의 거리

- 2 다음 좌표평면 위의 두 점 사이의 거리를 구하시오.

(1) $A(2, 1)$, $B(5, -3)$

(2) $O(0, 0)$, $A(-4, 6)$

| 공통수학2 | 집합

- 3 다음 두 집합 A 와 B 에 대하여 $A \cup B$ 를 구하시오.

(1) $A = \{2, 3, 5, 7\}$, $B = \{1, 3, 5, 7, 9\}$

(2) $A = \{\text{곰, 호랑이, 고래, 수달}\}$, $B = \{\text{상어, 고래, 가오리, 수달}\}$



이 단원에서는

인공지능이 텍스트 데이터를 표현하고, 이를 분석하는 수학적 방법을 알아본다.

스스로 세우는 학습 계획 예 서두르지 않고 꼼꼼하게 문제를 풀어 보겠다.

1

텍스트 데이터 표현

학습
목표


집합과 벡터를 이용하여 텍스트 데이터를 목적에 맞게 표현할 수 있다.

텍스트 데이터의 종류



생각
열기

다음은 어느 고등학교 학생들을 대상으로 지난 학기 급식에 대하여 '선호하는 메뉴'와 '의견'을 조사한 데이터의 일부를 나타낸 것이다.



식재료가 신선하고
모든 메뉴의 품질이
좋아요.

영양사 선생님께서
친절하고 맛있게
음식을 해 주세요.

고기가 자주 나와서
좋지만 가끔 짠
맛이 느껴져요.

집에서 먹는 음식과
비교하면 성의가
없어 보여요.

◇ '선호하는 메뉴'와 '의견'이 정형 데이터인지 비정형 데이터인지 말해 보자.

텍스트 데이터에는 정형 데이터와 비정형 데이터가 있다. 위의 **생각 열기**에 제시된 텍스트 데이터에서 '선호하는 메뉴'는 좋아했던 메뉴의 이름을 정해진 형식으로 저장한 정형 데이터이고, '의견'은 급식에 대한 의견을 자유로운 형식으로 저장한 비정형 데이터이다.

정형 데이터는 정해진 형식으로 저장되기 때문에 컴퓨터에서 쉽게 처리할 수 있고 효율적으로 검색하거나 분석할 수 있으므로 인공지능에 활용하기 편리하다. 그러나 미리 정해진 형식 외의 세부적인 정보를 파악하거나 새로운 데이터 유형을 추가하는 것은 어렵다.

한편, 비정형 데이터는 정해진 형식이 없기 때문에 다양한 형식의 데이터를 저장할 수 있고 세부적이고 다양한 정보를 포함할 수 있지만, 인공지능에 활용하려면 컴퓨터가 인식할 수 있는 형태로 바꾸어 표현해야 한다.

따라서 이 두 가지 데이터 유형은 사용 목적과 특성에 따라 적절히 선택하여 사용해야 한다.

문제 1 다음 텍스트 데이터를 정형 데이터와 비정형 데이터로 구분하시오.

이름, 댓글, 설명서, 신문 기사, 거주 지역, 문자 메시지

정형 텍스트 데이터의 표현

인공지능은 단어나 문장과 같은 텍스트 데이터를 사람처럼 글자 형태로 인식하지 못하기 때문에 인공지능이 인식할 수 있도록 이를 수 또는 수학 기호로 표현해야 한다.

1 수로 표현하기

성별이나 혈액형과 같은 정형 텍스트 데이터는 다음과 같이 특정한 범주를 수로 바꾸어 표현할 수 있다.

남성	여성
3	4

◆ 성별 구분

A형	B형	O형	AB형
0	1	2	3

◆ 혈액형 구분

2 수학 기호로 표현하기

정형 텍스트 데이터를 수학 기호로 표현할 때, 벡터를 이용할 수 있다.
이를 위해 벡터에 대하여 알아보자.

n 개의 수 $x_1, x_2, \dots, x_n$ 을 괄호 속에 순서대로 나열하여 나타낸

$$\vec{X} = (x_1, x_2, \dots, x_n)$$

을 **벡터**라고 한다. 이때 $x_1, x_2, \dots, x_n$ 을 벡터 $\vec{X}$ 의 성분이라 하고, x_1 을 첫째 성분, x_2 를 둘째 성분, $\dots, x_n$ 을 n 째 성분이라고 한다.

참고 벡터는 보통 알파벳 위에 화살표를 붙여서 $\vec{A}, \vec{P}, \vec{X}$ 등으로 나타내고, 성분의 개수를 그 벡터의 ‘차원’이라고 한다.

◆ 벡터 $\vec{X}$ 의 차원은 5이다.

보기 벡터 $\vec{X} = (2, 0, 1, 3, 5)$ 의 첫째 성분은 2이고, 셋째 성분은 1이다.

문제 2 벡터 $\vec{X} = (1, 0, 2, 3)$ 에 대하여 다음을 구하시오.

(1) 벡터 $\vec{X}$ 의 둘째 성분

(2) 벡터 $\vec{X}$ 의 넷째 성분

◆ 특정한 범주의 성분을 1, 나머지를 모두 0으로 나타낸 벡터를 원-핫(one-hot) 벡터라고 한다.

정형 텍스트 데이터를 벡터로 표현할 때, 범주의 개수를 차원으로 하고 특정한 범주의 성분을 1, 나머지를 모두 0으로 나타낼 수 있다.

예를 들어 앞의 성별 구분 표에서 남성을 벡터로 (1, 0), 여성을 벡터로 (0, 1)로 표현할 수 있다.

문제 3 오른쪽 표는 학생 5명의 혈액형을 조사하여 나타낸 것이다. A형을 벡터로 (1, 0, 0, 0)으로 표현할 때, 나머지 혈액형을 벡터로 표현하여 표를 완성하십시오. (단, 벡터의 성분은 A형, B형, O형, AB형의 순서로 한다.)

	혈액형	벡터 표현
지수	A	(1, 0, 0, 0)
영우	O	
채원	AB	
재영	B	
세미	AB	

비정형 텍스트 데이터의 표현

비정형 텍스트 데이터를 수학 기호로 표현하는 방법을 알아보자. 이때 집합이나 벡터를 이용할 수 있다.

배웠어요

집합은 보통 알파벳 대문자 $A, B, C, \dots$ 로 나타내고, 원소는 알파벳 소문자 $a, b, c, \dots$ 로 나타낸다.

어떤 기준에 따라 대상을 분명하게 정할 수 있을 때, 그 대상들의 모임을 **집합**이라고 한다. 이때 집합을 이루는 대상 하나하나를 그 집합의 원소라고 한다.

집합에 속하는 모든 원소는 { } 안에 나열하여 나타내며, 같은 원소를 중복하여 나열하지 않는다.

이제 비정형 텍스트 데이터를 집합으로 표현하는 방법을 알아보자.

다음은 어느 학교의 교복에 대한 학생들의 댓글 중에서 세 개를 모은 *말뭉치이다.

댓글 A 우리 학교 교복은 주변 학교 교복보다 디자인이 예뻐요.

댓글 B 디자인과 신축성이 좋은 교복이에요.

댓글 C 소재가 좋은 교복이라고 생각해요.


* 선호도를 알아보기 위해 특정한 영화의 댓글을 모아 둔 데이터처럼, 어떤 목적을 가지고 수집한 텍스트 데이터 전체를 말뭉치 또는 코퍼스(corpus)라고 한다.



일반적으로 앞의 댓글 A와 같은 문장은 다음과 같이 띄어쓰기를 기준으로 각 낱말을 분리하고, 각각의 낱말을 기본 사전형 단어로 바꾸어 나타낸다. 이때 마침표, 느낌표, 따옴표 등의 문장 부호는 보통 제외한다.

낱말 분리	우리	학교	교복은		주변	학교	교복보다		디자이너		예뻐요
기본 사전형 단어	우리	학교	교복	은	주변	학교	교복	보다	디자이너	이	예쁘다

* 텍스트 데이터에는 등장하지만 분석에 사용되지 않는 단어를 불용어(不用語)라고 하고, 대명사, 관사, 전치사, 조사, 접속사, 특수 문자 등이 해당된다.



◆ $U = A \cup B \cup C$

위의 기본 사전형 단어에서 *불용어를 다음과 같이 표시해 보자.

기본 사전형 단어	우리	학교	교복	은	주변	학교	교복	보다	디자이너	이	예쁘다
-----------	----	----	----	---	----	----	----	----	------	---	-----

이 표에서 불용어를 제거하고 남은 단어를 원소로 하는 집합을 A 라 하면

$$A = \{\text{학교, 교복, 주변, 디자인, 예쁘다}\}$$

이다. 이때 집합 A 를 댓글 A의 **단어집합**이라고 한다.

같은 방법으로 두 댓글 B와 C에서 불용어를 제거하고 남은 단어를 원소로 하는 단어집합을 B 와 C 라 하면

$$B = \{\text{디자인, 신축성, 좋다, 교복}\}, \quad C = \{\text{소재, 좋다, 교복, 생각}\}$$

과 같이 구할 수 있다.

위에서 구한 세 단어집합 A, B, C 의 합집합을 U 라 하면

$$U = \{\text{학교, 교복, 주변, 디자인, 예쁘다, 신축성, 좋다, 소재, 생각}\}$$

이다. 이 집합 U 를 세 댓글 A, B, C로부터 구성한 **단어 사전**이라고 한다. 즉, 단어 사전은 말뭉치의 단어집합이다.

참고 불용어는 경우에 따라 사용자가 목적에 맞게 설정할 수 있다. 예를 들어 세 댓글 A, B, C는 '학교의 교복'에 대한 댓글이므로 댓글 분석을 할 때 '학교'와 '교복'을 불용어에 포함시킬 수도 있다.

문제 4 다음은 어느 영화의 후기 중에서 세 개를 모은 말뭉치이다. 세 후기 A, B, C의 단어집합 A, B, C 와 단어 사전 U 를 구하시오.

* 컴퓨터를 이용하여 이미지를 제작하는 작업을 CG (computer graphics)라고 한다.



◆ 텍스트 형태의 자연어를 기계가 인식할 수 있도록 수로 나열하여 벡터로 표현하는 것을 임베딩(embedding)이라고 한다.

이제 앞의 단어 사전 U 를 이용하여 세 댓글 A, B, C 를 벡터로 표현해 보자.

다음 표는 단어 사전 U 에 있는 단어를 순서대로 나열하고, 단어 사전 U 의 각 단어가 세 단어집합 A, B, C 에 각각 속하면 1, 속하지 않으면 0으로 나타낸 것이다.

	학교	교복	주변	디자인	예쁘다	신축성	좋다	소재	생각
A	1	1	1	1	1	0	0	0	0
B	0	1	0	1	0	1	1	0	0
C	0	1	0	0	0	0	1	1	1

이 표에서 세 단어집합 A, B, C 에 대응하는 수를 순서대로 나열하여 벡터로 표현하면

$$\vec{A} = (1, 1, 1, 1, 1, 0, 0, 0, 0),$$

$$\vec{B} = (0, 1, 0, 1, 0, 1, 1, 0, 0),$$

$$\vec{C} = (0, 1, 0, 0, 0, 0, 1, 1, 1)$$

이고, 이것은 단어 사전 U 의 각 단어가 세 댓글 A, B, C 에 속하는지 속하지 않는지를 보여 준다.

이와 같은 과정을 통해 문장으로 이루어진 비정형 텍스트 데이터를 수로 이루어진 벡터로 표현할 수 있다.

주의 비정형 텍스트 데이터를 벡터로 표현할 때, 벡터의 성분은 단어 사전 U 에 있는 단어의 순서를 따른다.

문제 5 앞의 문제 4에서 단어 사전 U 의 각 단어가 세 단어집합 A, B, C 에 각각 속하면 1, 속하지 않으면 0으로 나타낸 벡터 $\vec{A}, \vec{B}, \vec{C}$ 를 구하시오.

확인
하기

◆ 다음 설명이 옳으면 ○표, 옳지 않으면 ×표를 해 보자.

(1) 벡터 $\vec{X} = (1, 0, 3, 4, 5, 2)$ 의 셋째 성분은 3이다. ()

(2) ‘이 소설은 감동적인 소설이에요.’에서 ‘소설’은 불용어에 포함시킬 수 없다. ()

(3) 문장을 벡터로 표현할 때, 단어집합을 이용할 수 있다. ()