

2

텍스트 데이터 처리

학습 목표

빈도수 벡터를 이용하여 텍스트 데이터를 요약하고 유용한 정보를 추출할 수 있다.

빈도수 벡터를 이용한 주제어 찾기



생각
열기

다음은 인공지능과 수학에 대한 두 표어 A와 B이다.

표어 A

수학으로 혁신하고
수학으로 발전하는 인공지능!

표어 B

수학은 인공지능의 꽃,
인공지능은 수학의 산물!

① 두 표어 A와 B의 단어 사전 U 가

$U = \{\text{수학, 혁신, 발전, 인공지능, 꽃, 산물}\}$

일 때, 단어 사전 U 의 각 단어가 두 표어의 단어집합에 각각 속하면 1, 속하지 않으면 0으로 나타낸 벡터 $\vec{A}$ 와 $\vec{B}$ 를 구해 보자.

② 다음 표는 두 표어 A와 B에 나오는 단어의 *빈도수를 나타낸 것이다. 표를 완성해 보자.

	수학	혁신	발전	인공지능	꽃	산물
A		1	1		0	
B	2			2		1

* 같은 현상이나 일이 반복되는 도수를 빈도수라고 한다.

위의 생각 열기 ①에서 두 표어 A와 B를 벡터로 표현하면

$$\vec{A} = (1, 1, 1, 1, 0, 0), \vec{B} = (1, 0, 0, 1, 1, 1)$$

인데, 이를 통해 단어의 출현 여부는 알 수 있지만 빈도수가 높은 단어가 무엇인지는 알 수 없다.

그러나 ②의 표에서는 각 단어의 빈도수를 나타내었기 때문에 빈도수가 높은 단어를 알 수 있다. 예를 들어 표어 A에서 빈도수가 가장 높은 단어는 ‘수학’이고, 표어 B에서 빈도수가 가장 높은 단어는 ‘수학’과 ‘인공지능’이다.

다량의 텍스트 데이터에서 특정한 단어의 빈도수는 그 데이터의 특성을 판단하는 기준이 되기 때문에, 주제어를 찾거나 선호도를 조사할 때 중요하게 쓰인다.

◆ ‘달리기’, ‘체력’, ‘근력’과 같은 단어가 자주 나오면 해당 문서를 체육 관련 문서로 판단할 수 있고, ‘함수’, ‘방정식’, ‘부등식’과 같은 단어가 자주 나오면 수학 관련 문서로 판단할 수 있다.

인공지능이 벡터를 이용하여 텍스트 데이터의 단어를 수로 처리할 때, 단어 사전을 기준으로 각 단어의 빈도수를 성분으로 하는 벡터를 **빈도수 벡터**라고 한다.

참고 텍스트 데이터에 나오는 단어 중에서 불용어를 제거하고 하나의 가방에 넣은 것을 **단어가방**(Bag of Words)이라고 한다. 단어가방 모형은 빈도수 벡터를 만들 때 이용할 수 있다.

이제 텍스트 데이터의 빈도수 벡터를 구하는 방법을 알아보자.



함께하기

다음은 어느 음식점의 식사 후기 중에서 네 개를 모은 말뭉치이다.

후기 A	추천! 위생적이고 인테리어가 예뻐서 이 음식점을 추천해요.	후기 B	이 음식점은 가격도 저렴하고, 맛도 좋아요! 정말 맛있어요. 추천!
후기 C	역시 저렴, 저렴한 가격! 예쁜 인테리어! 추천하는 음식점!	후기 D	뭐라 해도 맛있죠. 맛있어요! 이 음식점을 추천합니다.

① 네 후기 A, B, C, D의 단어 사전 U 가

$U = \{\text{추천, 위생적, 인테리어, 예쁘다, 음식점, 가격, 저렴, 맛, 좋다}\}$

일 때, 다음 표는 단어 사전 U 에 있는 단어를 순서대로 나열하고, 네 후기 A, B, C, D와 말뭉치에 나오는 단어의 빈도수를 나타낸 것이다. 표를 완성해 보자.

	추천	위생적	인테리어	예쁘다	음식점	가격	저렴	맛	좋다
A	2	1	1		1	0	0	0	0
B	1	0		0	1	1	1		1
C	1	0	1		1	1		0	0
D	1	0	0	0	1	0	0		0
말뭉치				2	4	2	3	4	

② ①의 표로부터 네 후기 A, B, C, D와 말뭉치의 빈도수 벡터를 구해 보자.

위의 **함께하기**에서 네 후기 A, B, C, D와 말뭉치의 빈도수 벡터를 다음과 같이 나타낼 수 있다.

$$\begin{aligned}\vec{A} &= (2, 1, 1, 1, 1, 0, 0, 0, 0), & \vec{B} &= (1, 0, 0, 0, 1, 1, 1, 2, 1), \\ \vec{C} &= (1, 0, 1, 1, 1, 1, 2, 0, 0), & \vec{D} &= (1, 0, 0, 0, 1, 0, 0, 2, 0), \\ \vec{U} &= (5, 1, 2, 2, 4, 2, 3, 4, 1)\end{aligned}$$

빈도수 벡터를 이용하면 어떤 단어가 얼마나 나오는지 알 수 있기 때문에 문서에서 강조하는 내용을 파악할 수 있다. 예를 들어 위의 말뭉치의 빈도수 벡터에서 빈도수가 가장 높은 단어가 ‘추천’이므로, 이 말뭉치의 주제는 ‘추천’임을 알 수 있다.



◆ 함께하기 말뭉치의 단어가방

이처럼 텍스트 데이터의 빈도수 벡터를 구하면 그 데이터의 주제어를 찾을 수 있다.

문제 1 오른쪽 시의 단어집합과 빈도수 벡터를 구하여 이 시의 주제어를 말하시오.

(출처: 윤동주, 『산울림』)

까치가 울어서
산울림,
아무도 못 들은
산울림,

까치가 들었다,
산울림,
저 혼자 들었다,
산울림,

예제 1 아래는 어느 자율주행 자동차 사고 책임에 대한 기사 제목 중에서 세 개를 모은 말뭉치에 대하여 단어집합 A, B, C 와 단어 사전 U 를 구한 것이다. 다음에 답하시오.

$A = \{\text{운전자, 책임, 제조사, 안전}\},$

$B = \{\text{안전, 책임, 주체, 운전자, 제조사, 논란}\},$

$C = \{\text{자동차, 안전, 책임, 운전자, 제조사}\},$

$U = \{\text{운전자, 책임, 제조사, 안전, 주체, 논란, 자동차}\}$

(1) 세 기사 제목 A, B, C 와 말뭉치의 빈도수 벡터를 구하시오.

(2) 각 기사 제목과 말뭉치의 주제어를 말하시오.

제목 A 운전자 책임? 제조사 책임?
안전! 안전! 또 안전!

제목 B 안전 책임의 주체,
운전자와 제조사 책임 논란!

제목 C 자동차 안전 책임?
운전자와 제조사 책임!

풀이 (1) 세 기사 제목 A, B, C 와 말뭉치에 나오는 단어의 빈도수를 표로 나타내면 다음과 같다.

	운전자	책임	제조사	안전	주체	논란	자동차
A	1	2	1	3	0	0	0
B	1	2	1	1	1	1	0
C	1	2	1	1	0	0	1
말뭉치	3	6	3	5	1	1	1

이 표에서 세 기사 제목 A, B, C 와 말뭉치의 빈도수 벡터는

$\vec{A} = (1, 2, 1, 3, 0, 0, 0), \vec{B} = (1, 2, 1, 1, 1, 1, 0),$

$\vec{C} = (1, 2, 1, 1, 0, 0, 1), \vec{U} = (3, 6, 3, 5, 1, 1, 1)$

(2) 세 빈도수 벡터 $\vec{A}, \vec{B}, \vec{C}$ 에서 빈도수가 가장 높은 단어인 ‘안전’, ‘책임’, ‘책임’이 각 기사 제목의 주제어임을 알 수 있다.

또, 빈도수 벡터 $\vec{U}$ 에서 빈도수가 가장 높은 단어인 ‘책임’이 말뭉치의 주제어임을 알 수 있다.

답 풀이 참조

문제 2 아래는 세 스포츠 기사 A, B, C의 단어 사전 U 와 빈도수 벡터 $\vec{A}, \vec{B}, \vec{C}$ 를 구한 것이다. 다음에 답하시오.

$U = \{\text{경기장, 승부차기, 공, 심판, 도루, 번트, 자유투, 리바운드}\},$

$\vec{A} = (3, 4, 2, 1, 0, 0, 0, 0),$

$\vec{B} = (1, 0, 2, 2, 4, 3, 0, 0),$

$\vec{C} = (1, 0, 2, 3, 0, 0, 4, 3)$

(1) 세 기사 A, B, C의 주제어를 각각 구하시오.

(2) 다음에서 세 기사 A, B, C가 나타내는 스포츠를 선으로 연결하시오.



A • 야구

B • 농구

C • 축구

(3) 세 기사 A, B, C를 모은 말뭉치의 주제어를 말하시오.

텍스트 데이터에서의 유용한 정보

56쪽의 함께하기에서 식사 후기에 대한 말뭉치의 빈도수 벡터를 구하여 주제어가 ‘추천’임을 찾았다. 그러나 빈도수 벡터만 이용하면 ‘추천’처럼 빈도수가 높은 주제어는 쉽게 찾을 수 있지만 ‘이 음식점을 추천하는 이유’처럼 유용한 정보를 파악하는 것은 어렵다.

이제 문서에서 빈도수는 낮지만 유용한 정보를 갖는 단어를 찾는 방법인 **TF-IDF**에 대하여 알아보자.



카렌(Karen, S. J., 1935 ~ 2007)

영국의 컴퓨터 과학자로, IDF의 개념을 처음으로 소개하였다.

네 후기

A: 추천! 위생적이고 인테리어가 예뻐서 이 음식점을 추천해요.

B: 이 음식점은 가격도 저렴하고, 맛도 좋아요! 정말 맛있어요. 추천!

C: 역시 저렴, 저렴한 가격! 예쁜 인테리어! 추천하는 음식점!

D: 뭐라 해도 맛있죠. 맛있어요! 이 음식점을 추천합니다.

에 대한 TF-IDF를 구하는 방법은 다음과 같다.

◆ TF는 Term Frequency의 줄임말이다.

단계 1 단어빈도(TF) 구하기

TF = (각 문서에서 그 단어가 나오는 횟수)로 정한다.

		추천	위생적	인테리어	예쁘다	음식점	가격	저렴	맛	좋다
TF	A	2	1	1	1	1	0	0	0	0
	B	1	0	0	0	1	1	1	2	1
	C	1	0	1	1	1	1	2	0	0
	D	1	0	0	0	1	0	0	2	0

◆ DF는 Document Frequency의 줄임말이다.

단계 2 문서빈도(DF) 구하기

DF = (각 단어별로 그 단어가 나오는 문서의 개수)로 정한다.

예를 들어 단계 1의 표에서 ‘추천’은 네 후기에 모두 나오므로 ‘추천’의 DF의 값은 4이고, ‘맛’은 두 문서 B와 D에 나오므로 ‘맛’의 DF의 값은 2이다.

	추천	위생적	인테리어	예쁘다	음식점	가격	저렴	맛	좋다
DF	4	1	2	2	4	2	2	2	1

◆ IDF는 Inverse Document Frequency의 줄임말로, 많은 문장에 나오는 단어의 중요도를 낮추는 역할을 한다.

단계 3 역문서빈도(IDF) 구하기

$IDF = \frac{(\text{전체 문서의 개수})}{DF}$ 로 정한다.

	추천	위생적	인테리어	예쁘다	음식점	가격	저렴	맛	좋다
IDF	1	4	2	2	1	2	2	2	4

단계 4 TF-IDF 구하기

TF-IDF = TF × IDF로 정한다.

예를 들어 후기 A에서 ‘추천’의 TF의 값은 2이고 IDF의 값은 1이므로, 후기 A에서 ‘추천’의 TF-IDF의 값은 $2 \times 1 = 2$ 이다.

		추천	위생적	인테리어	예쁘다	음식점	가격	저렴	맛	좋다
TF-IDF	A	2	4	2	2	1	0	0	0	0
	B	1	0	0	0	1	2	2	4	4
	C	1	0	2	2	1	2	4	0	0
	D	1	0	0	0	1	0	0	4	0

후기 A의 TF에서는 ‘추천’이 ‘위생적’보다 중요도가 높은 단어인 것처럼 보인다. 한편, 문서 전체의 IDF에서는 ‘추천’이 ‘위생적’보다 중요도가 낮은 단어인 것처럼 보인다. 이 경우 후기 A에서는 TF-IDF의 값이 더 큰 ‘위생적’이 ‘추천’보다 TF는 낮지만 더 유용한 단어라 판단한다.

일반적으로 TF-IDF는 모든 문서에서 자주 나오는 단어는 중요도가 낮다고 판단하고, 특정한 문서에서만 자주 나오는 단어는 중요도가 높다고 판단한다. 즉, 특정한 문서에서 TF-IDF의 값이 작은 단어는 그 문서에서 중요도가 낮고, TF-IDF의 값이 큰 단어는 중요도가 높다.

앞에서 구한 TF-IDF로부터 후기 A는 ‘위생적’, 후기 B는 ‘맛’과 ‘좋다’, 후기 C는 ‘저렴’, 후기 D는 ‘맛’이 유용한 정보임을 알 수 있고, 이 정보로부터 각 후기에서 이 음식점을 추천하는 이유를 다음과 같이 판단할 수 있다.

A: 위생적이기 때문에 B: 맛이 좋기 때문에
C: 저렴하기 때문에 D: 맛있기 때문에

예제 2 아래 표는 57쪽 **예제 1**의 세 문서의 단어빈도 TF를 구하여 나타낸 것이다. 다음에 답하시오.

		운전자	책임	제조사	안전	주체	논란	자동차
TF	A	1	2	1	3	0	0	0
	B	1	2	1	1	1	1	0
	C	1	2	1	1	0	0	1

- (1) TF-IDF를 구하시오.
- (2) 각 기사 제목에서 중요도가 가장 높은 단어를 말하시오.

풀이 (1) 각 단어의 문서빈도(DF)와 역문서빈도(IDF)를 구하면 다음과 같다.

	운전자	책임	제조사	안전	주체	논란	자동차
DF	3	3	3	3	1	1	1
IDF	1	1	1	1	3	3	3

이 표를 이용하여 TF-IDF를 구하면 다음과 같다.

		운전자	책임	제조사	안전	주체	논란	자동차
TF-IDF	A	1	2	1	3	0	0	0
	B	1	2	1	1	3	3	0
	C	1	2	1	1	0	0	3

- (2) 각 기사 제목에서 중요도가 가장 높은 단어는
A: 안전, B: 주체, 논란, C: 자동차

 풀이 참조

문제 3 다음은 미세 먼지와 관련된 세 문서 A, B, C의 단어 사전 U 와 단어빈도 TF를 구하여 나타낸 것이다. TF-IDF를 이용하여 각 문서에서 중요도가 가장 높은 단어를 말하시오.

$$U = \{\text{농도, 외출, 환기, 자제, 낮다, 높다}\}$$

		농도	외출	환기	자제	낮다	높다
TF	A	1	2	1	2	0	1
	B	1	0	2	0	2	0
	C	1	0	1	0	0	4

『대수』를 이수한 학생이 학습할 수 있습니다.

TF-IDF는 말뭉치에서 특정한 단어가 얼마나 중요한지를 수치로 나타낸 것으로 $TF \times IDF$ 로 정했다. 일반적으로 인공지능이 다루는 문서에서 전체 문장의 개수 n 은 매우 큰 수이므로 $IDF = \frac{n}{DF}$ 의 값도 매우 커져서 계산이 불편하다. 따라서 IDF를 작은 값으로 만들기 위해 상용로그(common logarithm)의 개념을 이용하여

$$IDF = \log \frac{n}{DF}$$

으로 계산한다.

예를 들어 $n = 10^6$ 이고 $DF = 10^2$ 인 경우에는 $\frac{n}{DF} = 10^4$ 으로 큰 값이지만 상용로그를 이용하면

$$\log \frac{n}{DF} = \log 10^4 = 4$$

로 작은 값이 되어 TF-IDF를 계산하기 편리해진다.

**확인
하기**

◆ 다음 설명이 옳으면 ○표, 옳지 않으면 ×표를 해 보자.

- (1) 빈도수 벡터로 텍스트 데이터의 주제어와 유용한 정보를 쉽게 찾을 수 있다. ()
- (2) TF의 값이 3이고 IDF의 값이 2이면 TF-IDF의 값은 6이다. ()
- (3) 각 문서에서 중요도가 가장 높은 단어를 찾을 때, TF-IDF의 값이 가장 작은 단어를 찾는다. ()

주제어 추적! 글의 핵심을 시각화하다

시각화는 데이터의 분석 결과를 쉽게 이해할 수 있도록 시각적으로 표현하여 효과적으로 전달하는 과정이다. 데이터를 시각화할 때는 주로 표나 그래프 등을 이용하는데, 데이터의 특성을 파악하여 가장 적합한 시각화 방법을 선택하는 것이 매우 중요하다.

시각화 방법에는 많은 종류가 있는데, 그중에서 워드 클라우드의 문서의 핵심 내용을 한눈에 파악하는 데 편리하다.

다음 데이터는 독도에 대한 글의 일부이다. 이 글을 워드 클라우드로 만드는 방법에 대하여 알아보자.

독도는 대한민국 정부 소유의 국유지로서 1982년 천연기념물로 지정된 섬이다. 울릉도의 동남쪽에 위치한 섬으로, 동도와 서도 외에 89개의 부속 도서로 구성되어 있다. 3세기경부터 사람이 살기 시작한 것으로 확인된다. 신라 지증왕 때 우산국이 신라에 병합되면서 부속 섬 독도도 편입되었고, 이후 고려에 이어 조선 시대에도 행정 구역상 우리의 영토로 존재해 왔다. 일제 강점기가 종료되었음에도 불구하고 일본은 독도 소유권 문제를 제기하는 도발을 계속해 오고 있다. 현재 독도 경비대와 등대원이 독도에 상주하고 있으며, 일부 주민이 서도에 거주하면서 어로 활동을 해 오고 있다.

(출처: 이민부, 「독도」)



- 1 워드 클라우드 생성기(<https://wordcloud.kr>)에 접속한다.
- 2 ‘글자색’, ‘폰트’, ‘배경색’을 선택하고 ‘마스크’와 ‘크기’에서 워드 클라우드의 모양과 크기를 정한다. 또, ‘단어수’에서 최대 단어의 수를 선택한다.
- 3 위의 글을 ‘텍스트’ 칸에 입력한다.
- 4 ‘워드 클라우드 만들기’를 클릭하면 오른쪽 그림과 같이 워드 클라우드가 만들어진다.
워드 클라우드에서 빈도수가 높은 단어인 ‘있다’, ‘독도’, ‘부속’, ‘독도는’, ‘대한민국’, ‘소유의’가 이 글의 주제어이므로, 이 글은 ‘독도는 대한민국 소유’와 관련된 내용임을 알 수 있다.



인터넷에서 자율주행에 관련된 글을 하나 검색하여 위와 같은 방법으로 워드 클라우드를 만들고, 그 글의 주제어를 말해 보자.