

3

텍스트 데이터 분석

학습
목표

인공지능이 텍스트를 특성에 따라 분석하는 수학적 방법을 설명할 수 있다.

감성 분석



생각
열기

다음은 어느 온라인 쇼핑몰에서 사과를 구매한 세 소비자 A, B, C의 별점과 후기이다.



- 1 두 소비자 A와 C의 별점과 후기가 긍정 표현인지 부정 표현인지 말해 보자.
- 2 소비자 B의 별점과 후기가 같은 의미인지 생각해 보자.

위의 생각 열기에서 소비자 A의 별점과 후기는 긍정 표현이고, 소비자 C의 별점과 후기는 부정 표현임을 분명히 알 수 있다. 그러나 소비자 B의 별점은 부정에 가깝고 후기는 긍정과 부정이 섞여 있어서 전체적으로 긍정 표현인지 부정 표현인지 판단하기 어렵다.

사람은 소비자 B의 후기가 긍정 표현인지 부정 표현인지 분류하기 어려울 수 있지만, 인공지능을 이용하면 정해진 기준에 따라 객관적으로 분류할 수 있다.

인공지능을 이용하여 텍스트 데이터를 분석하는 방법에는, 주관적인 감성 정보를 추출하여 분석하는 감성 분석과 데이터 사이의 관계를 파악하여 분석하는 유사도 분석이 있다.

먼저 인공지능이 텍스트 데이터를 감성 분석을 이용하여 분석하는 방법에 대해 알아보자.

한 텍스트에 들어 있는 의견이나 감정, 평가, 태도 등의 주관적인 감성 정보를 추출해 인공지능이 그 텍스트를 분류하여 분석하는 것을 **감성 분석(sentiment analysis)**이라고 한다. 감성 분석을 이용하면 텍스트 데이터를 ‘긍정과 부정’ 또는 ‘좋음과 싫음’ 등의 범주로 분류하여 분석할 수 있다.

◆ KNU 한국어 감성 사전
(<http://dilab.kunsan.ac.kr/knu/knu.html>)
은 국립국어원 표준국어대사전의 뜻풀이 분석을 통해 긍정 단어와 부정 단어를 추출하였고, 최근 온라인에서 많이 사용되는 축약어 및 긍정과 부정의 특수 문자 목록도 포함하고 있다.

텍스트 데이터에 대한 감성 분석을 할 때, 텍스트에 포함된 단어들이 긍정 단어인지 부정 단어인지 판단하기 위하여 감성 사전을 이용한다. **감성 사전**이란 긍정 또는 부정과 같은 감성을 포함한 단어들을 구분하여 모아 놓은 것이다. 따라서 감성 사전에 있는 단어는 긍정 단어와 부정 단어로 구분되며, 감성 사전에 없는 단어는 중립 단어로 생각한다.

다음은 긍정 단어와 부정 단어를 모아서 만든 감성 사전이다. 감성 사전을 이용하여 텍스트 데이터에 대한 감성 분석 방법을 알아보자.

 감동, 따뜻하다, 믿다, 사랑, 웃다, 좋다, 귀엽다, 예쁘다, 괜찮다, 재미있다, 최고, 흥미, 행복하다, 달다, 맛있다, 신선하다, 높다, 많다, 보장 긍정 단어	 눈물, 슬프다, 싫어하다, 아쉽다, 아프다, 억지, 울다, 유치하다, 재미없다, 지루하다, 부족, 별로, 작다, 실망, 상하다, 늦다, 못난이, 맛없다 부정 단어
---	---

참고 ‘작다’, ‘높다’, ‘많다’처럼 상황에 따라 긍정 표현이 될 수도 있고 부정 표현이 될 수도 있는 단어가 있다. 이와 같이 긍정과 부정의 판단이 애매한 단어에 대해서는 해당 텍스트의 상황이나 분야에 맞도록 감성 사전을 새롭게 구축할 필요가 있다.

텍스트 데이터의 단어는 감성 사전을 이용하여 긍정 단어, 부정 단어, 중립 단어의 세 범주로 구분할 수 있으므로, 각각의 텍스트를

(긍정 단어의 수, 부정 단어의 수, 중립 단어의 수)

와 같은 벡터로 나타낼 수 있다.


예를 들어 63쪽의 **생각 열기**에서 소비자 A의 후기

A: 달고 맛있어서 좋아요. 다음에 또 주문할 거예요.

로부터 단어집합을

{달다, 맛있다, 좋다, 다음, 주문}

으로 구성하면 이들을 감성 사전에 따라 구분하여 단어의 수를 다음과 같이 구할 수 있다.



이때 소비자 A의 후기를 벡터 (3, 0, 2)와 같이 나타낼 수 있고, 이 벡터를 이 텍스트의 **감성 벡터**라고 한다.

이제 텍스트 데이터를 감성 벡터로 나타내고, 감성 점수를 이용하여 감성 분석을 해 보자.

텍스트의 **감성 점수**는 다음과 같이 정한다.

$$(\text{감성 점수}) = (\text{긍정 단어의 수}) - (\text{부정 단어의 수})$$

즉, 감성 점수는 감성 벡터의 첫째 성분에서 둘째 성분을 뺀 값이다. 이때


(감성 점수) > 0이면 **긍정**,

(감성 점수) < 0이면 **부정**,

(감성 점수) = 0이면 **중립**

으로 분석한다. 예를 들어 소비자 A의 후기의 감성 점수는 $3 - 0 = 3$ 이므로, 소비자 A의 후기는 ‘**긍정**’으로 분석한다.

◆ 텍스트 데이터에 대한 감성 분석 과정은 다음과 같다.



보기 63쪽의 **생각 열기**에서 두 소비자 B와 C의 후기

B: 크기가 작아 실망했는데 신선하고 당도가 높네요.

C: 상한 것이 많고 배송이 늦어서 별로예요. 실망!

에 대한 감성 분석은 다음과 같이 할 수 있다.

	단어집합	감성 벡터	감성 점수	감성 분석
B	{크기, 작다, 실망, 신선하다, 당도, 높다}	(2, 2, 2)	0	중립
C	{상하다, 많다, 배송, 늦다, 별로, 실망}	(1, 4, 1)	-3	부정

문제 1 다음은 63쪽의 **생각 열기**의 온라인 쇼핑몰에서 사과를 구매한 또 다른 두 소비자 D와 E의 후기이다. 표를 완성하시오.

D: 외형은 못난이 사과이지만 껍질째 먹어도 맛있어요. 당도는 보장!

E: 신선해 보이지만 처음에는 맛있어서 실망했는데, 며칠 지나니까 맛있어요.

	단어집합	감성 벡터	감성 점수	감성 분석
D				
E				

지금까지 각각의 후기에 대한 감성 분석 방법을 알아보았다.

이제 텍스트 전체에 대한 감성 분석 방법을 살펴보자. 이때 다음과 같은 벡터의 덧셈을 이용한다.

◆ 벡터의 덧셈은 각 벡터의 차원이 같을 때만 가능하다.

두 벡터

$$\vec{P} = (p_1, p_2, \dots, p_n), \quad \vec{Q} = (q_1, q_2, \dots, q_n)$$

의 덧셈은

$$\vec{P} + \vec{Q} = (p_1 + q_1, p_2 + q_2, \dots, p_n + q_n)$$

과 같이 정한다.

또, 세 개 이상의 벡터에 대하여도 덧셈이 가능하다.

◆ 실수의 덧셈에서와 마찬가지로 벡터의 덧셈에서도 결합법칙이 성립한다.

예를 들어 세 벡터 $\vec{P} = (p_1, p_2, \dots, p_n)$, $\vec{Q} = (q_1, q_2, \dots, q_n)$, $\vec{R} = (r_1, r_2, \dots, r_n)$ 의 덧셈은 다음과 같다.

$$\vec{P} + \vec{Q} + \vec{R} = (p_1 + q_1 + r_1, p_2 + q_2 + r_2, \dots, p_n + q_n + r_n)$$

보기 세 벡터 $\vec{P} = (1, 4, -3)$, $\vec{Q} = (-3, 1, 0)$, $\vec{R} = (5, -3, 2)$ 에 대하여

① $\vec{P} + \vec{Q} = (1 + (-3), 4 + 1, -3 + 0) = (-2, 5, -3)$

② $\vec{P} + \vec{Q} + \vec{R} = (1 + (-3) + 5, 4 + 1 + (-3), -3 + 0 + 2) = (3, 2, -1)$

문제 2 세 벡터 $\vec{P} = (2, 1, 4, 0)$, $\vec{Q} = (0, 1, -2, 3)$, $\vec{R} = (3, -5, 1, 2)$ 에 대하여 다음을 구하시오.

(1) $\vec{P} + \vec{Q}$

(2) $\vec{P} + \vec{Q} + \vec{R}$

63쪽의 **생각 열기**의 세 소비자 A, B, C의 후기를 나타내는 감성 벡터

$$\vec{A}=(3, 0, 2), \vec{B}=(2, 2, 2), \vec{C}=(1, 4, 1)$$

에 대하여

$$\vec{A}+\vec{B}+\vec{C}=(6, 6, 5)$$

이다. 따라서 세 소비자 A, B, C의 전체 후기의 감성 점수는

$$6-6=0$$

이다. 이로부터 세 소비자 A, B, C의 전체 후기는 ‘중립’으로 분석한다.

문제 3 63쪽의 **생각 열기**와 **문제 1**에 제시된 5명의 소비자 A, B, C, D, E의 전체 후기에 대한 감성 분석을 하시오.

텍스트 데이터의 감성 분석을 활용하면 제품 후기를 통해 사람들이 제품에 대하여 긍정적인지 부정적인지를 분석할 수 있고, 공연 감상 평에서 공연의 선호도를 파악할 수도 있다. 또, 이런 분석 결과를 기업은 제품의 품질 개선이나 홍보에 활용할 수 있고, 개인은 제품을 구매할 때 참고할 수 있다.

따라서 감성 분석은 텍스트 데이터에서 가치 있는 정보를 찾아내는 데 유용한 방법이다.

유사도의 종류



다음은 세 문장 T_1 , T_2 , T_3 을 모은 말뭉치이다.

T_1 : 딸기를 좋아하고, 바나나도 좋아한다.

T_2 : 딸기는 좋아하지만, 바나나는 싫어한다.

T_3 : 딸기와 바나나를 모두 싫어한다.

◆ 세 문장 T_1 , T_2 , T_3 을 유사한 정도에 따라 두 그룹으로 분류해 보자.



67쪽의 **생각 열기**에서 세 문장 T_1, T_2, T_3 을 유사한 정도에 따라 두 그룹으로 분류하는 것은 사람마다 기준이 주관적이기 때문에 다양한 결과가 나올 수 있다.

예를 들어 딸기를 좋아하는 그룹과 싫어하는 그룹으로 나눌 수도 있고, 바나나를 좋아하는 그룹과 싫어하는 그룹으로 나눌 수도 있다.

인공지능을 이용하여 텍스트 데이터를 분류하기 위해서는 두 텍스트 사이의 유사한 정도를 정량화할 필요가 있다.

두 텍스트 사이의 유사한 정도를 수치화한 것을 **유사도(similarity)**라 하고, 보통 유클리드 유사도, 코사인 유사도, 자카드 유사도를 많이 사용한다.

1. 유클리드 유사도(Euclid similarity)

두 텍스트 P와 Q를 나타내는 벡터가

$$\vec{P} = (p_1, p_2, \dots, p_n), \quad \vec{Q} = (q_1, q_2, \dots, q_n)$$


일 때, P와 Q의 유클리드 유사도를 기호 $D(P, Q)$ 로 나타내고

$$D(P, Q) = \sqrt{(q_1 - p_1)^2 + (q_2 - p_2)^2 + \dots + (q_n - p_n)^2}$$

과 같이 정한다.

보기 두 텍스트 P와 Q를 나타내는 벡터가 $\vec{P} = (5, 1)$ 과 $\vec{Q} = (2, 3)$ 일 때, P와 Q의 유클리드 유사도 $D(P, Q)$ 는

$$D(P, Q) = \sqrt{(2-5)^2 + (3-1)^2} = \sqrt{13}$$




참고 **보기**의 유클리드 유사도 $D(P, Q)$ 는 좌표평면 위의 두 점 $P(5, 1)$ 과 $Q(2, 3)$ 사이의 거리와 같다.

문제 4 두 텍스트 P와 Q를 나타내는 벡터가 $\vec{P} = (1, 2, 4)$ 와 $\vec{Q} = (3, 0, 1)$ 일 때, P와 Q의 유클리드 유사도 $D(P, Q)$ 를 구하시오.

두 텍스트의 유클리드 유사도는 텍스트를 나타내는 벡터의 성분에 의해 결정되는 두 점 사이의 거리와 같다. 그러므로 두 점 사이의 거리가 가까울수록 유클리드 유사도의 값은 작아진다.

따라서 유클리드 유사도의 값이 0에 가까울수록 두 텍스트가 유사하다고 판단한다.

예를 들어 오른쪽 그림과 같이 세 텍스트를 나타내는 벡터 $\vec{A}$, $\vec{B}$, $\vec{C}$ 의 성분에 의해 결정되는 세 점 A, B, C 중에서 두 점 A와 B 사이의 거리가 가장 가까우므로, 두 벡터 $\vec{A}$ 와 $\vec{B}$ 로 나타내어진 두 텍스트가 가장 유사하다고 판단할 수 있다.



◆ 세 텍스트 P, Q, R의 유클리드 유사도를 표로 나타내면 다음과 같다.

	P	Q	R
P	0	$\sqrt{3}$	$\sqrt{5}$
Q	$\sqrt{3}$	0	$\sqrt{2}$
R	$\sqrt{5}$	$\sqrt{2}$	0

예제 1 세 텍스트 P, Q, R을 나타내는 벡터가 다음과 같을 때, 유클리드 유사도를 이용하여 가장 유사한 텍스트 두 개를 고르시오.

$$\vec{P} = (0, 1, 2), \quad \vec{Q} = (1, 2, 1), \quad \vec{R} = (1, 1, 0)$$

풀이 P와 Q, Q와 R, R과 P의 유클리드 유사도를 구하면

$$D(P, Q) = \sqrt{(1-0)^2 + (2-1)^2 + (1-2)^2} = \sqrt{3},$$

$$D(Q, R) = \sqrt{(1-1)^2 + (1-2)^2 + (0-1)^2} = \sqrt{2},$$

$$D(R, P) = \sqrt{(0-1)^2 + (1-1)^2 + (2-0)^2} = \sqrt{5}$$

따라서 유클리드 유사도의 값이 가장 작은 Q와 R이 가장 유사하다.

답 Q와 R

문제 5 세 텍스트 P, Q, R을 나타내는 벡터가 다음과 같을 때, 유클리드 유사도를 이용하여 가장 유사한 텍스트 두 개를 고르시오.

$$\vec{P} = (0, 2, 1, 1), \quad \vec{Q} = (1, 2, 1, 0), \quad \vec{R} = (1, 0, 1, 2)$$

2. 코사인 유사도(Cosine similarity)

두 텍스트 P와 Q를 나타내는 벡터가

$$\vec{P} = (p_1, p_2, \dots, p_n), \quad \vec{Q} = (q_1, q_2, \dots, q_n)$$

일 때, P와 Q의 코사인 유사도를 기호 $C(P, Q)$ 로 나타내고

$$C(P, Q) = \frac{p_1q_1 + p_2q_2 + \dots + p_nq_n}{\sqrt{p_1^2 + p_2^2 + \dots + p_n^2} \sqrt{q_1^2 + q_2^2 + \dots + q_n^2}}$$

과 같이 정한다.

보기 두 텍스트 P와 Q를 나타내는 벡터가 $\vec{P} = (1, 2)$ 와 $\vec{Q} = (3, 1)$ 일 때, P와 Q의 코사인 유사도 $C(P, Q)$ 는

$$C(P, Q) = \frac{1 \times 3 + 2 \times 1}{\sqrt{1^2 + 2^2} \sqrt{3^2 + 1^2}} = \frac{5}{\sqrt{5} \sqrt{10}} = \frac{\sqrt{2}}{2}$$


문제 6 두 텍스트 P와 Q를 나타내는 벡터가 $\vec{P}=(1, 2, 3)$ 과 $\vec{Q}=(2, 3, 1)$ 일 때, P와 Q의 코사인 유사도 $C(P, Q)$ 를 구하시오.

◆ θ 는 그리스 문자로, '세타(theta)'라고 읽는다.

◆ 두 텍스트 P와 Q를 벡터로 표현하는 방법에 따라

$C(P, Q) < 0$
이 될 수도 있다.

두 텍스트 P와 Q를 나타내는 벡터 $\vec{P}$ 와 $\vec{Q}$ 가 이루는 각의 크기를 θ ($0^\circ \leq \theta \leq 90^\circ$)라 할 때, 두 텍스트 P와 Q의 코사인 유사도 $C(P, Q)$ 는 $\cos \theta$ 와 같음이 알려져 있다. 이와 같은 이유에서 $C(P, Q)$ 를 코사인 유사도라고 부른다. 이때 $0 \leq C(P, Q) \leq 1$ 이다.



참고 $\cos 45^\circ = \frac{\sqrt{2}}{2}$ 이므로 69쪽의 **보기**에서 두 벡터 $\vec{P}$ 와 $\vec{Q}$ 가 이루는 각의 크기는 45° 임을 알 수 있다.

◆ θ 가 0° 에 가까울수록 두 텍스트는 유사하다.

두 텍스트를 나타내는 벡터가 이루는 각의 크기가 작아질수록 코사인 유사도의 값은 커진다.

따라서 코사인 유사도의 값이 1에 가까울수록 두 텍스트가 유사하다고 판단한다.

예제 2 세 텍스트 P, Q, R을 나타내는 벡터가 다음과 같을 때, 코사인 유사도를 이용하여 가장 유사한 텍스트 두 개를 고르시오.

$$\vec{P}=(0, 1, 1), \vec{Q}=(1, 0, 2), \vec{R}=(2, 0, 0)$$

◆ 세 텍스트 P, Q, R의 코사인 유사도를 표로 나타내면 다음과 같다.

	P	Q	R
P	1	$\frac{\sqrt{10}}{5}$	0
Q	$\frac{\sqrt{10}}{5}$	1	$\frac{\sqrt{5}}{5}$
R	0	$\frac{\sqrt{5}}{5}$	1

풀이 P와 Q, Q와 R, R과 P의 코사인 유사도를 구하면

$$C(P, Q) = \frac{0 \times 1 + 1 \times 0 + 1 \times 2}{\sqrt{0^2 + 1^2 + 1^2} \sqrt{1^2 + 0^2 + 2^2}} = \frac{2}{\sqrt{10}} = \frac{\sqrt{10}}{5},$$

$$C(Q, R) = \frac{1 \times 2 + 0 \times 0 + 2 \times 0}{\sqrt{1^2 + 0^2 + 2^2} \sqrt{2^2 + 0^2 + 0^2}} = \frac{2}{2\sqrt{5}} = \frac{\sqrt{5}}{5},$$


$$C(R, P) = \frac{2 \times 0 + 0 \times 1 + 0 \times 1}{\sqrt{2^2 + 0^2 + 0^2} \sqrt{0^2 + 1^2 + 1^2}} = \frac{0}{2\sqrt{2}} = 0$$

따라서 코사인 유사도의 값이 가장 큰 P와 Q가 가장 유사하다.

답 P와 Q

문제 7 세 텍스트 P, Q, R을 나타내는 벡터가 다음과 같을 때, 코사인 유사도를 이용하여 가장 유사한 텍스트 두 개를 고르시오.

$$\vec{P}=(1, 2, 0, 1), \vec{Q}=(0, 1, 0, 1), \vec{R}=(1, 0, 1, 1)$$



자카드(Jaccard, P., 1868 ~ 1944)
스위스의 식물학자로, 식물 사이의 유사도를 정리하기 위해 자카드 유사도를 고안하였다.

배웠어요

$n(A)$ 는 유한집합 A 의 원소의 개수를 나타낸다.

3. 자카드 유사도(Jaccard similarity)

지금까지는 벡터를 이용하는 유클리드 유사도와 코사인 유사도에 대하여 알아보았다.

이제 집합을 이용하는 유사도에 대하여 알아보자.

함께하기

다음은 세 학생 A, B, C가 좋아하는 영화 장르 5가지를 단어집합으로 나타낸 것이다.

$A = \{\text{액션, 코미디, 스릴러, 전쟁, 판타지}\},$

$B = \{\text{액션, 스릴러, 뮤지컬, 드라마, SF}\},$

$C = \{\text{액션, 코미디, 스릴러, 드라마, SF}\}$

① 세 집합 $A \cap B, B \cap C, C \cap A$ 를 구해 보자.

② 세 집합 $A \cup B, B \cup C, C \cup A$ 를 구해 보자.

③ $\frac{n(A \cap B)}{n(A \cup B)}, \frac{n(B \cap C)}{n(B \cup C)}, \frac{n(C \cap A)}{n(C \cup A)}$ 의 값을 구해 보자.

④ ③을 이용하여 좋아하는 영화 장르가 가장 유사한 두 학생을 추측해 보자.

위의 함께하기에서 두 집합의 합집합의 원소의 개수를 기준으로 할 때, 두 집합에 공통으로 포함되는 원소가 많을수록 좋아하는 영화 장르가 유사하다고 말할 수 있다.

이와 같이 각 텍스트를 단어집합으로 표현하고, 두 집합의 교집합의 원소의 개수를 두 집합의 합집합의 원소의 개수로 나눈 값을 자카드 유사도라고 한다.

두 텍스트 P와 Q의 단어집합이 P와 Q일 때, P와 Q의 자카드 유사도를 기호 $J(P, Q)$ 로 나타내고

$$J(P, Q) = \frac{n(P \cap Q)}{n(P \cup Q)}$$

와 같이 정한다.

$$\begin{aligned} \diamond n(P \cup Q) \\ &= n(P) + n(Q) \\ &\quad - n(P \cap Q) \end{aligned}$$

$$\begin{aligned} \diamond P \cap Q = \emptyset \text{이면} \\ J(P, Q) &= 0, \\ P = Q \text{ 이면} \\ J(P, Q) &= 1 \end{aligned}$$

두 텍스트 P와 Q의 단어집합 P와 Q에 대하여 $0 \leq n(P \cap Q) \leq n(P \cup Q)$ 이므로 $0 \leq J(P, Q) \leq 1$ 이다.

두 텍스트의 단어집합에 공통으로 포함되는 원소가 많을수록 자카드 유사도의 값은 커진다.

따라서 자카드 유사도의 값이 1에 가까울수록 두 텍스트가 유사하다고 판단한다.

보기 71쪽의 함께하기에서

$$J(A, B) = \frac{1}{4}, \quad J(B, C) = \frac{2}{3}, \quad J(C, A) = \frac{3}{7}$$

따라서 자카드 유사도의 값이 가장 큰 B와 C가 가장 유사하다.

문제 8 다음은 어느 일기 예보 기사 제목 중에서 세 개를 모은 말뭉치에 대하여 단어집합 A, B, C 를 구한 것이다. 자카드 유사도를 이용하여 가장 유사한 기사 제목 두 개를 고르시오.

제목 A 한파에 눈 예보, 일부는 비 예보
제목 B 눈 예보, 퇴근길에 눈 조심!
제목 C 비 예보, 일부는 눈 또는 비, 비 그치면 한파

$A = \{\text{한파, 눈, 예보, 일부, 비}\},$
 $B = \{\text{눈, 예보, 퇴근길, 조심}\},$
 $C = \{\text{비, 예보, 일부, 눈, 그치다, 한파}\}$

유사도 분석

유사도를 이용하여 텍스트 데이터 사이의 관계를 파악하여 분석하는 것을 **유사도 분석** (similarity analysis)이라고 한다.

여기서는 앞에서 배운 세 가지 유사도를 이용하여 유사도 분석을 하고, 그 결과를 비교해 보자.

다음은 환경에 대한 세 문서 A, B, C에 나오는 주요 단어의 빈도수를 표로 나타낸 것이다. 문서 C가 두 문서 A와 B 중에서 어느 문서와 더 유사한지 알아보자.

	대기	오존	환경	오염	미세먼지	폐수	하천	수질	하수	댐
A	3	2	3	3	2	0	0	0	0	1
B	0	0	0	0	2	3	3	7	5	5
C	0	0	0	1	1	1	1	2	2	2

세 문서 A, B, C의 단어 사전

$$U = \{\text{대기, 오존, 환경, 오염, 미세먼지, 폐수, 하천, 수질, 하수, 댐}\}$$

에 대하여 단어집합과 빈도수 벡터를 구하면 다음과 같다.

$$A = \{\text{대기, 오존, 환경, 오염, 미세먼지, 댐}\}, \quad \vec{A} = (3, 2, 3, 3, 2, 0, 0, 0, 0, 1)$$

$$B = \{\text{미세먼지, 폐수, 하천, 수질, 하수, 댐}\}, \quad \vec{B} = (0, 0, 0, 0, 2, 3, 3, 7, 5, 5)$$

$$C = \{\text{오염, 미세먼지, 폐수, 하천, 수질, 하수, 댐}\}, \quad \vec{C} = (0, 0, 0, 1, 1, 1, 1, 2, 2, 2)$$

이때 문서 C와 A, 문서 C와 B의 유클리드 유사도, 코사인 유사도, 자카드 유사도를 구하여 표로 나타내면 다음과 같다.

	유클리드 유사도	코사인 유사도	자카드 유사도
C와 A	$\sqrt{38}$	$\frac{7}{24}$	$\frac{3}{10}$
C와 B	$\sqrt{53}$	$\frac{21}{22}$	$\frac{6}{7}$

이 표를 이용하여 인공지능은 다음과 같이 판단한다.

유클리드 유사도	코사인 유사도	자카드 유사도
$D(C, A) < D(C, B)$ ↓ 문서 C는 문서 A와 더 유사하다.	$C(C, A) < C(C, B)$ ↓ 문서 C는 문서 B와 더 유사하다.	$J(C, A) < J(C, B)$ ↓ 문서 C는 문서 B와 더 유사하다.

이와 같이 어떤 유사도를 사용하는지에 따라 유사도 분석의 결과는 달라질 수 있다. 따라서 텍스트의 분석 목적과 특성에 따라 적절한 유사도를 선택해야 의미 있는 분석 결과를 얻을 수 있다.

문제 9 다음 표는 세 문서 A, B, C에 나오는 주요 단어의 빈도수를 나타낸 것이다. 유클리드 유사도, 코사인 유사도, 자카드 유사도를 이용하여 문서 C와 가장 유사한 문서를 찾으시오.

	발라드	힙합	록	팝
A	2	0	1	2
B	0	4	0	3
C	2	3	2	0

확인
하기

◆ 다음 설명이 옳으면 ○표, 옳지 않으면 ×표를 해 보자.

- (1) 텍스트 데이터에 대하여 감성 분석을 할 때, 텍스트에 포함된 단어들을 긍정 단어 또는 부정 단어로만 구분한다. ()
- (2) 두 텍스트의 유클리드 유사도, 코사인 유사도, 자카드 유사도의 값이 1에 가까울수록 두 텍스트가 유사하다고 판단한다. ()



AI 웹 실험실로 텍스트 데이터 분석하기

◆ AskMath는 수학 학습 진단, 수학 콘텐츠 등을 제공하는 누리집이다.

(<https://askmath.kosac.re.kr>)

다음 데이터는 은하에 대한 글의 일부이다. AskMath의 AI 웹 실험실을 이용하여 이 글에 있는 문장의 세 가지 유사도를 구하고, 유사도 분석을 해 보자.

별들은 우주 공간에 아무렇게나 흩어져 있는 것이 아니다. 20세기 초까지만 해도 사람들은 우리 은하계가 우주의 전부라고 생각했다. 당시의 망원경은 지금보다 성능이 떨어졌기 때문에 뿌연 구름 덩어리처럼 보이는 천체를 모두 성운이라고 불렀다. 하지만 망원경의 성능이 향상되고 관측 기술이 발전하면서 수많은 별들이 모여 있는 별들의 집단, 즉 은하가 있다는 것을 알게 되었다. 우리 은하계 밖에 있는 은하를 외부 은하라고 하는데, 우주에는 이런 외부 은하들이 수없이 많다. 사람들이 이 도시에 모여 살듯이, 별들은 은하에 모여 사는 셈이다. 은하는 우주의 바다에 떠 있는 별들의 섬이며, 은하는 하나의 작은 우주가 된다. 별들은 은하 속에서 태어나고 폭발해서 사라진다. 천문학자 허블은 수많은 은하를 형태에 따라 나선 은하, 타원 은하 등으로 분류하였다. 나선 은하는 어두운 먼지층과 함께 나선팔이 보이는 은하인데 원반 모양을 하고 있으나 지구를 향하고 있는 방향에 따라 다르게 보인다. 타원 은하는 원반이나 나선팔이 없고 별의 재료가 되는 가스나 어두운 먼지층도 보이지 않는 구형 또는 타원체 모양의 은하이다.

(출처: 김충섭, 「은하」)



① AskMath 누리집에 접속한다.

② 메뉴에서 '수학 학습 > AI 웹 실험실 > 텍스트 분석'을 클릭한다.

③ 안내된 공지 사항에 따라 위의 글을 입력하고 '입력 완료'를 클릭하면 상위 10개의 문장의 '문장 분리' 결과를 확인할 수 있다.

공지 사항

- 텍스트 분석은 "한국어"를 대상으로 합니다.
- 포털 뉴스 기사 등을 입력하면, 텍스트에 대한 결과가 분석됩니다.
- 텍스트 분석은 입력된 전체 문서 중 상위 10개의 문장과, 문장에 존재하는 10개의 한국어 명사를 기준으로 합니다. (워드 클라우드의 전체 명사, 연결망은 20개 명사 사용)
- 입력된 문서에 대해 조건 확인이 진행되며, 조건 충족 여부에 따라 오류 안내가 발생합니다. (감성 분석 제외)

입력 문서의 문장 분리 (최대 10개)

No	내용
문장 1	별들은 우주 공간에 아무렇게나 흩어져 있는 것이 아니다.
문장 2	20세기 초까지만 해도 사람들은 우리 은하계가 우주의 전부라고 생각했다.
문장 3	당시의 망원경은 지금보다 성능이 떨어졌기 때문에 뿌연 구름 덩어리처럼 보이는 천체를 모두 성운이라고 불렀다.
문장 4	하지만 망원경의 성능이 향상되고 관측 기술이 발전하면서 수많은 별들이 모여 있는 별들의 집단, 즉 은하가 있다는 것을 알게 되었다.
문장 5	우리 은하계 밖에 있는 은하를 외부 은하라고 하는데, 우주에는 이런 외부 은하들이 수없이 많다.
문장 6	사람들이 도시에 모여 살듯이, 별들은 은하에 모여 사는 셈이다.
문장 7	은하는 우주의 바다에 떠 있는 별들의 섬이며, 은하는 하나의 작은 우주가 된다.
문장 8	별들은 은하 속에서 태어나고 폭발해서 사라진다.
문장 9	천문학자 허블은 수많은 은하를 형태에 따라 나선 은하, 타원 은하 등으로 분류하였다.
문장 10	나선 은하는 어두운 먼지층과 함께 나선팔이 보이는 은하인데 원반 모양을 하고 있으나 지구를 향하고 있는 방향에 따라 다르게 보인다.

◆ 불용어 제거 후 사용자 목적에 따라 명사만 추출할 수 있다.

④ '다음'을 클릭하면 첫째 문장의 '텍스트 전처리' 과정을 확인할 수 있다.

⑤ '다음'을 클릭하면 10개의 문장에 나오는 주요 단어의 TF와 TF-IDF의 결과를 확인할 수 있다.

- ⑥ ‘다음’을 클릭하면 10개의 문장의 코사인 유사도, 자카드 유사도, 유클리드 유사도의 결과를 확인할 수 있다.

코사인 유사도										공식 보기
No	문장 3	문장 4	문장 1	문장 2	문장 10	문장 9	문장 7	문장 8	문장 5	문장 6
문장 1	0	0.44	1	0.33	0	0	0.58	0.41	0.15	0.33
문장 2	0	0	0.33	1	0	0	0.38	0	0.3	0.33
문장 3	1	0.53	0	0	0	0	0	0	0	0
문장 4	0.53	1	0.44	0	0.34	0.36	0.5	0.8	0.29	0.65
문장 5	0	0.29	0.15	0.3	0.69	0.73	0.69	0.55	1	0.45
문장 6	0	0.65	0.33	0.33	0.52	0.55	0.58	0.82	0.45	1
문장 7	0	0.5	0.58	0.38	0.6	0.63	1	0.71	0.69	0.58
문장 8	0	0.8	0.41	0	0.63	0.67	0.71	1	0.55	0.82
문장 9	0	0.36	0	0	0.99	1	0.63	0.67	0.73	0.55
문장 10	0	0.34	0	0	1	0.99	0.6	0.63	0.69	0.52

자카드 유사도										공식 보기
No	문장 3	문장 4	문장 1	문장 2	문장 10	문장 9	문장 7	문장 8	문장 5	문장 6
문장 1	0	0.17	1	0.2	0	0	0.5	0.25	0.17	0.2
문장 2	0	0	0.2	1	0	0	0.2	0	0.4	0.2
문장 3	1	0.5	0	0	0	0	0	0	0	0
문장 4	0.5	1	0.17	0	0.2	0.2	0.4	0.5	0.14	0.4
문장 5	0	0.14	0.17	0.4	0.2	0.2	0.4	0.2	1	0.17
문장 6	0	0.4	0.2	0.2	0.25	0.25	0.5	0.67	0.17	1
문장 7	0	0.4	0.5	0.2	0.25	0.25	1	0.67	0.4	0.5
문장 8	0	0.5	0.25	0	0.33	0.33	0.67	1	0.2	0.67
문장 9	0	0.2	0	0	1	1	0.25	0.33	0.2	0.25
문장 10	0	0.2	0	0	1	1	0.25	0.33	0.2	0.25

유클리드 유사도										공식 보기
No	문장 3	문장 4	문장 1	문장 2	문장 10	문장 9	문장 7	문장 8	문장 5	문장 6
문장 1	2.24	2.45	0	2	2.83	3.61	2.45	1.73	4	2
문장 2	2.24	3.16	2	0	2.83	3.61	2.83	2.24	3.74	2
문장 3	0	2.24	2.24	2.24	2.65	3.46	3.32	2	4.12	2.24
문장 4	2.24	0	2.45	3.16	2.83	3.32	2.83	1.73	4	2
문장 5	4.12	4	4	3.74	2.83	2.65	2.83	3.32	0	3.46
문장 6	2.24	2	2	2	2	2.65	2.45	1	3.46	0
문장 7	3.32	2.83	2.45	2.83	2.45	2.65	0	2.24	2.83	2.45
문장 8	2	1.73	1.73	2.24	1.73	2.45	2.24	0	3.32	1
문장 9	3.46	3.32	3.61	3.61	1	0	2.65	2.45	2.65	2.65
문장 10	2.65	2.83	2.83	2.83	0	1	2.45	1.73	2.83	2

위의 세 가지 유사도의 결과를 보면 각 문장이 어느 문장과 가장 유사한지 확인할 수 있다. 예를 들어 문장 1은 다음과 같이 유사도 분석을 할 수 있다.

- ① C (문장 1, 문장 7)의 값이 가장 크므로, 문장 1은 문장 7과 가장 유사하다.
- ② J (문장 1, 문장 7)의 값이 가장 크므로, 문장 1은 문장 7과 가장 유사하다.
- ③ D (문장 1, 문장 8)의 값이 가장 작으므로, 문장 1은 문장 8과 가장 유사하다.

이와 같은 방법으로 한 문서에서 가장 유사한 문장을 찾을 수 있는데, 이때 어떤 유사도를 사용하는지에 따라 그 결과는 다를 수 있다.



인터넷에서 자신의 관심 분야를 다룬 글을 하나 검색한 후, 위와 같은 방법으로 코사인 유사도, 자카드 유사도, 유클리드 유사도 분석을 해 보자.

스팸 메일은 어떻게 분류할까?


활동
목표

단어의 빈도수와 퍼셉트론을 이용하여 스팸 메일을 분류할 수 있다.

현대 사회에서 우리는 이메일(e-mail)을 이용하여 편리하게 정보를 주고받을 수 있다. 메일함에 접속하면 스팸 메일함에 자동으로 스팸 메일이 분류되어 있음을 알 수 있는데, 이를 ‘스팸 메일 자동 분류 서비스’라고 한다.

인공지능은 텍스트 데이터에 포함된 특정한 단어의 빈도수를 분석하고 퍼셉트론을 이용하여 정상 메일과 스팸 메일로 분류할 수 있다.

인공지능이 정상 메일과 스팸 메일을 분류하는 방법을 알아보자.



메일함에 도착한 메일에 나오는 ‘할인’과 ‘협조’라는 단어의 빈도수를 각각 x_1 과 x_2 라 하자. 입력값 x_1 과 x_2 에 대한 가중치가 w_1 과 w_2 일 때, 가중합이 $x = x_1w_1 + x_2w_2$ 이고 활성화함수가

$$\sigma(x) = \begin{cases} \text{스팸} & (x \geq c) \\ \text{정상} & (x < c) \end{cases} \quad (c \text{는 임계값})$$

인 퍼셉트론을 생각해 보자.


예를 들어 가중치가 $w_1 = 1.5$ 와 $w_2 = -1$ 이고 임계값이 $c = 0$ 인 퍼셉트론은 4개의 메일을 다음과 같이 분류할 수 있다.

x_1	x_2	x	$\sigma(x)$	실제 메일
2	7	$2 \times 1.5 + 7 \times (-1) = -4$	정상	정상
3	6	$3 \times 1.5 + 6 \times (-1) = -1.5$	정상	정상
6	1	$6 \times 1.5 + 1 \times (-1) = 8$	스팸	스팸
7	2	$7 \times 1.5 + 2 \times (-1) = 8.5$	스팸	스팸

오른쪽 그림은 위의 4개의 입력값에 대한 순서쌍 (x_1, x_2) 를 좌표평면 위에 나타낸 것이다. 이때 $x_1w_1 + x_2w_2 = 0$ 을 직선의 방정식으로 생각하고, $w_1 = 1.5$ 와 $w_2 = -1$ 을 대입하면

$$1.5x_1 - x_2 = 0, \quad \text{즉} \quad 3x_1 - 2x_2 = 0$$

이다. 이 직선은 오른쪽 그림과 같이 4개의 점을 정상과 스팸으로 구분하고 있음을 알 수 있다.




이와 같이 퍼셉트론은 좌표평면 위에 점으로 나타낸 입력값을 직선으로 구분하여 정상 메일과 스팸 메일을 분류한다. 이때 학습용 데이터를 추가하여 가중치와 임계값을 조정하면서 퍼셉트론을 학습시켜야 인공지능이 정상 메일과 스팸 메일을 정확히 분류할 수 있다.

활동 1 아래 표는 2개의 메일을 추가로 조사하여 분류한 결과를 나타낸 것이다. 다음에 답해 보자.

x_1	x_2	x	$\sigma(x)$	실제 메일
3	2			스팸
5	6			정상


- (1) 앞의 퍼셉트론에 대하여 표를 완성하고, 이 퍼셉트론이 2개의 메일을 정확히 분류하는지 말해 보자.
- (2) 6개의 입력값에 대한 순서쌍 (x_1, x_2) 를 오른쪽 좌표평면 위에 나타내고, 직선 $x_1w_1 + x_2w_2 = 0$ 이 6개의 점을 정상과 스팸으로 구분하도록 가중치 w_1 과 w_2 를 정해 보자.



활동 2 아래 표는 2개의 메일을 추가로 조사하여 분류한 결과를 나타낸 것이다. 다음에 답해 보자.

x_1	x_2	x	$\sigma(x)$	실제 메일
1	2			스팸
7	6			정상

- (1) **활동 1** (2)의 퍼셉트론에 대하여 표를 완성하고, 이 퍼셉트론이 2개의 메일을 정확히 분류하는지 말해 보자.
- (2) 8개의 입력값에 대한 순서쌍 (x_1, x_2) 를 오른쪽 좌표평면 위에 나타내고, 직선 $x_1w_1 + x_2w_2 = 0$ 이 8개의 점을 정상과 스팸으로 구분하도록 가중치 w_1 과 w_2 를 정할 수 있는지 말해 보자.
- (3) 직선 $x_1w_1 + x_2w_2 = c$ 가 8개의 점을 정상과 스팸으로 구분하도록 가중치 w_1, w_2 와 임계값 c 를 정해 보자.



프로젝트 평가

- 단어의 빈도수와 퍼셉트론을 이용하여 스팸 메일을 분류하는 과정을 이해하였는가?
- 프로젝트 해결 과정을 논리적으로 설명하였는가?
- 프로젝트에 적극적으로 참여하고 다른 학생의 의견을 경청하였는가?



☐	☐	☐
☐	☐	☐
☐	☐	☐

만족 보통 부족

II 대단원 정리

1 텍스트 데이터 표현

텍스트 데이터를 수학 기호로 표현하기

(1) 정형 텍스트 데이터는 벡터, 비정형 텍스트 데이터는 집합이나 벡터를 이용하여 수학 기호로 표현할 수 있다.

(2) 벡터: n 개의 수 $x_1, x_2, \dots, x_n$ 을 괄호 속에 순서대로 나열하여 나타낸 것 $\rightarrow$ 성분

$$\vec{X} = (x_1, x_2, \dots, x_n) \rightarrow \text{차원: } n$$

(3) 집합: 어떤 기준에 따라 대상을 분명하게 정할 수 있을 때, 그 대상들의 모임

단어집합: 텍스트 데이터에서 불용어를 제거하고 남은 단어를 원소로 하는 집합

단어 사전: 단어집합의 합집합

2 텍스트 데이터 처리

빈도수 벡터

(1) 빈도수 벡터: 단어 사전을 기준으로 각 단어의 빈도수를 성분으로 하는 벡터

$\rightarrow$ 빈도수 벡터를 만들 때 단어가방 모형을 이용할 수 있다.

(2) 텍스트 데이터의 빈도수 벡터를 구하면 그 데이터의 주제를 찾을 수 있다.

TF-IDF 구하는 방법

① TF=(각 문서에서 그 단어가 나오는 횟수) 구하기

단어빈도 $\rightarrow$

② DF=(각 단어별로 그 단어가 나오는 문서의 개수) 구하기

문서빈도 $\rightarrow$

③ IDF= $\frac{(\text{전체 문서의 개수})}{DF}$ 구하기

역문서빈도 $\rightarrow$

④ TF-IDF=TF×IDF 구하기

$\rightarrow$ TF-IDF의 값이 작은 단어는 중요도가 낮고, TF-IDF의 값이 큰 단어는 중요도가 높다.

3 텍스트 데이터 분석

감성 분석

(1) 감성 분석: 한 텍스트에 들어 있는 의견이나 주관적 감성 정보를 추출해 인공지능이 그 텍스트를 분류하여 분석하는 것

(2) 텍스트 데이터에 대한 감성 분석

(감성 점수) > 0 $\rightarrow$ 긍정

(감성 점수) < 0 $\rightarrow$ 부정

(감성 점수) = 0 $\rightarrow$ 중립

$\rightarrow$ (감성 점수) = (긍정 단어의 수) - (부정 단어의 수)

유사도: 두 텍스트 사이의 유사한 정도를 수치화한 것

유클리드 유사도

(1) 두 텍스트 P와 Q를 나타내는 벡터가

$$\vec{P} = (p_1, p_2, \dots, p_n), \vec{Q} = (q_1, q_2, \dots, q_n)$$

일 때, P와 Q의 유클리드 유사도 $D(P, Q)$ 는

$$D(P, Q) = \sqrt{(q_1 - p_1)^2 + (q_2 - p_2)^2 + \dots + (q_n - p_n)^2}$$

(2) 유클리드 유사도의 값이 0에 가까울수록 두 텍스트가 유사하다고 판단한다.

코사인 유사도

(1) 두 텍스트 P와 Q를 나타내는 벡터가

$$\vec{P} = (p_1, p_2, \dots, p_n), \vec{Q} = (q_1, q_2, \dots, q_n)$$

일 때, P와 Q의 코사인 유사도 $C(P, Q)$ 는

$$C(P, Q) = \frac{p_1 q_1 + p_2 q_2 + \dots + p_n q_n}{\sqrt{p_1^2 + p_2^2 + \dots + p_n^2} \sqrt{q_1^2 + q_2^2 + \dots + q_n^2}}$$

(2) 코사인 유사도의 값이 1에 가까울수록 두 텍스트가 유사하다고 판단한다.

자카드 유사도

(1) 두 텍스트 P와 Q의 단어집합이 P 와 Q 일 때, P와 Q의 자카드 유사도 $J(P, Q)$ 는

$$J(P, Q) = \frac{n(P \cap Q)}{n(P \cup Q)}$$

(2) 자카드 유사도의 값이 1에 가까울수록 두 텍스트가 유사하다고 판단한다.

유사도 분석: 유사도를 이용하여 텍스트 데이터 사이의 관계를 파악하여 분석하는 것

II 대단원 평가 문제

하 중 상

01

다음 보기의 텍스트 데이터 중에서 정형 데이터인 것을 모두 고르시오.

보기

이름, 성별, 댓글, 혈액형, 감상 평

02

벡터 $\vec{X} = (1, 3, 0, 4, 2, 5)$ 에 대하여 둘째 성분을 a , 다섯째 성분을 b 라 할 때, $a+b$ 의 값은?

- ① 1 ② 3 ③ 5
④ 7 ⑤ 9

03

다음은 세 후기 A, B, C의 단어집합 A , B , C 와 단어 사전 U 를 구한 것이다. 단어 사전 U 의 각 단어가 세 단어집합 A , B , C 에 각각 속하면 1, 속하지 않으면 0으로 나타낸 벡터 $\vec{A}$, $\vec{B}$, $\vec{C}$ 를 구하시오.

$A = \{\text{가격, 대비, 성능, 좋다, 구매}\},$

$B = \{\text{통화, 기능, 불편}\},$

$C = \{\text{제품, 음질, 좋다}\},$

$U = \{\text{가격, 대비, 성능, 좋다, 구매, 통화, 기능, 불편, 제품, 음질}\}$

04

단어 사전 U 가

$U = \{\text{인공지능, 새롭다, 상상, 현실, 시대, 태도}\}$

일 때, 다음 두 문장 A와 B의 빈도수 벡터 $\vec{A}$ 와 $\vec{B}$ 를 구하시오.

문장 A: 인공지능, 새로운 상상! 상상이 현실로!

문장 B: 인공지능 시대에서 우리의 태도

05

다음은 세 도서 A, B, C의 단어 사전 U 와 빈도수 벡터 $\vec{A}$, $\vec{B}$, $\vec{C}$ 를 나타낸 것이다.

$U = \{\text{소크라테스, 수학, 운동주, 소년, 하늘, 세포, 힘, 사상, 그리스}\},$

$\vec{A} = (5, 3, 0, 0, 1, 0, 0, 6, 4),$

$\vec{B} = (0, 4, 0, 0, 0, 8, 1, 0, 0),$

$\vec{C} = (0, 0, 7, 4, 3, 0, 1, 0, 0)$

세 도서 A, B, C가 보기의 도서 분류 중에서 어느 것에 해당하는지 고르시오.

보기

철학, 언어, 자연 과학,
요리, 문학, 기술 과학

06

단어 사전 $U = \{\text{나, 좋아하다, 싫어하다, 고양이, 강아지}\}$ 에 대하여 문장 A의 빈도수 벡터 $\vec{A}$ 가

$$\vec{A} = (1, 1, 0, 1, 0)$$

일 때, 다음에 답하시오.

- (1) 벡터 $\vec{A}$ 를 이용하여 문장을 두 가지 이상 추측하시오.
- (2) (1)에서와 같이 여러 가지 문장으로 추측할 수 있는 이유를 설명하시오.

07

아래는 세 요리 방법 A, B, C의 단어 사전 U 와 빈도수 벡터 $\vec{A}, \vec{B}, \vec{C}$ 를 구한 것이다. 다음에 답하시오.

$$U = \{\text{김치, 두부, 찌개, 고기, 호박, 된장, 볶음, 파}\},$$

$$\vec{A} = (5, 1, 5, 4, 0, 0, 0, 0),$$

$$\vec{B} = (0, 0, 4, 0, 2, 4, 0, 0),$$

$$\vec{C} = (4, 0, 0, 2, 0, 0, 4, 1)$$

- (1) 세 요리 방법 A, B, C의 주제를 각각 구하시오.
- (2) 세 요리 방법 A, B, C가 각각 어느 요리를 나타내는지 추측하시오.
- (3) 세 요리 방법 A, B, C를 모은 말뭉치의 주제를 서술하시오.

08

다음은 경제와 관련된 네 문서 A, B, C, D의 단어 사전 U 와 단어빈도 TF를 구하여 나타낸 것이다. TF-IDF를 이용하여 각 문서에서 중요도가 가장 높은 단어를 쓰시오.

$$U = \{\text{금리, 환율, 주식, 채권, 물가}\}$$

		금리	환율	주식	채권	물가
TF	A	3	0	1	2	2
	B	2	1	2	1	3
	C	1	2	0	2	1
	D	0	1	1	3	2

09

다음은 어느 스마트 TV의 구매 후기 중에서 4개를 모은 말뭉치와 감성 사전이다. 네 구매 후기 A, B, C, D를 각각 감성 벡터로 나타내고, 감성 분석을 하시오.

후기 A: 합리적인 가격의 TV예요.

후기 B: 배송과 설치 부분이 다소 불만이에요.

후기 C: 믿고 구매해도 좋은 제품입니다.

후기 D: 구매 추천! 망설이면 후회할 제품!

감성 사전	
긍정 단어	부정 단어
합리적, 민다, 좋다, 추천	불만, 망설이다, 후회

10

세 벡터

$$\vec{P} = (3, a, b), \vec{Q} = (1, -b, 2a), \vec{R} = (2, 2b, -3b)$$

에 대하여 $\vec{P} + \vec{Q} + \vec{R} = (c, -3, 2)$ 일 때, $a + 2b + 3c$ 의 값을 구하시오.

11

다음 표는 세 문서 A, B, C에 나오는 주요 단어의 빈도수를 나타낸 것이다. 유클리드 유사도를 이용하여 가장 유사한 문서 두 개를 고르시오.

	한식	중식	일식	양식
A	3	2	1	3
B	2	3	3	2
C	1	1	2	3

12

세 텍스트 P, Q, R의 단어집합 P, Q, R 이 다음과 같을 때, 자카드 유사도를 이용하여 가장 유사한 텍스트 두 개를 고르시오.

$$P = \{\text{쥐, 호랑이, 용}\},$$

$$Q = \{\text{소, 호랑이, 용}\},$$

$$R = \{\text{쥐, 소, 호랑이, 뱀}\}$$

13

다음 표는 단어 사전

$$U = \{\text{주의, 건조, 기록, 역대, 캠프}\}$$

에 대하여 날씨와 스포츠 분야의 신문 기사에 나오는 주요 단어의 빈도수를 나타낸 것이다.

	주의	건조	기록	역대	캠프
날씨	3	2	1	1	0
스포츠	1	0	2	2	1

동일한 단어 사전 U 에 대하여 새로운 신문 기사 A에 나오는 단어의 빈도수가 아래 표와 같을 때, 유클리드 유사도, 코사인 유사도, 자카드 유사도를 이용하여 신문 기사 A를 날씨 또는 스포츠 기사로 분류하시오.

	주의	건조	기록	역대	캠프
A	2	0	0	1	1



자기 평가

정답을 맞힌 문항에 ○표 하여 학습 성취도를 표시하고, 부족한 부분은 교과서의 해당 쪽을 확인하여 복습해 보자.

문항 번호	성취기준	성취도	복습
01 02 03	집합과 벡터를 이용하여 텍스트 데이터를 목적에 맞게 표현할 수 있다.	😊 😐 😞	50 ~ 54쪽
04 05 06 07 08	빈도수 벡터를 이용하여 텍스트 데이터를 요약하고 유용한 정보를 추출할 수 있다.	😊 😐 😞	55 ~ 61쪽
09 10 11 12 13	인공지능이 텍스트를 특성에 따라 분석하는 수학적 방법을 설명할 수 있다.	😊 😐 😞	63 ~ 73쪽

만족 보통 부족



감성 인식 기술 전문가, 로봇이 사람의 감정을 읽게 하다



**감성 인식 기술 전문가는
무슨 일을 하나요?**

감성 인식 기술은 제품과 서비스에 인간의 감성을 자동 인지하고 사용 상황에 맞게 감성 정보를 처리하여 사용자 감성 맞춤 서비스를 제공하는 기술입니다.

인간의 여러 감성을 컴퓨터가 인지할 수 있는 유무선 센서 기술과 감성 신호의 피드백에 따라 각각의 상황에 맞는 적절한 처리 능력을 부여하는 기술로 개발합니다.


또, 기존 정보 기술(IT) 제품 및 몸에 착용하는 웨어러블 기기에 사용자의 감성을 인지하고 상호 간 소통이 가능한 기술을 적용시키기도 합니다.



**감성 인식 기술 전문가가 되려면
어떤 지식이 필요한가요?**

감성 인식은 컴퓨터 공학, 의공학, 전자 공학, 수학, 인지 심리학, 디자인 등이 연계된 융합 분야입니다.

시각, 청각, 촉각 센서를 이용한 감성 인식과 감성 처리를 통해 인간과 인간, 인간과 제품이 효율적인 상호 작용을 하게 하는 기술이라는 점에서 고도의 전문 지식이 필요합니다.



**감성 인식 기술 전문가의
전망은 어때요?**

감성 인식 기술은 미래에 인간 중심 사회를 이끌 제품, 직업, 산업으로 발전할 가능성이 높습니다. 특히, 서비스의 지속적인 경쟁력 확보와 신규 수요 창출이 가능하고 의료와 교육 등 국가 산업 경쟁력을 강화시키는 데 큰 몫을 할 것으로 전망됩니다. 감성 인식 분야의 시장 확대에 따라 감성 인식 기술 전문가의 역할이 더 중요해지고 인력 수요도 증가할 것입니다.

(출처: 커리어넷, 2024)

