

II 텍스트 데이터 처리

준비 학습 1

삼각비 \ A	0°	30°	45°	60°	90°
cos A	1	$\frac{\sqrt{3}}{2}$	$\frac{\sqrt{2}}{2}$	$\frac{1}{2}$	0

위의 표에서 $\angle A$ 의 크기가 커질수록 $\cos A$ 의 값은 작아진다.

- ② (1) $AB = \sqrt{(5-2)^2 + (-3-1)^2} = 5$
 (2) $OA = \sqrt{(-4)^2 + 6^2} = 2\sqrt{13}$
 ③ (1) $A \cup B = \{1, 2, 3, 5, 7, 9\}$
 (2) $A \cup B = \{\text{곰, 호랑이, 고래, 수달, 상어, 가오리}\}$

1 텍스트 데이터 표현

50~54쪽

생각 열기 선호하는 메뉴: 정형 데이터
 의견: 비정형 데이터

문제 1 정형 데이터: 이름, 거주 지역
 비정형 데이터: 댓글, 설명서, 신문 기사, 문자 메시지

문제 2 (1) 0 (2) 3

문제 3

	혈액형	벡터 표현
지수	A	(1, 0, 0, 0)
영우	O	(0, 0, 1, 0)
채원	AB	(0, 0, 0, 1)
재영	B	(0, 1, 0, 0)
세미	AB	(0, 0, 0, 1)

문제 4 **예시** 후기 A 이 영화는 스토리가 탄탄합니다. 추천!

날말 분리	이	영화는		스토리가		탄탄합니다	추천
기본 사전형 단어	이	영화	는	스토리	가	탄탄하다	추천

위의 기본 사전형 단어에서 불용어를 표시하면 다음과 같다.

기본 사전형 단어	이	영화	는	스토리	가	탄탄하다	추천
-----------	---	----	---	-----	---	------	----

따라서 단어집합 A는

$$A = \{\text{영화, 스토리, 탄탄하다, 추천}\}$$

후기 B 영화 내내 긴장하며 봤네요. 역시 영화는 액션과 CG!

날말 분리	영화	내내	긴장하며	봤네요	역시	영화는		액션과		CG
기본 사전형 단어	영화	내내	긴장하다	보다	역시	영화	는	액션	과	CG

위의 기본 사전형 단어에서 불용어를 표시하면 다음과 같다.

기본 사전형 단어	영화	내내	긴장하다	보다	역시	영화	는	액션	과	CG
-----------	----	----	------	----	----	----	---	----	---	----

따라서 단어집합 B는

$$B = \{\text{영화, 긴장하다, 보다, 액션, CG}\}$$

후기 C 배우의 연기가 훌륭해요. 탄탄한 스토리와 액션 최고!

날말 분리	배우의		연기가		훌륭해요	탄탄한	스토리와		액션	최고
기본 사전형 단어	배우	의	연기	가	훌륭하다	탄탄하다	스토리	와	액션	최고

위의 기본 사전형 단어에서 불용어를 표시하면 다음과 같다.

기본 사전형 단어	배우	의	연기	가	훌륭하다	탄탄하다	스토리	와	액션	최고
-----------	----	---	----	---	------	------	-----	---	----	----

따라서 단어집합 C는

$$C = \{\text{배우, 연기, 훌륭하다, 탄탄하다, 스토리, 액션, 최고}\}$$

위의 세 단어집합 A, B, C로부터 구성된 단어 사전 U는

$$U = \{\text{영화, 스토리, 탄탄하다, 추천, 긴장하다, 보다, 액션, CG, 배우, 연기, 훌륭하다, 최고}\}$$

문제 5 **예시** 단어 사전 U에 있는 단어를 순서대로 나열하고, 단어 사전 U의 각 단어가 세 단어집합 A, B, C에 각각 속하면 1, 속하지 않으면 0으로 나타내면 다음과 같다.

	영화	스토리	탄탄하다	추천	긴장	보다
A	1	1	1	1	0	0
B	1	0	0	0	1	1
C	0	1	1	0	0	0
	액션	CG	배우	연기	훌륭하다	최고
A	0	0	0	0	0	0
B	1	1	0	0	0	0
C	1	0	1	1	1	1

앞의 표에서 세 단어집합 A, B, C 에 대응하는 수를
순서대로 나열하여 벡터로 표현하면

$$\begin{aligned}\vec{A} &= (1, 1, 1, 1, 0, 0, 0, 0, 0, 0, 0), \\ \vec{B} &= (1, 0, 0, 0, 1, 1, 1, 1, 0, 0, 0), \\ \vec{C} &= (0, 1, 1, 0, 0, 0, 1, 0, 1, 1, 1)\end{aligned}$$

확인하기 (1) ○ (2) × (3) ○

2 텍스트 데이터 처리

55~62쪽

생각 열기 ① 두 표어 A 와 B 의 단어집합을 각각 A 와 B 라 하자.

단어 사전 U 에 있는 단어를 순서대로 나열하고, 단어 사전 U 의 각 단어가 두 단어집합 A 와 B 에 속하면 1, 속하지 않으면 0으로 나타내면 다음과 같다.

	수학	혁신	발전	인공지능	꽃	산물
A	1	1	1	1	0	0
B	1	0	0	1	1	1

이 표에서 두 단어집합 A 와 B 에 대응하는 수를 순서대로 나열하여 벡터로 표현하면

$$\begin{aligned}\vec{A} &= (1, 1, 1, 1, 0, 0), \\ \vec{B} &= (1, 0, 0, 1, 1, 1)\end{aligned}$$

②

	수학	혁신	발전	인공지능	꽃	산물
A	2	1	1	1	0	0
B	2	0	0	2	1	1

함께 하기 ①

	추천	위생적	인테리어	예쁘다	음식점	가격	저렴	맛	좋다
A	2	1	1	1	1	0	0	0	0
B	1	0	0	0	1	1	1	2	1
C	1	0	1	1	1	1	2	0	0
D	1	0	0	0	1	0	0	2	0
말뭉치	5	1	2	2	4	2	3	4	1

② ①의 표에서 네 후기 A, B, C, D 와 말뭉치의 빈도수 벡터는

$$\begin{aligned}\vec{A} &= (2, 1, 1, 1, 1, 0, 0, 0, 0), \\ \vec{B} &= (1, 0, 0, 0, 1, 1, 1, 2, 1), \\ \vec{C} &= (1, 0, 1, 1, 1, 1, 2, 0, 0), \\ \vec{D} &= (1, 0, 0, 0, 1, 0, 0, 2, 0), \\ \vec{U} &= (5, 1, 2, 2, 4, 2, 3, 4, 1)\end{aligned}$$

문제 1 예시 단어집합은

{까치, 울다, 산울림, 듣다, 혼자}


빈도수 벡터는

$$(2, 1, 4, 3, 1)$$

따라서 빈도수 벡터에서 빈도수가 가장 높은 단어인 ‘산울림’이 이 시의 주제어임을 알 수 있다.

문제 2 (1) 세 빈도수 벡터 $\vec{A}, \vec{B}, \vec{C}$ 에서 빈도수가 가장 높은 단어인 ‘승부차기’, ‘도루’, ‘자유투’가 각 기사의 주제어임을 알 수 있다.

(2) 세 기사 A, B, C 의 주제어가 각각 ‘승부차기’, ‘도루’, ‘자유투’이므로 세 기사 A, B, C 가 나타내는 스포츠는 각각 ‘축구’, ‘야구’, ‘농구’임을 알 수 있다. 따라서 세 기사 A, B, C 가 나타내는 스포츠를 선으로 연결하면 다음과 같다.



(3) 말뭉치의 빈도수 벡터 $\vec{U}$ 는

$$\vec{U} = (5, 4, 6, 6, 4, 3, 4, 3)$$

따라서 말뭉치의 주제어는 빈도수가 가장 높은 단어인 ‘공’과 ‘심판’임을 알 수 있다.

문제 3 각 단어의 문서빈도(DF)와 역문서빈도(IDF)를 구하면 다음과 같다.

	농도	외출	환기	자제	낮다	높다
DF	3	1	3	1	1	2
IDF	1	3	1	3	3	$\frac{3}{2}$

이 표를 이용하여 TF-IDF를 구하면 다음과 같다.

	농도	외출	환기	자제	낮다	높다
TF-IDF	A	1	6	1	6	$\frac{3}{2}$
	B	1	0	2	0	6
	C	1	0	1	0	6

따라서 각 문서에서 중요도가 가장 높은 단어는

A: 외출, 자제, B: 낮다, C: 높다

확인하기 (1) × (2) ○ (3) ×

탐구 & 융합 예시



워드 클라우드에서 빈도수가 높은 단어인 ‘자율주행’과 ‘자동차’가 이 글의 주제어임을 알 수 있다.

3 텍스트 데이터 분석

63~75쪽

- 생각 열기** ① 소비자 A의 별점과 후기는 긍정 표현이고, 소비자 C의 별점과 후기는 부정 표현이다.
 ② 소비자 B의 별점은 부정에 가깝고 후기는 긍정과 부정이 섞여 있어서 별점과 후기가 같은 의미인지 판단할 수 없다.

문제 1 예시

	단어집합	감성 벡터	감성 점수	감성 분석
D	{외형, 못난이, 사과, 겁질, 먹다, 맛있다, 당도, 보장}	(2, 1, 5)	1	긍정
E	{신선하다, 보이다, 처음, 맛없다, 실망, 며칠, 지나다, 맛있다}	(2, 2, 4)	0	중립

- 문제 2** (1) $\vec{P} + \vec{Q} = (2+0, 1+1, 4+(-2), 0+3) = (2, 2, 2, 3)$
 (2) $\vec{P} + \vec{Q} + \vec{R} = (2+0+3, 1+1+(-5), 4+(-2)+1, 0+3+2) = (5, -3, 3, 5)$

- 문제 3 예시** 5명의 소비자 A, B, C, D, E의 후기를 나타내는 감성 벡터는

$$\vec{A} = (3, 0, 2), \vec{B} = (2, 2, 2), \vec{C} = (1, 4, 1), \\ \vec{D} = (2, 1, 5), \vec{E} = (2, 2, 4)$$

이므로

$$\vec{A} + \vec{B} + \vec{C} + \vec{D} + \vec{E} = (10, 9, 14)$$

따라서 5명의 소비자 A, B, C, D, E의 전체 후기의 감성 점수는 $10 - 9 = 1$ 이므로, 5명의 소비자 A, B, C, D, E의 전체 후기는 ‘긍정’으로 분석한다.

- 생각 열기 예시** 다음과 같이 딸기를 좋아하는 그룹과 싫어하는 그룹으로 나눌 수 있다.
 딸기를 좋아하는 그룹: T_1, T_2
 딸기를 싫어하는 그룹: T_3

문제 4 $D(P, Q) = \sqrt{(3-1)^2 + (0-2)^2 + (1-4)^2} = \sqrt{17}$

- 문제 5** P와 Q, Q와 R, R과 P의 유클리드 유사도를 구하면

$$D(P, Q) = \sqrt{(1-0)^2 + (2-2)^2 + (1-1)^2 + (0-1)^2} = \sqrt{2}, \\ D(Q, R) = \sqrt{(1-1)^2 + (0-2)^2 + (1-1)^2 + (2-0)^2} = \sqrt{8} = 2\sqrt{2}, \\ D(R, P) = \sqrt{(0-1)^2 + (2-0)^2 + (1-1)^2 + (1-2)^2} = \sqrt{6}$$

따라서 유클리드 유사도의 값이 가장 작은 P와 Q가 가장 유사하다.

문제 6 $C(P, Q) = \frac{1 \times 2 + 2 \times 3 + 3 \times 1}{\sqrt{1^2 + 2^2 + 3^2} \sqrt{2^2 + 3^2 + 1^2}} = \frac{11}{\sqrt{14} \sqrt{14}} = \frac{11}{14}$

- 문제 7** P와 Q, Q와 R, R과 P의 코사인 유사도를 구하면

$$C(P, Q) = \frac{1 \times 0 + 2 \times 1 + 0 \times 0 + 1 \times 1}{\sqrt{1^2 + 2^2 + 0^2 + 1^2} \sqrt{0^2 + 1^2 + 0^2 + 1^2}} = \frac{3}{\sqrt{6} \sqrt{2}} = \frac{\sqrt{3}}{2}, \\ C(Q, R) = \frac{0 \times 1 + 1 \times 0 + 0 \times 1 + 1 \times 1}{\sqrt{0^2 + 1^2 + 0^2 + 1^2} \sqrt{1^2 + 0^2 + 1^2 + 1^2}} = \frac{1}{\sqrt{2} \sqrt{3}} = \frac{\sqrt{6}}{6}, \\ C(R, P) = \frac{1 \times 1 + 0 \times 2 + 1 \times 0 + 1 \times 1}{\sqrt{1^2 + 0^2 + 1^2 + 1^2} \sqrt{1^2 + 2^2 + 0^2 + 1^2}} = \frac{2}{\sqrt{3} \sqrt{6}} = \frac{\sqrt{2}}{3}$$

따라서 코사인 유사도의 값이 가장 큰 P와 Q가 가장 유사하다.

- 함께하기** ① $A \cap B = \{\text{액션, 스릴러}\},$
 $B \cap C = \{\text{액션, 스릴러, 드라마, SF}\},$
 $C \cap A = \{\text{액션, 코미디, 스릴러}\}$
 ② $A \cup B = \{\text{액션, 코미디, 스릴러, 전쟁, 판타지, 뮤지컬, 드라마, SF}\},$
 $B \cup C = \{\text{액션, 스릴러, 뮤지컬, 드라마, SF, 코미디}\},$
 $C \cup A = \{\text{액션, 코미디, 스릴러, 드라마, SF, 전쟁, 판타지}\}$
 ③ $\frac{n(A \cap B)}{n(A \cup B)} = \frac{2}{8} = \frac{1}{4}, \frac{n(B \cap C)}{n(B \cup C)} = \frac{4}{6} = \frac{2}{3},$
 $\frac{n(C \cap A)}{n(C \cup A)} = \frac{3}{7}$

- ④ 두 집합의 합집합의 원소의 개수를 기준으로 할 때, 두 집합에 공통으로 포함되는 원소가 가장 많은 B와 C가 가장 유사하다고 추측할 수 있다.

문제 8 $A \cap B = \{\text{눈, 예보}\}$,
 $B \cap C = \{\text{눈, 예보}\}$,
 $C \cap A = \{\text{한파, 눈, 예보, 일부, 비}\}$,
 $A \cup B = \{\text{한파, 눈, 예보, 일부, 비, 퇴근길, 조심}\}$,
 $B \cup C = \{\text{눈, 예보, 퇴근길, 조심, 비, 일부, 그치다, 한파}\}$,

$C \cup A = \{\text{비, 예보, 일부, 눈, 그치다, 한파}\}$
 이므로 A와 B, B와 C, C와 A의 자카드 유사도를 구하면

$$J(A, B) = \frac{n(A \cap B)}{n(A \cup B)} = \frac{2}{7},$$

$$J(B, C) = \frac{n(B \cap C)}{n(B \cup C)} = \frac{2}{8} = \frac{1}{4},$$

$$J(C, A) = \frac{n(C \cap A)}{n(C \cup A)} = \frac{5}{6}$$

따라서 자카드 유사도의 값이 가장 큰 C와 A가 가장 유사하다.

문제 9 (i) 세 문서 A, B, C의 빈도수 벡터를 구하면

$$\vec{A} = (2, 0, 1, 2), \quad \vec{B} = (0, 4, 0, 3),$$

$$\vec{C} = (2, 3, 2, 0)$$

C와 A, C와 B의 유클리드 유사도를 구하면

$$D(C, A)$$

$$= \sqrt{(2-2)^2 + (0-3)^2 + (1-2)^2 + (2-0)^2}$$

$$= \sqrt{14},$$

$$D(C, B)$$

$$= \sqrt{(0-2)^2 + (4-3)^2 + (0-2)^2 + (3-0)^2}$$

$$= \sqrt{18} = 3\sqrt{2}$$

따라서 $D(C, B) > D(C, A)$ 이므로 문서 C는 문서 A와 더 유사하다.

(ii) C와 A, C와 B의 코사인 유사도를 구하면

$$C(C, A)$$

$$= \frac{2 \times 2 + 3 \times 0 + 2 \times 1 + 0 \times 2}{\sqrt{2^2 + 3^2 + 2^2 + 0^2} \sqrt{2^2 + 0^2 + 1^2 + 2^2}}$$

$$= \frac{6}{3\sqrt{17}} = \frac{2\sqrt{17}}{17},$$

$$C(C, B)$$

$$= \frac{2 \times 0 + 3 \times 4 + 2 \times 0 + 0 \times 3}{\sqrt{2^2 + 3^2 + 2^2 + 0^2} \sqrt{0^2 + 4^2 + 0^2 + 3^2}}$$

$$= \frac{12}{5\sqrt{17}} = \frac{12\sqrt{17}}{85}$$

따라서 $C(C, B) > C(C, A)$ 이므로 문서 C는 문서 B와 더 유사하다.

(iii) 세 문서 A, B, C의 단어집합은

$$A = \{\text{발라드, 록, 팝}\},$$

$$B = \{\text{힙합, 팝}\},$$

$$C = \{\text{발라드, 힙합, 록}\}$$

이므로

$$C \cap A = \{\text{발라드, 록}\},$$

$$C \cap B = \{\text{힙합}\},$$

$$C \cup A = \{\text{발라드, 힙합, 록, 팝}\},$$

$$C \cup B = \{\text{힙합, 팝, 발라드, 록}\}$$

C와 A, C와 B의 자카드 유사도를 구하면

$$J(C, A) = \frac{n(C \cap A)}{n(C \cup A)} = \frac{2}{4} = \frac{1}{2},$$

$$J(C, B) = \frac{n(C \cap B)}{n(C \cup B)} = \frac{1}{4}$$

따라서 $J(C, B) < J(C, A)$ 이므로 문서 C는 문서 A와 더 유사하다.

확인하기 (1) $\times$ (2) $\times$

공학 도구 **예시** 아래 글에 있는 문장의 코사인 유사도, 자카드 유사도, 유클리드 유사도를 구하면 다음과 같다.

환경 제책은 전 세계적으로 수많은 동물들 멸종 위기에 몰아넣고 있다. 우리나라 환경부는 1급과 2급으로 멸종 위기 야생 동식물을 지정했다. 지정된 동식물은 불법 포획, 채취 등의 행위가 엄격히 금지된다. 또, 3년 주기로 실시되는 '전국 분포 조사'의 대상이 되는 등 정부의 관리로 받는다. 이를 통해 멸종 위기에 놓인 야생 동식물들을 보호하고자 노력하고 있다. 멸종 위기 야생 동식물 1급에는 개체가 현저히 감소하여 멸종 위기에 있는 야생 동식물들이 포함된다. 현재 50종의 동식물이 멸종 위기 야생 동식물 1급으로 지정되어 보호받고 있다. 대표적으로 반달가슴곰과 수달이 멸종 위기 야생 동식물 1급으로 지정되어 있다. 멸종 위기 야생 동식물 2급은 아직 멸종 위기에 있지는 않지만 개체 수가 현저히 감소하고 있는 경우이다. 즉, 가까운 장래에 멸종 위기에 처할 수 있는 야생 동식물들이 포함된다. 대표적으로 풀개와 하늬대망리가 멸종 위기 야생 동식물 2급으로 지정되어 있다.

(출처: 한국환경공단 블로그, 2019)

코사인 유사도										공식 보기
No	문장 3	문장 4	문장 1	문장 2	문장 10	문장 9	문장 7	문장 8	문장 5	문장 6
문장 1	0	0	1	0.47	0.63	0.78	0.45	0.58	0.63	0.63
문장 2	0.47	0	0.47	1	0.6	0.74	0.84	0.95	0.6	0.75
문장 3	1	0	0	0.47	0.32	0.2	0.67	0.58	0.32	0.32
문장 4	0	0	0	0	0	0	0	0	0	0
문장 5	0.32	0	0.63	0.6	0.8	0.74	0.85	0.73	1	0.8
문장 6	0.32	0	0.63	0.75	0.9	0.93	0.78	0.82	0.8	1
문장 7	0.67	0	0.45	0.84	0.71	0.7	1	0.9	0.85	0.78
문장 8	0.58	0	0.58	0.95	0.73	0.79	0.9	1	0.73	0.82
문장 9	0.2	0	0.78	0.74	0.74	1	0.7	0.79	0.74	0.93
문장 10	0.32	0	0.63	0.6	1	0.74	0.71	0.73	0.8	0.9

자카드 유사도										공식 보기
No	문장 3	문장 4	문장 1	문장 2	문장 10	문장 9	문장 7	문장 8	문장 5	문장 6
문장 1	0	0	1	0.33	0.4	0.29	0.29	0.33	0.4	0.25
문장 2	0.33	0	0.33	1	0.57	0.62	0.86	1	0.57	0.56
문장 3	1	0	0	0.33	0.17	0.12	0.29	0.33	0.17	0.11
문장 4	0	0	0	0	0	0	0	0	0	0
문장 5	0.17	0	0.4	0.57	0.67	0.5	0.71	0.57	1	0.44
문장 6	0.11	0	0.25	0.56	0.62	0.88	0.5	0.56	0.44	1
문장 7	0.29	0	0.29	0.86	0.5	0.56	1	0.86	0.71	0.5
문장 8	0.33	0	0.33	1	0.57	0.62	0.86	1	0.57	0.56
문장 9	0.12	0	0.29	0.62	0.5	1	0.56	0.62	0.5	0.88
문장 10	0.17	0	0.4	0.57	1	0.5	0.5	0.57	0.67	0.62

유클리드 유사도										공식 보기
No	문장 3	문장 4	문장 1	문장 2	문장 10	문장 9	문장 7	문장 8	문장 5	문장 6
문장 1	2	1.41	0	2.65	1.73	2.65	2.83	2	1.73	3.74
문장 2	2.65	3	2.65	0	2.45	2.45	1.73	1	2.45	3
문장 3	0	1.41	2	2.65	2.24	3.61	2.45	2	2.24	4.24
문장 4	1.41	0	1.41	3	2.24	3.61	3.16	2.45	2.24	4.47
문장 5	2.24	2.24	1.73	2.45	1.41	2.45	1.73	1.73	0	3
문장 6	4.24	4.47	3.74	3	2.65	1.73	2.83	2.83	3	0
문장 7	2.45	3.16	2.83	1.73	2.24	2.65	0	1.41	1.73	2.83
문장 8	2	2.45	2	1	1.73	2.24	1.41	0	1.73	2.83
문장 9	3.61	3.61	2.65	2.45	2.45	0	2.65	2.24	2.45	1.73
문장 10	2.24	2.24	1.73	2.45	0	2.45	2.24	1.73	1.41	2.65


위의 세 가지 유사도를 이용하여 각 문장이 어느 문장과 가장 유사한지 확인할 수 있다.

- ① (1) $x_1=3$ 이고 $x_2=2$ 일 때, $x=4.5-2=2.5$
 $x_1=5$ 이고 $x_2=6$ 일 때, $x=7.5-6=1.5$
 이므로 표를 완성하면 다음과 같다.

x_1	x_2	x	$\sigma(x)$	실제 메일
3	2	2.5	스팸	스팸
5	6	1.5	스팸	정상

따라서 이 퍼셉트론은 2개의 메일을 정확히 분류하지 못한다.

- (2) **예시** 6개의 입력값에 대한 순서쌍 (x_1, x_2) 를 좌표평면 위에 나타내면 오른쪽 그림과 같다. 따라서 직선이 원점과 점 $(5, 5)$ 를 지나도록 하면 6개의 점을 정상과 스팸으로 구분할 수 있다. 이때 직선의 방정식은



$$x_2 = \frac{5-0}{5-0}x_1, \text{ 즉 } x_1 - x_2 = 0$$


이므로 $w_1=1, w_2=-1$

- ② (1) **예시** $x_1=1$ 이고 $x_2=2$ 일 때, $x=1-2=-1$
 $x_1=7$ 이고 $x_2=6$ 일 때, $x=7-6=1$
 이므로 표를 완성하면 다음과 같다.


x_1	x_2	x	$\sigma(x)$	실제 메일
1	2	-1	정상	스팸
7	6	1	스팸	정상

따라서 이 퍼셉트론은 2개의 메일을 정확히 분류하지 못한다.

- (2) 8개의 입력값에 대한 순서쌍 (x_1, x_2) 를 좌표평면 위에 나타내면 오른쪽 그림과 같다. 이 점들을 정상과 스팸으로 구분하는 원점을 지나는 직선을 찾을 수 없으므로 가중치 w_1 과 w_2 를 정할 수 없다.



- (3) **예시** 오른쪽 그림과 같이 직선이 두 점 $(1, 3)$ 과 $(7, 5)$ 를 지나도록 하면 8개의 점을 정상과 스팸으로 구분할 수 있다. 이때 직선의 방정식은



$$x_2 - 3 = \frac{5-3}{7-1}(x_1 - 1)$$

즉, $x_1 - 3x_2 = -8$

이므로 $w_1=1, w_2=-3, c=-8$

II 대단원 평가문제

79~81쪽

- 01 이름, 성별, 혈액형 02 ③ 03 풀이 참조
 04 $\vec{A}=(1, 1, 2, 1, 0, 0), \vec{B}=(1, 0, 0, 0, 1, 1)$
 05 A: 철학, B: 자연 과학, C: 문학 06 풀이 참조
 07 풀이 참조
 08 A: 금리, B: 물가, C: 환율, D: 채권
 09 풀이 참조 10 13 11 C와 A
 12 P와 Q 13 풀이 참조

- 02 벡터 $\vec{X}=(1, 3, 0, 4, 2, 5)$ 의 둘째 성분은 3, 다섯째 성분은 2이다.

따라서 $a=3, b=2$ 이므로 $a+b=5$

- 03 단어 사전 U 에 있는 단어를 순서대로 나열하고, 단어 사전 U 의 각 단어가 세 단어집합 A, B, C 에 각각 속하면 1, 속하지 않으면 0으로 나타내면 다음과 같다.

	가격	대비	성능	좋다	구매
A	1	1	1	1	1
B	0	0	0	0	0
C	0	0	0	1	0
	통화	기능	불편	제품	음질
A	0	0	0	0	0
B	1	1	1	0	0
C	0	0	0	1	1

이 표에서 세 단어집합 A, B, C 에 대응하는 수를 순서대로 나열하여 벡터로 표현하면

$$\vec{A}=(1, 1, 1, 1, 1, 0, 0, 0, 0, 0),$$

$$\vec{B}=(0, 0, 0, 0, 0, 1, 1, 1, 0, 0),$$

$$\vec{C}=(0, 0, 0, 1, 0, 0, 0, 0, 1, 1)$$

- 04 두 문장 A와 B에서 각 단어의 빈도수를 표로 나타내면 다음과 같다.

	인공지능	새롭다	상상	현실	시대	태도
A	1	1	2	1	0	0
B	1	0	0	0	1	1

이 표에서 두 문장 A와 B의 빈도수 벡터 $\vec{A}$ 와 $\vec{B}$ 는

$$\vec{A}=(1, 1, 2, 1, 0, 0),$$

$$\vec{B}=(1, 0, 0, 0, 1, 1)$$

- 05 세 빈도수 벡터 $\vec{A}, \vec{B}, \vec{C}$ 에서 빈도수가 가장 높은 단어인 '사상', '세포', '운동주'가 각 도서의 주제어임을 알 수 있다.

따라서 A: 철학, B: 자연 과학, C: 문학

- 06 (1) 예시 ‘나는 고양이를 좋아한다.’, ‘고양이는 나를 좋아한다.’
 (2) 예시 단어 사전은 집합으로 표현되므로 단어의 순서를 알 수 없기 때문이다.

- 07 (1) 빈도수가 가장 높은 단어가 주제어이므로 세 요리 방법 A, B, C의 주제어는 각각 다음과 같다.

A: 김치, 찌개,

B: 찌개, 된장,

C: 김치, 볶음

- (2) 예시 A: 김치찌개, B: 된장찌개, C: 김치볶음으로 추측할 수 있다.

- (3) 말뚱치의 빈도수 벡터 $\vec{U}$ 는

$$\vec{U} = (9, 1, 9, 6, 2, 4, 4, 1)$$

이므로 빈도수가 가장 높은 단어인 ‘김치’와 ‘찌개’가 이 말뚱치의 주제어임을 알 수 있다.

- 08 각 단어의 문서빈도(DF)와 역문서빈도(IDF)를 구하면 다음과 같다.

	금리	환율	주식	채권	물가
DF	3	3	3	4	4
IDF	$\frac{4}{3}$	$\frac{4}{3}$	$\frac{4}{3}$	1	1

이 표를 이용하여 TF-IDF를 구하면 다음과 같다.

		금리	환율	주식	채권	물가
TF-IDF	A	4	0	$\frac{4}{3}$	2	2
	B	$\frac{8}{3}$	$\frac{4}{3}$	$\frac{8}{3}$	1	3
	C	$\frac{4}{3}$	$\frac{8}{3}$	0	2	1
	D	0	$\frac{4}{3}$	$\frac{4}{3}$	3	2

따라서 각 문서에서 중요도가 가장 높은 단어는

A: 금리, B: 물가, C: 환율, D: 채권

- 09 각 구매 후기를 감성 벡터로 나타내고 감성 점수를 이용하여 감성 분석을 하면 다음과 같다.

	단어집합	감성 벡터	감성 점수	감성 분석
A	{합리적, 가격, TV}	(1, 0, 2)	1	긍정
B	{배송, 설치, 부분, 다소, 불만}	(0, 1, 4)	-1	부정
C	{민다, 구매, 좋다, 제품}	(2, 0, 2)	2	긍정
D	{구매, 추천, 망설이다, 후회, 제품}	(1, 2, 2)	-1	부정

$$\begin{aligned} & \vec{P} + \vec{Q} + \vec{R} \\ &= (3+1+2, a+(-b)+2b, b+2a+(-3b)) \\ &= (6, a+b, 2a-2b) \end{aligned}$$

즉, $(6, a+b, 2a-2b) = (c, -3, 2)$ 에서

$$c=6,$$

$$a+b=-3,$$

..... ①

$$2a-2b=2$$

..... ②

①과 ②를 연립하여 풀면

$$a=-1, b=-2$$

따라서 $a+2b+3c=13$

- 11 세 문서 A, B, C의 빈도수 벡터를 구하면

$$\vec{A} = (3, 2, 1, 3),$$

$$\vec{B} = (2, 3, 3, 2),$$

$$\vec{C} = (1, 1, 2, 3)$$

A와 B, B와 C, C와 A의 유클리드 유사도를 구하면

$$D(A, B)$$

$$= \sqrt{(2-3)^2 + (3-2)^2 + (3-1)^2 + (2-3)^2}$$

$$= \sqrt{7},$$

$$D(B, C)$$

$$= \sqrt{(1-2)^2 + (1-3)^2 + (2-3)^2 + (3-2)^2}$$

$$= \sqrt{7},$$

$$D(C, A)$$

$$= \sqrt{(3-1)^2 + (2-1)^2 + (1-2)^2 + (3-3)^2}$$

$$= \sqrt{6}$$

따라서 유클리드 유사도의 값이 가장 작은 두 문서 C와 A가 가장 유사하다.

- 12 $P \cap Q = \{\text{호랑이, 용}\},$

$$Q \cap R = \{\text{소, 호랑이}\},$$

$$R \cap P = \{\text{쥐, 호랑이}\},$$

$$P \cup Q = \{\text{쥐, 호랑이, 용, 소}\},$$

$$Q \cup R = \{\text{소, 호랑이, 용, 쥐, 뱀}\},$$

$$R \cup P = \{\text{쥐, 소, 호랑이, 뱀, 용}\}$$

이므로 P와 Q, Q와 R, R과 P의 자카드 유사도를 구하면

$$J(P, Q) = \frac{n(P \cap Q)}{n(P \cup Q)} = \frac{2}{4} = \frac{1}{2},$$

$$J(Q, R) = \frac{n(Q \cap R)}{n(Q \cup R)} = \frac{2}{5},$$

$$J(R, P) = \frac{n(R \cap P)}{n(R \cup P)} = \frac{2}{5}$$

따라서 자카드 유사도의 값이 가장 큰 P와 Q가 가장 유사하다.

- 13 날씨와 스포츠 분야의 신문 기사를 P와 Q라 하고, 두 신문 기사의 빈도수 벡터를 구하면

$$\vec{P} = (3, 2, 1, 1, 0),$$

$$\vec{Q} = (1, 0, 2, 2, 1)$$

또, 신문 기사 A의 빈도수 벡터를 구하면

$$\vec{A} = (2, 0, 0, 1, 1)$$

- (i) A와 P, A와 Q의 유클리드 유사도를 구하면

$$D(A, P)$$

$$= \sqrt{(3-2)^2 + (2-0)^2 + (1-0)^2 + (1-1)^2 + (0-1)^2}$$

$$= \sqrt{7},$$

$$D(A, Q)$$

$$= \sqrt{(1-2)^2 + (0-0)^2 + (2-0)^2 + (2-1)^2 + (1-1)^2}$$

$$= \sqrt{6}$$

따라서 $D(A, P) > D(A, Q)$ 이므로 신문 기사 A는 스포츠 기사로 분류한다.

- (ii) A와 P, A와 Q의 코사인 유사도를 구하면

$$C(A, P)$$

$$= \frac{2 \times 3 + 0 \times 2 + 0 \times 1 + 1 \times 1 + 1 \times 0}{\sqrt{2^2 + 0^2 + 0^2 + 1^2 + 1^2} \sqrt{3^2 + 2^2 + 1^2 + 1^2 + 0^2}}$$

$$= \frac{7\sqrt{10}}{30},$$

$$C(A, Q)$$

$$= \frac{2 \times 1 + 0 \times 0 + 0 \times 2 + 1 \times 2 + 1 \times 1}{\sqrt{2^2 + 0^2 + 0^2 + 1^2 + 1^2} \sqrt{1^2 + 0^2 + 2^2 + 2^2 + 1^2}}$$

$$= \frac{\sqrt{15}}{6}$$

따라서 $C(A, P) > C(A, Q)$ 이므로 신문 기사 A는 날씨 기사로 분류한다.

- (iii) 두 신문 기사 P와 Q의 단어집합은

$$P = \{\text{주의, 건조, 기록, 역대}\},$$

$$Q = \{\text{주의, 기록, 역대, 캠프}\}$$

또, 신문 기사 A의 단어집합은

$$A = \{\text{주의, 역대, 캠프}\}$$

이때

$$A \cap P = \{\text{주의, 역대}\},$$

$$A \cap Q = \{\text{주의, 역대, 캠프}\},$$

$$A \cup P = \{\text{주의, 건조, 기록, 역대, 캠프}\},$$

$$A \cup Q = \{\text{주의, 기록, 역대, 캠프}\}$$

이므로 A와 P, A와 Q의 자카드 유사도를 구하면

$$J(A, P) = \frac{n(A \cap P)}{n(A \cup P)} = \frac{2}{5},$$

$$J(A, Q) = \frac{n(A \cap Q)}{n(A \cup Q)} = \frac{3}{4}$$

따라서 $J(A, P) < J(A, Q)$ 이므로 신문 기사 A는 스포츠 기사로 분류한다.

III 이미지 데이터 처리

준비 학습 ① $a = -1, b = -4$

$$\textcircled{2} (1) A + B = \begin{pmatrix} -1 & 3 \\ 2 & -2 \end{pmatrix} + \begin{pmatrix} 1 & 4 \\ 2 & -1 \end{pmatrix}$$

$$= \begin{pmatrix} 0 & 7 \\ 4 & -3 \end{pmatrix}$$

$$(2) 2A = 2 \begin{pmatrix} -1 & 3 \\ 2 & -2 \end{pmatrix} = \begin{pmatrix} -2 & 6 \\ 4 & -4 \end{pmatrix}$$

$$(3) AB = \begin{pmatrix} -1 & 3 \\ 2 & -2 \end{pmatrix} \begin{pmatrix} 1 & 4 \\ 2 & -1 \end{pmatrix}$$

$$= \begin{pmatrix} 5 & -7 \\ -2 & 10 \end{pmatrix}$$


③

x_1	x_2	$\sigma(x)$
1	1	1
1	0	1
0	1	0
0	0	0


1 이미지 데이터 표현

86~91쪽

생각 열기



문제 1



문제 2

(1) 변환된 세 행렬이 3×2 행렬이므로 이 컬러 이미지의 해상도는 2×3 이다.

(2) 세 행렬 R, G, B 의 $(2, 1)$ 성분은 차례대로 0, 32, 128

이므로 이 성분에 대응하는 픽셀의 색상 정보는 (0, 32, 128)

또, 세 행렬 R, G, B 의 $(3, 2)$ 성분은 차례대로 128, 0, 192

이므로 이 성분에 대응하는 픽셀의 색상 정보는 (128, 0, 192)

(3) 색상 정보가 (0, 32, 128)인 픽셀의 색은 남색이고, 색상 정보가 (128, 0, 192)인 픽셀의 색은 보라이다.