

3

손실함수

학습
목표

손실함수를 이해하고 최적화된 추세선을 찾을 수 있다.


손실함수



생각
열기

다음은 어느 농작물 수확량 x kg에 대한 매출액 y 만 원을 조사한 데이터와 그 산점도 및 추세선을 나타낸 것이다.

수확량(kg)	매출액(만 원)
64	78
67	56
83	82
88	99
98	84



◆ 원점을 지나는 추세선 $f(x)=ax$ 를 이용하여 수확량에 대한 매출액을 예측하려고 한다. 위의 네 추세선 A, B, C, D의 식이

$$A: f_A(x)=1.5x, \quad B: f_B(x)=1.1x,$$

$$C: f_C(x)=0.9x, \quad D: f_D(x)=0.7x$$

일 때, 예측에 가장 적합한 것은 무엇인지 생각해 보자.

위의 **생각 열기**의 그래프에서 추세선 A는 추세선 B보다 매출액을 더 크게 예측하며 오차의 크기도 더 크다. 따라서 추세선 B가 추세선 A보다 예측에 더 적합하다고 할 수 있다. 마찬가지로 추세선 C가 추세선 D보다 예측에 더 적합하다고 할 수 있다.

그러나 두 추세선 B와 C 중에서 어느 것이 더 정확하게 예측하는지 산점도와 추세선만 보고 판단하는 것은 쉽지 않다.

이제 추세선 중에서 어느 것이 예측에 더 적합한지 비교하는 방법에 대하여 알아 보자.

132쪽의 **생각 열기**의 데이터에서 두 추세선 B 와 C 를 이용하여 매출액의 예측값, 오차, 오차의 크기를 구하면 다음과 같다.

$$\text{추세선 } B: f_B(x) = 1.1x$$

수확량(kg)	매출액(만 원)	예측값(만 원)	오차(만 원)	오차의 크기
64	78	70.4	7.6	7.6
67	56	73.7	-17.7	17.7
83	82	91.3	-9.3	9.3
88	99	96.8	2.2	2.2
98	84	107.8	-23.8	23.8

$$\text{추세선 } C: f_C(x) = 0.9x$$

수확량(kg)	매출액(만 원)	예측값(만 원)	오차(만 원)	오차의 크기
64	78	57.6	20.4	20.4
67	56	60.3	-4.3	4.3
83	82	74.7	7.3	7.3
88	99	79.2	19.8	19.8
98	84	88.2	-4.2	4.2

위의 표에서 오차의 크기가 수확량이 64 kg, 88 kg일 때는 추세선 B 에서 더 작지만, 67 kg, 83 kg, 98 kg일 때는 추세선 C 에서 더 작다.

따라서 단순히 추세선의 오차의 크기를 비교하는 것으로는 추세선 B 와 C 중에서 어느 것이 예측에 더 적합한지 판단하기 어렵다.

예측에 적합한 추세선을 찾는 방법은 다양하지만 오차의 제곱의 평균을 구하여 비교하는 방법이 가장 많이 사용되며, 이 값이 더 작은 추세선이 예측에 더 적합하다고 판단한다.

(i) 추세선 B 로 예측하는 경우, 오차의 제곱의 평균은

$$\frac{7.6^2 + (-17.7)^2 + (-9.3)^2 + 2.2^2 + (-23.8)^2}{5} = 205.764$$

(ii) 추세선 C 로 예측하는 경우, 오차의 제곱의 평균은

$$\frac{20.4^2 + (-4.3)^2 + 7.3^2 + 19.8^2 + (-4.2)^2}{5} = 179.524$$

따라서 추세선 C 로 예측할 때 오차의 제곱의 평균이 더 작으므로, 추세선 C 가 예측에 더 적합하다고 판단한다.

문제 1 132쪽의 **생각 열기**의 두 추세선 A 와 D 의 오차의 제곱의 평균을 구하고, 추세선 C 의 오차의 제곱의 평균과 비교하시오.

일반적으로 추세선을 이용하여 예측할 때, 오차의 제곱의 평균을 이 추세선에 대한 **손실함수**(loss function)라고 한다.

변량 x 의 값 $x_1, x_2, \dots, x_n$ 에 대응하는 변량 y 의 값이 각각 $y_1, y_2, \dots, y_n$ 일 때, 원점을 지나는 추세선 $f(x)=ax$ 에 대한 손실함수를 기호 $L(a)$ 로 나타내고

$$L(a) = \frac{(y_1 - ax_1)^2 + (y_2 - ax_2)^2 + \dots + (y_n - ax_n)^2}{n}$$

과 같이 정한다.

따라서 원점을 지나는 추세선 $f(x)=ax$ 에 대한 손실함수 $L(a)$ 는 추세선의 기울기 a 에 대한 이차함수이며, $L(a)$ 의 값이 더 작을수록 추세선 $f(x)=ax$ 가 데이터의 예측에 더 적합하다.

예제 1 오른쪽 표는 어느 미생물의 배양 시간 x 분에 대한 미생물 수 y 마리를 조사한 데이터이다. 다음에 답하시오.

배양 시간 (분)	미생물 수 (마리)
1	1
2	3
3	5

(1) 추세선 $f(x)=ax$ 에 대한 손실함수 $L(a)$ 를 구하시오.

(2) 두 추세선 $f(x)=x$ 와 $f(x)=2x$ 중에서 어느 것이 예측에 더 적합한지 설명하시오.

풀이 (1) 추세선 $f(x)=ax$ 를 이용하여 예측값 ax 와 오차 $y-ax$ 를 구하면 다음과 같다.

배양 시간 (분)	미생물 수 (마리)	예측값(마리)	오차(마리)
1	1	a	$1-a$
2	3	$2a$	$3-2a$
3	5	$3a$	$5-3a$

이 표를 이용하여 추세선 $f(x)=ax$ 에 대한 손실함수 $L(a)$ 를 구하면

$$\begin{aligned} L(a) &= \frac{(1-a)^2 + (3-2a)^2 + (5-3a)^2}{3} \\ &= \frac{14a^2 - 44a + 35}{3} \end{aligned}$$

(2) $L(1)=1.6\dots$, $L(2)=1$ 이므로 $L(2) < L(1)$

따라서 추세선 $f(x)=2x$ 가 예측에 더 적합하다.

답 (1) $L(a) = \frac{14a^2 - 44a + 35}{3}$ (2) $f(x)=2x$

문제 2 아래 표는 어느 장난감 기차가 레일 위를 움직인 시간 x 초에 대한 이동 거리 y m를 조사한 데이터에서 추세선 $f(x)=ax$ 를 이용하여 이동 거리의 예측값과 오차를 나타낸 것이다. 다음에 답하시오.

시간(초)	이동 거리(m)	예측값(m)	오차(m)
2	1		
	2	$5a$	
			$4-9a$

- (1) 표를 완성하시오.
- (2) 추세선 $f(x)=ax$ 에 대한 손실함수 $L(a)$ 를 구하시오.
- (3) 두 추세선 $f(x)=x$ 와 $f(x)=2x$ 중에서 어느 것이 예측에 더 적합한지 설명하시오.

최적 추세선

앞에서는 손실함수를 구하여 어떤 추세선이 예측에 더 적합한지 비교하는 방법을 살펴보았다.

이제 손실함수의 값이 최소가 되도록 하는 원점을 지나는 추세선을 찾는 방법을 알아보자.




함께하기 오른쪽 표는 어느 기계에 넣은 연료 x L에 대한 작동 시간 y 시간을 조사한 데이터이다.

연료(L)	작동 시간(시간)
4	6
8	5
12	15
16	12
20	20

❶ 추세선 $f(x)=ax$ 에 대한 손실함수 $L(a)$ 를 구해 보자.

❷ ❶에서 구한 $L(a)$ 를 $p(a-q)^2+r$ 의 꼴로 나타내어 예측에 가장 적합한 a 의 값을 구해 보자. (단, p, q, r 은 상수)




위의 **함께하기**에서 손실함수 $L(a)$ 는

$$L(a)=176(a-0.95)^2+7.16$$

이고, 이것은 a 에 대한 이차함수이므로 $a=0.95$ 일 때 최솟값을 갖는다.

이와 같이 손실함수의 값을 최소로 하는 추세선의 기울기를 찾는 과정을 **최적화**(optimization)라 하고, 손실함수의 값이 최소가 되도록 하는 추세선을 **최적 추세선**이라고 한다.

예를 들어 135쪽의 **함께하기**에서 최적 추세선의 식은 $f(x)=0.95x$ 이다.



문제 3 추세선 $f(x)=ax$ 에 대한 손실함수가 $L(a)=2a^2-12a+20$ 일 때, 다음에 답하십시오.

- (1) 최적 추세선의 식을 구하십시오.
- (2) $x=4$ 일 때 (1)에서 구한 최적 추세선의 예측값을 구하십시오.

탐구 문제 4 추세선 $f(x)=ax$ 에 대한 손실함수가 $L(a)=3a^2-12pa+q$ 이다. 최적 추세선의 식이 $f(x)=2x$ 일 때, 다음에 답하십시오. (단, p 와 q 는 상수)

- (1) p 의 값을 구하십시오.
- (2) q 의 값의 범위를 구하십시오.

**확인
하기**

◆ 다음 설명이 옳으면 ○표, 옳지 않으면 ×표를 해 보자.

- (1) 추세선의 오차의 크기를 비교하면 예측에 더 적합한 추세선을 항상 찾을 수 있다. ()
- (2) 손실함수 $L(a)$ 의 값이 더 큰 추세선 $f(x)=ax$ 가 데이터의 예측에 더 적합하다. ()
- (3) 추세선 $f(x)=ax$ 에 대한 손실함수가 $L(a)=3a^2-6a+10$ 일 때, 최적 추세선의 식은 $f(x)=x$ 이다. ()

인공지능 이야기

엉뚱한 점 하나가 바꾼 최적 추세선의 운명



오른쪽 그림은 두 변량 x 와 y 의 값 20개를 조사하여 얻은 데이터의 산점도이다.

이 산점도에서 19개의 파란색 점은 비슷한 경향성을 보이지만, 빨간색 점은 파란색 점이 나타내는 경향성을 많이 벗어난 것으로 보인다.

이와 같이 대부분의 데이터가 나타내는 경향성에서 벗어난 점을 ‘이상점(outlier)’이라고 한다.

이상점이 있는 데이터를 그대로 사용하여 앞에서 배운 손실함수를 이용하면 최적 추세선이 이상점을 제외한 데이터의 경향성을 정확하게 나타낼 수 없다. 따라서 이상점을 제거하거나 다른 손실함수를 사용해야 한다.

추세선 $f(x)=ax$ 를 이용하여 변량 x 의 값 $x_1, x_2, \dots, x_n$ 에 대응하는 변량 y 의 값 $y_1, y_2, \dots, y_n$ 을 예측할 때, 다음과 같이 오차 $e_1=y_1-ax_1, e_2=y_2-ax_2, \dots, e_n=y_n-ax_n$ 의 제곱의 평균을 이용하여 손실함수를 구하는 방법에 대해 살펴 보았다.




$$L(a) = \frac{e_1^2 + e_2^2 + \dots + e_n^2}{n}$$

이 손실함수를 이용하면 이상점의 오차의 제곱이 너무 커지므로, 위의 그림과 같이 최적 추세선이 이상점이 있는 방향으로 치우치는 현상이 나타난다.

이러한 치우침 현상을 방지하기 위하여 다음과 같이 오차의 제곱 대신 오차의 절댓값의 평균을 이용하며, 이를 ‘절대 손실함수(absolute loss function)’라고 한다.

$$M(a) = \frac{|e_1| + |e_2| + \dots + |e_n|}{n}$$

절대 손실함수를 이용하면 위의 그림과 같이 최적 추세선이 이상점이 있는 방향으로 치우치는 현상이 완화된다. 즉, 이상점을 제거하지 않아도 이상점의 영향력을 줄여 주는 효과를 얻을 수 있다.





공학 도구로 손실함수의 값의 변화 관찰하기

다음은 어느 합금의 전기 저항을 알아보기 위한 실험에서 전압 x V에 대한 전류 y mA를 측정된 데이터이다.

전압(V)	1.05	2.11	2.96	3.97	5.23	6.02	7.24	8.17
전류(mA)	5.22	7.65	12.42	18.91	21.65	29.44	32.86	41.01

◆ Desmos는 그래핑 계산기, 공학용 계산기, 기하학 도구 등 수학 관련 도구를 제공한다.
(<https://www.desmos.com>)


Desmos 프로그램을 이용하여 이 데이터의 산점도를 그리고 추세선 $f(x)=ax$ 의 오차와 손실함수의 값의 변화를 관찰해 보자.



① Desmos에 접속하여 ‘그래핑 계산기 열기’를 클릭한다.

② 좌측 상단의 **+**를 클릭한 후 ‘표’를 선택한다.


표의 x_1 열과 y_1 열에 각각 전압의 변량과 전류의 변량을 입력하면 기하 창에 산점도가 나타난다.



③ 입력 창 2행에 ‘ $y=ax$ ’를 입력하면 a 에 대한 슬라이더가 나타난다. 이때 a 의 값의 범위를 $4.0 \leq a \leq 5.8$ 로 설정하고, 간격을 0.1로 설정한다.

또, 입력 창 4행에 ‘ $y_1 \sim ax_1$ ’을 입력하면 기하 창에 추세선 $f(x)=ax$ 가 나타난다.


$a = 4$
 $4.0 \leq a \leq 5.8$ 간격: 0.1



④ 입력 창 1행의 표의 1행 3열에 ' ax_1 '을 입력하면 추세선 $f(x) = ax$ 에 대한 예측 값이 ax_1 열에 나타난다.

입력 창 4행의 [구성]을 클릭하면 오차의 값이 입력 창 1행의 표의 e_1 열에 나타난다.



x_1	y_1	ax_1	e_1
1.05	5.22	4.2	1.02
2.11	7.65	8.44	-0.79
2.96	12.42	11.84	0.58
3.97	18.91	15.88	3.03
5.23	21.65	20.92	0.73
6.02	29.44	24.08	5.36
7.24	32.86	28.96	3.9
8.17	41.01	32.68	8.33



◆ 'mean()'은 평균을 계산하는 명령어이다.

⑤ 입력 창 5행에 ' $\text{mean}((e_1)^2)$ '을 입력하면 손실함수의 값이 나타난다.

입력 창 3행의 [▶]을 클릭하고, a 의 값에 따른 손실함수의 값의 변화를 관찰해 보면 $a = 4.7$ 일 때 손실함수의 값이 3.199400125로 최소가 됨을 확인할 수 있다.



확인

다음은 운동 시간 x 분에 대한 칼로리 소모량 y kcal를 조사한 데이터이다. 위와 같은 방법으로 손실함수의 값의 변화를 관찰해 보자.

운동 시간(분)	10	15	20	25	30	35	40	45	50	55	60
칼로리 소모량(kcal)	82	124	158	215	241	292	315	358	409	438	481