

자료의 표현

인공지능이 내용을 판별하고 의사 결정을 하기 위해서는 인공지능이 이해할 수 있는 자료로 표현해야 한다.

수와 수학 기호는 자료를 효과적으로 표현할 수 있기 때문에, 인공지능이 다루는 자료는 수학을 이용하여 표현된다.



성취 기준

12인수02-01

수와 수학 기호를 이용하여 실생활의 텍스트 자료를 목적에 알맞게 표현할 수 있다.

12인수02-02


수와 수학 기호로 표현된 텍스트 자료를 처리하는 수학 원리를 이해하고 자료를 시각화할 수 있다.

12인수02-03

수와 수학 기호를 이용하여 실생활의 이미지 자료를 목적에 알맞게 표현할 수 있다.

12인수02-04


수와 수학 기호로 표현된 이미지 자료를 처리하는 수학 원리를 이해한다.



1. 텍스트 자료의 표현

2. 이미지 자료의 표현

이 단원에서는 수와 수학 기호를 이용하여 실생활의 텍스트 자료와 이미지 자료를 목적에 알맞게 표현하고 이를 처리하는 수학 원리를 이해하며, 자료를 시각화할 수 있다.




01 텍스트 자료의 표현



2 이미지 자료의 표현

01 이미지 자료의 표현



| 중학교 정보_자료와 정보 |

1 이미지나 화면을 구성하는 작은 정사각형을 의미하는 것은?

- ① 선 ② 비트 ✓ ③ 픽셀
④ 해상도 ⑤ 주파수

| 중학교 정보_자료와 정보 |

2 비트맵 방식에 대한 설명으로 적절하지 않은 것은?

- ① 파일 형식에는 bmp, jpg, gif 등이 있다.
- ② 이미지의 크기를 확대할 경우 변형이 심하다.
- ③ 픽셀 하나하나에 색상을 표현하는 방식이다.
- ④ 컴퓨터를 이용하여 이미지 자료를 작성하는 방법 중의 하나이다.
- ✓ ⑤ 픽셀에 색상 표현 정보가 있으므로 이미지를 완성한 후 수정이 쉽다.

| 고등학교 수학 집합 |

3 전체집합 $U = \{1, 2, 3, \dots, 10\}$ 의 두 부분집합

$$A = \{2, 3, 5, 7\},$$

$$B = \{x \mid x \text{는 } 10\text{의 약수}\}$$

에 대하여 다음을 구하시오.

(1) $A \cup B = \{1, 2, 3, 5, 7, 10\}$

(2) $A \cap B = \{2, 5\}$


- 자료는 정형, 비정형, 범주형, 연속형 등이 있음을 알고, 실생활의 텍스트 자료로 댓글이나 감상평 등을 다룰 수 있도록 한다.
- 실생활의 텍스트 자료를 수와 수학 기호를 이용하여 다양한 방식으로 표현해 보고, 각 표현 방식의 장단점을 이해하게 한다.
- 텍스트 자료는 벡터로 표현할 수 있음을 간략하게 소개할 수 있다.

01

텍스트 자료의 표현

개념 PPT

학습목표 ● 수와 수학 기호를 이용하여 실생활의 텍스트 자료를 목적에 알맞게 표현할 수 있다.



교수 · 학습 활동 - 텍스트 자료

자료의 의미를 알고, 자료의 유형을 구분하여 알게 한다.

1 자료란 무엇인가?

키와 성적 또는 각종 설문을 통해서 얻는 값이나 의견처럼, 관찰이나 측정 등을 통해 얻게 되는 가공되지 않은 정보를 **자료(data)**라고 한다.

자료에는 단어나 문장과 같은 텍스트 자료, 그림이나 사진과 같은 이미지 자료, 영화나 동영상과 같은 영상 자료, 음성이나 노래와 같은 소리 자료 등이 있다.


※ 자료는 키나 몸무게처럼 그 값으로 연산이 가능하고 연속적인 수로 나타낼 수 있는 '연속형 자료'와, 성별이나 혈액형처럼 그 값으로는 연산이 어렵고 범주에 대한 정보만 주는 '범주형 자료'로 구분할 수도 있다.

또, 자료는 정형 자료와 비정형 자료로 구분할 수 있다. 일정한 형식을 갖춘 문서나 회계 자료 등은 정형 자료이고, 일정한 형식을 갖추지 않은 문서, 오디오, 사진, 동영상 등은 비정형 자료이다.

한편, 텍스트 자료는 이름, 성별, 혈액형처럼 그 자체로 이미 분류가 되는 정형 텍스트 자료와 감상평, 댓글, 설명서처럼 그 자체로는 분류가 되지 않는 비정형 텍스트 자료로 나눌 수 있다.

평가 방법 및 유의사항

자료의 표현에 대한 평가는 실제 자료를 목적에 맞게 수와 수학 기호로 표현하고 처리할 수 있는지를 어렵지 않은 수준에서 간단히 다룬다.



정형 텍스트 자료

비정형 텍스트 자료

텍스트 자료를 집합 또는 벡터로 표현하게 한다.

② 텍스트 자료를 수와 수학 기호를 이용하여 어떻게 표현하는가?

컴퓨터는 단어나 문장과 같은 텍스트를 글자 형태로 인식하지 못하기 때문에 이를 수 또는 수학 기호를 이용하여 표현해야 한다.

성별이나 혈액형과 같은 정형 텍스트 자료는 다음과 같이 특정한 범주를 수로 바꾸어 나타내면 컴퓨터가 인식할 수 있다.

남자	여자	A	B	O	AB
3	4	0	1	2	3

♣ 성별 구분 ♣ 혈액형 구분

그런데 댓글이나 감상평과 같은 비정형 텍스트 자료는 수학 기호로 바꾸어 나타내야 컴퓨터가 인식할 수 있다.

이제 비정형 텍스트 자료를 집합 기호를 이용하여 표현하는 방법을 알아보자.

다음은 어느 영화의 댓글 중에서 세 개를 모은 말뭉치이다.

※ 선호도를 알아보기 위해 한 영화의 댓글을 모아 둔 자료처럼, 특정한 목적을 가지고 수집한 텍스트 자료를 '말뭉치' 또는 '코퍼스(corpus)'라고 한다.



이 말뭉치에서 댓글 A를 다음과 같이 띄어쓰기를 기준으로 각 낱말을 분리하고, 각각의 낱말을 기본 사전형 단어로 바꾸어 나타낸다. 이때 문장 부호는 보통 제외한다.

댓글 A	이 영화는 긴장감과 감동이 있는 영화예요.									
낱말 분리	이	영화는	긴장감과	감동이	있는	영화예요				
기본 사전형 단어	이	영화	는	긴장감	과	감동	이	있다	영화	이다

※ 불용어(不用語)

인터넷 검색 시 검색 용어로 사용하지 않는 단어. 관형사, 조사, 접미사, 특수 문자 등과 같이 문장에서 의미가 없는 불필요한 요소를 뜻한다.

이제 위의 기본 사전형 단어에서 불용어를 다음과 같이 표시한다.

불용어	이	영화	는	긴장감	과	감동	이	있다	영화	이다
-----	---	----	---	-----	---	----	---	----	----	----

텍스트 자료의 단어를 수로 표현하는 방법을 이하하게 한다.

위의 표에서 불용어를 제거하고 남은 단어를 원소로 하는 집합을 A 로 나타내면

$$A = \{\text{영화, 긴장감, 감동}\}$$

이다. 같은 방법으로 댓글 B와 댓글 C에서 불용어를 제거하고 남은 단어를 원소로 하는 집합 B 와 C 를 구하면 다음과 같다.

$$B = \{\text{영화, 감동, 지루하다, 실망}\},$$

$$C = \{\text{추천, 눈물, 보다, 감동, 영화}\}$$

댓글 B 이 영화는 감동은 있지만 지루해서 실망이에요.

불용어 이 영화 는 감동 은 있다 지만 지루하다 실망 이다

위의 표에서 불용어를 제거하고 남은 단어를 원소로 하는 집합을 B 로 나타내면
 $B = \{\text{영화, 감동, 지루하다, 실망}\}$

주어진 댓글에서 불용어를 제거하고 남은 단어를 집합으로 직접 나타내 보게 한다.

문제 1

위의 두 집합 B 와 C 가 댓글 B와 C에서 불용어를 제거하고 남은 단어를 원소로 하는 집합임을 확인하시오. 풀이 참조

댓글 C 추천! 눈물 없이는 볼 수 없는 감동적인 영화입니다.

불용어 추천 눈물 없다 보다 수 없다 감동 영화 이다

위의 표에서 불용어를 제거하고 남은 단어를 원소로 하는 집합을 C 로 나타내면
 $C = \{\text{추천, 눈물, 보다, 감동, 영화}\}$

이제 위에서 구한 세 집합 A, B, C 의 합집합을 U 라 하면

$$U = \{\text{영화, 긴장감, 감동, 지루하다, 실망, 추천, 눈물, 보다}\}$$

이다. 이 집합 U 를 세 댓글 A, B, C로부터 구성된 단어 사전이라고 한다.

$$\ast U = A \cup B \cup C$$

한편, 불용어는 경우에 따라 사용자가 목적에 맞게 설정할 수 있다. 예를 들어 세 댓글 A, B, C는 ‘영화를 본’ 후의 감상평이므로 영화 감상 분석을 할 때는 ‘영화’와 ‘보다’를 불용어에 포함시킬 수도 있다. 이 경우에 세 집합 A', B', C' 과 이로부터 만든 단어 사전 U' 은

$$A' = \{\text{긴장감, 감동}\},$$

$$B' = \{\text{감동, 지루하다, 실망}\},$$

$$C' = \{\text{추천, 눈물, 감동}\},$$

$$U' = \{\text{긴장감, 감동, 지루하다, 실망, 추천, 눈물}\}$$

예시 세 후기는 돈가스 음식점의 식사 후기이므로 ‘돈가스’를 불용어에 포함시킬 수 있다.

후기 A 수제 돈가스가 맛있고, 양도 많았어요~!

불용어 수제 돈가스 가 맛있다 양 도 많다

위의 표에서 불용어를 제거하고 남은 단어를 원소로 하는 집합을 A 로 나타내면
 $A = \{\text{수제, 맛있다, 양, 많다}\}$

문제 2

후기 B 돈가스에 치즈가 많아요. 치즈 돈가스 추천!

불용어 돈가스 에 치즈 가 많다 치즈 돈가스 추천

위의 표에서 불용어를 제거하고 남은 단어를 원소로 하는 집합을 B 로 나타내면
 $B = \{\text{치즈, 많다, 추천}\}$

후기 C 역시 수제 돈가스! 치즈 돈가스와 카레 돈가스도 맛있어요!

불용어 역시 수제 돈가스 치즈 돈가스와 카레 돈가스 도 맛있다

위의 표에서 불용어를 제거하고 남은 단어를 원소로 하는 집합을 C 로 나타내면
 $C = \{\text{수제, 치즈, 카레, 맛있다}\}$
 위의 세 집합 A, B, C 로부터 단어 사전 U 를 만들면
 $U = \{\text{수제, 맛있다, 양, 많다, 치즈, 추천, 카레}\}$

과 같다.

주어진 댓글에서 불용어를 제거하고 남은 단어를 집합으로 나타내 보게 한다.

다음은 어느 돈가스 음식점의 손님들이 남긴 식사 후기 중에서 세 개를 모은 말뭉치이다. 세 후기 A, B, C에서 불용어를 제거하고 남은 단어를 원소로 하는 세 집합 A, B, C 와 단어 사전 U 를 구하시오. 풀이 참조

후기 A: 수제 돈가스가 맛있고, 양도 많았어요~!

후기 B: 돈가스에 치즈가 많아요. 치즈 돈가스 추천!

후기 C: 역시 수제 돈가스! 치즈 돈가스와 카레 돈가스도 맛있어요!



이제 집합으로 나타낸 텍스트 자료를 벡터로 나타내는 방법을 알아보자.

n 개의 수 $x_1, x_2, \dots, x_n$ 을 괄호 속에 순서대로 나열하여 나타낸

$$\vec{X} = (x_1, x_2, \dots, x_n)$$

을 **벡터**라고 한다. 이때 $x_1, x_2, \dots, x_n$ 을 벡터 $\vec{X}$ 의 성분이라 하고, x_1 을 첫째 성분, x_2 을 둘째 성분, $\dots, x_n$ 을 n 째 성분이라고 한다.

참고 벡터는 보통 알파벳 위에 화살표를 붙여서 $\vec{A}, \vec{P}, \vec{X}$ 등으로 나타낸다.

보기 벡터 $\vec{X} = (2, 1, 0, 3)$ 에서 2는 벡터 $\vec{X}$ 의 첫째 성분이고, 벡터 $\vec{X}$ 의 셋째 성분은 0이다.

벡터에서 각 성분을 찾을 수 있게 한다.

문제 3

벡터 $\vec{X} = (1, 0, 2, 3, 1)$ 에서 다음을 구하시오.

(1) 벡터 $\vec{X}$ 의 둘째 성분 0

(2) 벡터 $\vec{X}$ 의 넷째 성분 3

벡터 $\vec{X} = (1, 0, 2, 3, 1)$ 의 둘째 성분은 0이다.

벡터 $\vec{X} = (1, 0, 2, 3, 1)$ 의 넷째 성분은 3이다.

다음 표는 앞의 단어 사전 U 에 있는 단어를 순서대로 나열하고, 세 집합 A, B, C 의 각 단어가 단어 사전 U 에 속하면 1, 속하지 않으면 0으로 나타낸 것이다.

	영화	긴장감	감동	지루하다	실망	추천	눈물	보다
A	1	1	1	0	0	0	0	0
B	1	0	1	1	1	0	0	0
C	1	0	1	0	0	1	1	1

※ 텍스트 형태의 자연어를 기계가 이해할 수 있도록 숫자를 나열하여 벡터로 나타내는 것을 임베딩(embedding)이라고 한다.

이 표에서 세 집합 A, B, C 에 대응하는 수를 순서대로 나열하면

$$\vec{A} = (1, 1, 1, 0, 0, 0, 0, 0),$$

$$\vec{B} = (1, 0, 1, 1, 1, 0, 0, 0),$$

$$\vec{C} = (1, 0, 1, 0, 0, 1, 1, 1)$$

과 같이 벡터로 나타낼 수 있으며, 이것은 단어 사전 U 의 각 단어가 세 댓글 A, B, C 에 속하는지 속하지 않는지를 보여 준다.

이와 같은 과정을 통하여, 문장으로 된 텍스트 자료를 수로 이루어진 벡터로 나타낼 수 있다.

주의 텍스트 자료를 벡터로 나타낼 때는 단어 사전 U 에 있는 단어의 순서를 따른다.

주어진 단어 사전을 이용하여 세 후기 A, B, C 를 각각 벡터로 나타내게 한다.

문제 4

문제 2에서 구한 세 집합 A, B, C 를 이용하여 만든 단어 사전 U 가 다음과 같을 때, 세 후기 A, B, C 를 벡터 $\vec{A}, \vec{B}, \vec{C}$ 로 나타내시오. 풀이 참조

$U = \{\text{수제, 맛있다, 양, 많다, 치즈, 추천, 카레}\}$

	수제	맛있다	양	많다	치즈	추천	카레
A	1	1	1	1	0	0	0
B	0	0	0	1	1	1	0
C	1	1	0	0	1	0	1

이 표에서 세 집합 A, B, C 에 대응하는 수를 순서대로 나열하여 벡터로 나타낸다

$$\vec{A} = (1, 1, 1, 1, 0, 0, 0),$$

$$\vec{B} = (0, 0, 0, 1, 1, 1, 0),$$

$$\vec{C} = (1, 1, 0, 0, 1, 0, 1)$$

- 텍스트 자료의 단어 빈도를 수치로 나타내어 벡터로 표현해 보게 한다.
- 텍스트 자료를 변환하는 활동을 통해 자료 처리의 원리를 이해하게 하고, 이때 공학적 도구를 이용할 수 있게 한다.


02

텍스트 자료의 처리

개념 PPT

학습목표 ● 수와 수학 기호로 표현된 텍스트 자료를 처리하는 수학 원리를 이해한다.

다가서



교수 · 학습 활동 - 텍스트 자료의 표현

실제 텍스트 자료를 여러 가지 수로 표현해 보게 하고, 단어 빈도수를 이용해 주제어를 찾을 수 있게 한다.

※ ‘달리기’, ‘체력’, ‘근력’과 같은 단어가 자주 출현하면 해당 문서를 체육 관련 문서로 판단할 수 있고, ‘함수’, ‘방정식’, ‘부등식’과 같은 단어가 자주 출현하면 수학 관련 문서로 판단할 수 있다.

1 텍스트 자료에서 주제어를 어떻게 찾는가?

인공지능은 많은 양의 비정형 텍스트 자료에서 주제어나 선호도 등을 찾아내는 데 이용된다.

특히, 텍스트 자료에서 특정한 단어의 출현 빈도는 그 자료의 성격을 판단하는 중요한 기준이 되기 때문에, 주제어 찾거나 선호도 판단에 중요하게 쓰인다. 그런데 앞에서는 텍스트 자료의 문장 또는 문서를 모두 성분이 1 또는 0인 벡터로 나타내었기 때문에 이를 통해서는 그 자료에서 특정한 단어의 출현 빈도를 알 수 없다.

여기서는 몇 개의 비정형 텍스트 자료에서 특정한 단어의 출현 빈도를 이용하여 주제어를 찾는 방법을 알아보자.

다음은 어느 의류 쇼핑몰의 구매 후기 중에서 세 개를 모은 말뭉치이다.



세 후기 A, B, C에서 불용어를 제거하고 남은 단어를 원소로 하는 세 집합 A , B , C 와 단어 사전 U 를 구하면 다음과 같다.

$A = \{\text{청바지, 추천, 예쁘다, 저렴하다}\},$

$B = \{\text{청바지, 가격, 디자인, 좋다, 추천}\},$

$C = \{\text{신축성, 디자인, 좋다, 가격, 청바지, 추천}\},$

$U = \{\text{청바지, 추천, 예쁘다, 저렴하다, 가격, 디자인, 좋다, 신축성}\}$

※ TF는 Term Frequency
의 줄임말이다.

이제 집합으로 나타낸 텍스트 자료에 출현하는 단어 빈도수(TF)를 구하여 표로 나타내어 보자.

다음 표는 위의 단어 사전 U 에 있는 단어를 순서대로 나열하고, 세 후기 A, B, C와 말뭉치에서 각 단어가 출현하는 빈도수를 나타낸 것이다.

예를 들어 ‘청바지’의 빈도수는 세 후기 A, B, C와 말뭉치에서 각각 2, 1, 1, 4이므로 다음 표와 같다.

	청바지	추천	예쁘다	저렴하다	가격	디자인	좋다	신축성
후기 A	2	2	1	1	0	0	0	0
후기 B	1	1	0	0	1	2	1	0
후기 C	1	1	0	0	1	1	2	1
말뭉치	4	4	1	1	2	3	3	1

이 표에서 세 후기 A, B, C와 말뭉치의 단어 빈도수를 단어 사전 U 의 단어 순서대로 나열하여 다음과 같이 벡터로 나타낼 수 있다.

$$\vec{A} = (2, 2, 1, 1, 0, 0, 0, 0),$$

$$\vec{B} = (1, 1, 0, 0, 1, 2, 1, 0),$$

$$\vec{C} = (1, 1, 0, 0, 1, 1, 2, 1),$$

$$\vec{U} = (4, 4, 1, 1, 2, 3, 3, 1)$$


이로부터 세 후기 A, B, C에서 빈도수가 가장 큰 단어인 ‘청바지’와 ‘추천’, ‘디자인’, ‘좋다’가 각 후기의 주제어임을 알 수 있다.

또한, 말뭉치에서 빈도수가 가장 큰 단어가 ‘청바지’와 ‘추천’이므로, 이 말뭉치의 주제어는 ‘청바지’와 ‘추천’임을 알 수 있다.

이처럼 비정형 텍스트 자료에서 단어 빈도수를 구하면 그 자료의 주제어를 찾을 수 있다.

예제 1

아래는 어느 일기 예보 기사 제목 중에서 세 개를 모은 말뭉치와 각 기사 제목에서 불용어를 제거하고 남은 단어를 원소로 하는 집합 A , B , C 와 단어 사전 U 를 구한 것이다. 다음에 답하시오.



$A = \{\text{한파, 눈, 예보, 일부, 비}\},$

$B = \{\text{눈, 예보, 퇴근길, 조심}\},$

$C = \{\text{비, 예보, 일부, 눈, 그치다, 한파}\},$

$U = \{\text{한파, 눈, 예보, 일부, 비, 퇴근길, 조심, 그치다}\}$

(1) 세 기사 제목 A , B , C 와 말뭉치의 단어 빈도수를 벡터로 나타내시오.

(2) (1)을 이용하여 각 기사 제목과 말뭉치의 주제어를 말하시오.

풀이

(1) 세 기사 제목 A , B , C 와 말뭉치의 단어 빈도수를 조사하여 표로 나타내면

	한파	눈	예보	일부	비	퇴근길	조심	그치다
제목 A	1	1	2	1	1	0	0	0
제목 B	0	2	1	0	0	1	1	0
제목 C	1	1	1	1	3	0	0	1
말뭉치	2	4	4	2	4	1	1	1

이 표에서 세 기사 제목 A , B , C 와 말뭉치의 단어 빈도수를 벡터로 나타내면

$\vec{A} = (1, 1, 2, 1, 0, 0, 0), \vec{B} = (0, 2, 1, 0, 0, 1, 1, 0),$

$\vec{C} = (1, 1, 1, 1, 3, 0, 0, 1), \vec{U} = (2, 4, 4, 2, 4, 1, 1, 1)$

(2) 세 기사 제목 A , B , C 에서 빈도수가 가장 큰 단어인 ‘예보’, ‘눈’, ‘비’가 각 기사 제목의 주제어임을 알 수 있다.

또한, 말뭉치에서 빈도수가 가장 큰 단어가 ‘눈’, ‘예보’, ‘비’이므로, 이 말뭉치의 주제어는 ‘눈’, ‘예보’, ‘비’임을 알 수 있다.

답 풀이 참조

단어 빈도수를 보고, 세 기사의 주제어를 찾을 수 있게 한다.

문제 1

아래는 세 스포츠 기사 A , B , C 에 출현하는 단어로부터 단어 사전 U 와 각 단어 빈도수를 벡터로 나타낸 것이다. 다음에 답하시오.

(1) 세 기사 A , B , C 에서 빈도수가 가장 큰 단어인 ‘골키퍼’, ‘스파이크’, ‘홀인원’이 각 기사의 주제어임을 알 수 있다.

$U = \{\text{잔디, 심판, 공, 골키퍼, 스파이크, 코트, 홀인원, 버디}\},$

(2) 세 기사 A , B , C 의 주제어가 ‘골키퍼’, ‘스파이크’, ‘홀인원’이므로 각 기사가 나타내는 스포츠는 ‘축구’, ‘배구’, ‘골프’임을 알 수 있다.

$\vec{A} = (2, 1, 2, 5, 0, 0, 0, 0),$

$\vec{B} = (0, 0, 2, 0, 4, 3, 0, 0),$

(3) 단어 사전 U 의 단어 빈도수를 벡터로 나타내면

$\vec{C} = (1, 1, 2, 0, 0, 0, 4, 3)$

$\vec{U} = (3, 2, 6, 5, 4, 3, 4, 3)$
이므로 말뭉치에서 빈도수가 가장 큰 단어는 ‘공’이다.
즉, 이 말뭉치의 주제어는 ‘공’임을 알 수 있다.

(1) 세 기사 A , B , C 의 주제어를 각각 구하시오. A : 골키퍼, B : 스파이크, C : 홀인원

(2) 세 기사 A , B , C 가 각각 어느 스포츠를 나타내는지 말하시오. A : 축구, B : 배구, C : 골프

(3) 세 기사 A , B , C 를 모은 말뭉치의 주제어를 말하시오. 공



유용한 정보를 찾아내기 위해 단어 빈도수, 역문서 빈도수를 활용하여 TF · IDF를 구하는 방법을 이해하게 한다.

② 텍스트 자료에서 유용한 정보를 어떻게 찾는가?

34쪽에서 청바지 구입 후기에 대한 말뭉치로부터 단어 빈도수를 벡터로 나타내어 ‘청바지’와 ‘추천’과 같은 주제어를 찾았다. 하지만 빈도수 벡터만 사용하면 ‘청바지’와 ‘추천’처럼 빈도수가 높은 주제어는 쉽게 찾을 수 있으나 ‘청바지를 추천하는 이유’와 같은 유용한 정보를 파악하는 것은 어렵다.

이제 문서에서 자주 사용된 단어 빈도수를 조정하여 빈도수가 낮지만 유용한 정보를 갖는 단어를 찾는 방법을 알아보자.

이를 위하여 먼저 33쪽의 말뭉치를 하나의 문서로 생각하고, 세 후기를 이 문서를 구성하는 각각의 문장으로 생각해 보자.

A: 청바지 추천! 예쁘고 저렴해서 청바지를 추천해요.

B: 청바지의 가격, 디자인 다 좋아요. 특히 디자인 추천!^^

C: 신축성과 디자인이 좋고, 가격도 좋아서 이 청바지를 추천해요.

수업 활동 시 유의점

TF · IDF는 보통 로그를 이용해서 구하지만, 로그 개념을 모르는 학생들도 구할 수 있도록 상대도수의 역수를 이용하여 구하는 것으로 구성하였다.

단계 1 각 문장에서 출현하는 단어 빈도수 TF 구하기

다음 표는 34쪽에서 구한 세 문장의 단어 빈도수 TF를 다시 쓴 것이다.

	청바지	추천	예쁘다	저렴하다	가격	디자인	좋다	신축성
TF(A)	2	2	1	1	0	0	0	0
TF(B)	1	1	0	0	1	2	1	0
TF(C)	1	1	0	0	1	1	2	1

※DF는 Document Frequency의 줄임말이다.

단계 2 특정 단어가 출현하는 문서 빈도수 DF와 상대도수 구하기

① 문서 빈도수 DF: 각 단어별로 그 단어가 출현하는 문장의 개수로 정한다.

예를 들어 단계 1의 표에서 ‘청바지’는 세 문장에 모두 출현하므로 ‘청바지’의 DF는 3이고, ‘가격’은 두 문장 B와 C에 출현하므로 ‘가격’의 DF는 2이다.

② 상대도수 $\frac{DF}{n}$ (n 은 전체 문장의 개수): 각 DF를 문서를 구성하는 전체 문장의 개수로 나눈 값으로 정한다.
이 경우에는 $n=3$ 이다.

	청바지	추천	예쁘다	저렴하다	가격	디자인	좋다	신축성
DF	3	3	1	1	2	2	2	1
$\frac{DF}{n}$	1	1	$\frac{1}{3}$	$\frac{1}{3}$	$\frac{2}{3}$	$\frac{2}{3}$	$\frac{2}{3}$	$\frac{1}{3}$

× IDF는 Inverse Document Frequency의 줄임말이다.

× IDF는 많은 문장에 출현하는 단어의 중요도를 낮추는 역할을 한다.

단계 3 역문서 빈도수 IDF 구하기

역문서 빈도수 IDF: 상대도수 $\frac{DF}{n}$ 의 역수, 즉 $IDF = \frac{n}{DF}$ 으로 정한다.

	청바지	추천	예쁘다	저렴하다	가격	디자인	좋다	신축성
IDF	1	1	3	3	$\frac{3}{2}$	$\frac{3}{2}$	$\frac{3}{2}$	3

단계 4 TF·IDF 구하기

× TF·IDF는 단어 빈도수 TF와 역문서 빈도수 IDF를 곱한 것이다.

TF·IDF = TF × IDF로 정한다. 예를 들어 후기 A에서 청바지의 TF는 2이고 청바지의 IDF는 1이므로, TF·IDF(A)에서 청바지의 값은 $2 \times 1 = 2$ 이다.

	청바지	추천	예쁘다	저렴하다	가격	디자인	좋다	신축성
TF·IDF(A)	2	2	3	3	0	0	0	0
TF·IDF(B)	1	1	0	0	$\frac{3}{2}$	3	$\frac{3}{2}$	0
TF·IDF(C)	1	1	0	0	$\frac{3}{2}$	$\frac{3}{2}$	3	3

일반적으로 모든 문장에서 자주 출현하는 단어는 중요도가 낮다고 판단하고, 특정한 문장에서만 자주 출현하는 단어는 중요도가 높다고 판단한다. 즉, TF·IDF가 작으면 중요도가 낮은 것이고, TF·IDF가 크면 중요도가 높은 것이다.

위에서 구한 TF·IDF로부터 세 후기 A, B, C에서 알 수 있는 유용한 정보는 다음과 같다.

A: 예쁘다와 저렴하다

B: 디자인

C: 좋다와 신축성

이로부터 각 후기에서 ‘청바지를 추천’하는 이유는 각각

A: 예쁘고 저렴하기 때문에

B: 디자인 때문에

C: 신축성이 좋기 때문에

와 같이 조금씩 차이를 알 수 있다.

참고 | 인공지능이 다루는 문서에서 전체 문장의 개수 n 은 일반적으로 엄청나게 큰 수이므로 $IDF = \frac{n}{DF}$ 도 매우 커져서 계산이 불편하다. 따라서 IDF를 작은 값으로 만들기 위하여 로그(logarithm)의 개념을 이용하여 $IDF = \log \frac{n}{DF}$ 으로 정한다.

예를 들어 $n = 1000000$ 이고 $DF = 100$ 인 경우에, $\frac{n}{DF} = 10000$ 으로 큰 값이지만 $\log \frac{n}{DF} = 4$ 로 작은 값이 된다.

× 이와 같은 로그의 성질은 『수학 I』에서 학습하게 된다.

예제 2

예제 1의 세 기사 제목을 한 문서로 생각하고, 세 기사 제목을 이 문서를 구성하는 각각의 문장으로 생각하자. 각 문장에서 출현하는 단어 빈도수 TF를 구한 표가 아래와 같을 때, 다음에 답하시오.

	한파	눈	예보	일부	비	퇴근길	조심	그치다
TF(A)	1	1	2	1	1	0	0	0
TF(B)	0	2	1	0	0	1	1	0
TF(C)	1	1	1	1	3	0	0	1

- (1) 위의 표를 이용하여 문서 빈도수 DF와 상대도수 $\frac{DF}{n}$ 를 구하시오.
- (2) (1)을 이용하여 역문서 빈도수 IDF를 구하시오.
- (3) (2)를 이용하여 세 기사 제목의 TF·IDF를 구하시오.
- (4) (3)을 이용하여 각 기사 제목에서 중요도가 가장 높은 단어를 찾으시오.

풀이 (1) $n=3$ 이므로 위의 표를 이용하여 각 단어의 DF와 $\frac{DF}{n}$ 를 구하면

	한파	눈	예보	일부	비	퇴근길	조심	그치다
DF	2	3	3	2	2	1	1	1
$\frac{DF}{n}$	$\frac{2}{3}$	$\frac{1}{1}$	$\frac{1}{1}$	$\frac{2}{3}$	$\frac{2}{3}$	$\frac{1}{3}$	$\frac{1}{3}$	$\frac{1}{3}$

(2) (1)을 이용하여 IDF를 구하면

	한파	눈	예보	일부	비	퇴근길	조심	그치다
IDF	$\frac{3}{2}$	1	1	$\frac{3}{2}$	$\frac{3}{2}$	3	3	3

(3) (2)를 이용하여 TF·IDF를 구하면

	한파	눈	예보	일부	비	퇴근길	조심	그치다
TF·IDF(A)	$\frac{3}{2}$	1	2	$\frac{3}{2}$	$\frac{3}{2}$	0	0	0
TF·IDF(B)	0	2	1	0	0	3	3	0
TF·IDF(C)	$\frac{3}{2}$	1	1	$\frac{3}{2}$	$\frac{9}{2}$	0	0	3

(4) 각 기사 제목에서 중요도가 가장 높은 단어는

A: 예보, B: 퇴근길, 조심, C: 비

답 (1)~(3) 풀이 참조 (4) A: 예보, B: 퇴근길, 조심, C: 비

TF·IDF를 구하여 기사의 중요도를 파악할 수 있게 한다.

문제 2

문제 1의 세 스포츠 기사를 한 문서로 생각하고, 세 기사의 TF·IDF를 구하여 각 기사에서 중요도가 가장 높은 단어를 찾으시오. A: 골프퍼, B: 스파이크, C: 출신원

	잔디	심판	공	골프퍼	스파이크	코트	출신원	버디
TF·IDF(A)	$2 \times \frac{3}{2} = 3$	$1 \times \frac{3}{2} = \frac{3}{2}$	$2 \times 1 = 2$	$5 \times 3 = 15$	$0 \times 3 = 0$	$0 \times 3 = 0$	$0 \times 3 = 0$	$0 \times 3 = 0$
TF·IDF(B)	$0 \times \frac{3}{2} = 0$	$0 \times \frac{3}{2} = 0$	$2 \times 1 = 2$	$0 \times 3 = 0$	$4 \times 3 = 12$	$3 \times 3 = 9$	$0 \times 3 = 0$	$0 \times 3 = 0$
TF·IDF(C)	$1 \times \frac{3}{2} = \frac{3}{2}$	$1 \times \frac{3}{2} = \frac{3}{2}$	$2 \times 1 = 2$	$0 \times 3 = 0$	$0 \times 3 = 0$	$0 \times 3 = 0$	$4 \times 3 = 12$	$3 \times 3 = 9$

03

텍스트 자료의 시각화

개념 PPT

학습목표 • 수와 수학 기호로 표현된 텍스트 자료를 시각화할 수 있다.

다가서



교수 · 학습 활동 - 텍스트 자료의 시각화

자료를 시각화하는 다양한 방법에 대해 알고, 텍스트 자료에 따라 가장 적합한 시각화 방법을 선택할 수 있게 한다.

1 자료를 시각화하는 방법에는 어떤 것들이 있는가?

시각화는 자료의 분석 결과를 쉽게 이해할 수 있도록 시각적으로 표현하여 효과적으로 전달하는 과정이다. 특히, 양이 많고 정돈되지 않은 자료로부터 필요한 정보를 효율적으로 제공하기 위해 시각화를 많이 이용한다.

자료를 시각화할 때는 주로 표나 그래프 등을 이용하는데, 자료의 특성을 파악하여 가장 적합한 시각화 방법을 선택하는 것이 매우 중요하다.

시각화 방법에는 많은 종류가 있으며, 자료의 특성에 맞춰 새로 개발되기도 한다.


다음은 자료의 시각화 방법을 여섯 가지 유형으로 정리한 것이다.

[시각화 방법의 6가지 유형]

시간 시각화

시간에 따른 자료의 변화를 표현한 것으로 막대그래프와 선그래프 등이 있다.


산림 면적과 임목 축적량의 변화



분포 시각화

전체에 대한 각 부분의 분포 특성을 표현한 것으로 원그래프, 도넛그래프, 단어 구름 등이 있다.


우리나라 1차 에너지 생산 현황



관계 시각화

두 변수 사이의 관계를 표현한 것으로 산점도와 버블그래프 등이 있다.


각 시도의 인구 부양비



비교 시각화

여러 변수 사이의 관계를 비교하여 표현한 것으로 레이더그래프와 다차원 척도법 등이 있다.


수도권의 집중도



공간 시각화

점과 선의 색상과 크기를 이용하여 지도 등의 공간에 정보를 표현한 것으로 지도 매핑이 있다.


주요 발전 설비 분포



구조 시각화

자료를 구조화하여 계층적 정보를 한눈에 파악할 수 있도록 표현한 것으로 의사 결정 나무, 표 등이 있다.

약제에 따른 생존 연한



교수 · 학습 활동 - 텍스트 자료의 시각화

텍스트 자료를 시각화하는 다양한 방법에 대해 알고, 텍스트 자료에 따라 효과적으로 표현할 수 있게 한다.

② 텍스트 자료를 어떻게 시각화하여 표현할 수 있는가?

앞에서 비정형 텍스트 자료를 벡터로 나타내어 필요한 정보를 얻는 방법을 배웠다. 이제 시각화를 이용하여 이러한 정보를 보다 효과적으로 전달하는 방법을 알아보자.

다음은 33쪽의 말뭉치에서 단어 사전 U 와 말뭉치의 단어 빈도수를 벡터로 나타낸 것이다.

$$U = \{\text{청바지, 추천, 예쁘다, 저렴하다, 가격, 디자인, 좋다, 신축성}\},$$

$$\vec{U} = (4, 4, 1, 1, 2, 3, 3, 1)$$

단어 빈도수를 표, 막대그래프, 원그래프, 단어 구름 등의 형태로 시각화하여 자료의 특징을 분석해 보자.

× 표는 다양한 그래프로 시각화하는 데 기초 자료로 사용된다.

❗ 표로 시각화하기

표는 자료를 일정한 기준에 따라 직사각형 모양의 칸에 알아보기 쉽게 정리한 것으로서, 수량을 한눈에 알아보기 쉽다.



앞의 자료를 다음과 같이 표로 시각화하여 나타내면 ‘청바지’와 ‘추천’과 같은 중요한 단어나 주제어를 찾을 수 있으며, 이 표에 상대도수를 나타내면 특정 단어가 전체에서 차지하는 비율을 알 수 있어서 중요도를 확인할 수 있다.

	청바지	추천	예쁘다	저렴하다	가격	디자인	좋다	신축성	합
빈도수(TF)	4	4	1	1	2	3	3	1	19
상대도수	0.21	0.21	0.05	0.05	0.11	0.16	0.16	0.05	1.00

❗ 막대그래프로 시각화하기

막대그래프는 범주별 빈도 자료를 빈도에 비례하는 길이의 막대로 나타낸 그래프로써 상대적 크기를 비교하기 편리하다.

위의 표를 오른쪽과 같이 막대그래프로 시각화하여 나타내면 표에 비해 한눈에 알아보기 편하며, ‘청바지’와 ‘추천’이 각각 4회, ‘디자인’과 ‘좋다’가 각각 3회 등 단어 빈도수의 크기 순서를 파악하기도 쉽다.



❗ 원그래프로 시각화하기

원그래프는 전체 자료에 대한 각 부분의 비율을 한 원의 내부에 부채꼴로 나타낸 그래프로써 전체에 대한 부분의 분포 특성을 표현하는 데 편리하다.

위의 표를 왼쪽과 같이 원그래프로 시각화하여 나타내면 각 단어의 횟수는 알 수 없지만 ‘청바지’, ‘추천’, ‘디자인’, ‘좋다’가 전체 단어 빈도수의 74 %를 차지하는 것을 알 수 있다.

❗ 단어 구름으로 시각화하기

단어 구름은 빈도수에 비례하여 단어의 크기를 나타낸 것으로서 빈도수가 큰 단어가 크게 표시되기 때문에 한눈에 문서의 핵심 내용을 파악하는 데 편리하다.

위의 표를 오른쪽 그림과 같이 단어 구름으로 시각화하여 나타내면 ‘청바지’와 ‘추천’의 빈도수가 가장 큰 것을 한눈에 바로 알 수 있다.



단어 구름으로 텍스트 자료를 시각화하고 분석해 보도록 한다.

③ 공학적 도구를 이용하여 단어 구름을 어떻게 만드는가?

이제 앞의 시각화 방법 중에서 단어 구름을 공학적 도구를 이용하여 만드는 방법에 대하여 알아보자.

오른쪽 자료는 인공지능과 관련된 어느 기사의 내용을 정리한 것이다.

(출처: 『연합뉴스』, 2020년 9월 13일)

초등학교 1~2학년, AI로 맞춤형 수학학습...고교엔 AI 과목 신설

출고시간 2020-09-13 09:04

4차 산업혁명의 대표적인 신기술인 인공지능(AI)이 학교 교육과정에 처음으로 활용되고 관련 교과목도 신설됩니다.

교육부는 오는 4월부터 초·중·고 1~2학년층 위한 AI 활용 수학 학습 프로그램인 '북북'

수학평면대는 교육과정, 교과서 기반으로 설계한 수학 학습 과제를 학생들이 학습하면 그 결과를 AI로 분석해 학생 수준에 맞는 학습 콘텐츠를 추천하는 시스템입니다.

수확량측정은 조종하고 저작근의 발달 특성을 고려해 수확 문제를 계몽 형식으로 제공하고 학생 개인별 학습 시간과 평가 결과 등을 수집해 앞으로 발생할 수 있는 학습 결손을 예측한 뒤 이를

① 워드클라우드 생성기(<http://wordcloud.kr/>)에 접속한다.

[illegible]

② ‘글자색’, ‘폰트’, ‘배경색’을 선택하고 ‘마스크’에서 단어 구름의 모양을 정한다.

또, ‘크기’에서 단어 구름의 크기를 정하고 ‘단어수’에서 단어 구름에 포함될 단어의 수를 선택한다.

③ 위의 자료를 복사한 후 ‘텍스트’란에 붙여 넣는다.

4 위드클라우드 만들기 를 클릭하면 오른쪽 그림과 같은 단어 구름이 만들어진다.

오른쪽 단어 구름에서 빈도수가 큰 단어가 ‘인공지능’과 ‘학습’이므로, 이 기사는 ‘인공지능 학습’과 관련된 내용임을 알 수 있다.



● 인터넷에서 검색한 자료를 바탕으로 공학적 도구를 활용하여 단어 구름을 만들게 한다.

문제 1

인터넷에서 자율 주행에 관련된 기사를 하나 검색하여 단어 구름을 만들고, 그 기사의 주제어를 찾아보시오. [풀이 참조](#)



○ 배운 내용을 바탕으로 () 안에 알맞은 것을 **날말** **상자** 에서 골라 적어 보자.

