


확률은 가능성을 예측하고 싶은 사건을 설정하고 자료를 수집하여 그 사건이 일어날 확률을 구하며, 조건부확률의 용어와 기호를 도입하지 않고 특정 조건으로 세분화된 확률을 상대도수로 추정하고 예측하는 과정에 어떤 수학적 원리가 사용되는지 경험하는 정도로 간단히 다룬다.

01

자료의 분석과 예측

개념 PPT

학습목표 ● 자료를 분석하여 사건이 일어날 확률을 구하고 예측에 이용할 수 있다.



교수·학습 활동-확률을 이용한 예측

자료로부터 여러 가지 사건의 확률을 구하게 한다.

1 확률을 이용하여 어떻게 예측하는가?

인공지능은 자료를 분석하여 사건이 일어날 확률을 구하고, 이를 예측에 이용한다. 이제 이와 같은 인공지능의 예측 방법을 알아보자.

다음은 어느 온라인 쇼핑몰에서 세 상품 A, B, C를 구매한 고등학생 200명에 대한 자료이다. 이 자료를 이용하여 쇼핑몰을 방문한 고등학생이 세 상품 A, B, C 중에서 어느 것을 구매할지 인공지능이 예측하는 방법을 알아보자.

(단위: 명)

학년	성별	상품 A	상품 B	상품 C
1학년	남	15	9	12
	여	1	2	2
2학년	남	16	10	9
	여	13	17	10
3학년	남	15	11	14
	여	12	14	18

이 자료에서 각 상품별로 구매한 학생 수를 표로 정리하면 다음과 같다.

(단위: 명)

상품 A	상품 B	상품 C	합계
72	63	65	200

이 표에서 쇼핑몰을 방문한 고등학생이 세 상품 A, B, C를 구매할 확률 p_A , p_B , p_C 는 다음과 같다.

$$p_A = \frac{72}{200}, \quad p_B = \frac{63}{200}, \quad p_C = \frac{65}{200}$$

수업의 주안점

자료로부터 확률을 구하고 예측 활동 및 비형식적인 통계적 추론을 수행할 수 있게 한다.

평가 방법 및 유의사항

자료의 예측에 대한 평가는 확률 계산이나 관계식 등 수치 계산에 치중하지 않도록 한다.

이때 상품 A를 구매할 확률이 가장 크므로, 인공지능은 이 학생이 상품 A를 구매할 것으로 예측한다.

이와 같이 인공지능은 여러 개의 사건 중에서 확률이 가장 큰 사건이 발생할 것으로 예측한다.

교수·학습 활동-조건부 확률을 이용한 예측

사건의 조건에 따라 자료의 일부만을 전체 경우로 다루는 조건부확률을 구하게 한다.



수업의 주안점

사건의 조건에 따라 자료의 일부만을 전체 경우로 다루는 문제를 해결하면서 비형식적으로 조건부확률을 이해할 수 있게 한다.

② 조건이 주어진 경우 어떻게 예측하는가?

예측의 결과는 주어진 조건에 따라 달라질 수 있다. 조건이 주어지면 먼저 그 조건에 맞는 확률을 계산하고, 이를 이용하여 인공지능이 예측하는 방법을 알아보자.

이 쇼핑몰을 방문한 고등학생이 1학년일 때, 세 상품 A, B, C 중에서 어느 것을 구매할지 예측해 보자.

방문한 고등학생이 1학년이라는 조건을 고려해야 하므로 전체 자료를 학년별로 구분하여 표로 정리하면 다음과 같다.

(단위: 명)

	상품 A	상품 B	상품 C	합계
1학년	16	11	14	41
2학년	29	27	19	75
3학년	27	25	32	84
합계	72	63	65	200

이 표에서 1학년 학생이 세 상품 A, B, C를 구매할 확률 p_A , p_B , p_C 는

$$p_A = \frac{16}{41}, \quad p_B = \frac{11}{41}, \quad p_C = \frac{14}{41}$$

이므로 상품 A를 구매할 확률이 가장 크다. 따라서 인공지능은 이 1학년 학생이 상품 A를 구매할 것으로 예측한다.

다음은 이 쇼핑몰을 방문한 고등학생이 여학생일 때, 세 상품 A, B, C 중에서 어느 것을 구매할지 예측해 보자.

방문한 고등학생이 여학생이라는 조건을 고려해야 하므로 전체 자료를 성별로 구분하여 표로 정리하면 다음과 같다.

(단위: 명)

	상품 A	상품 B	상품 C	합계
남	46	30	35	111
여	26	33	30	89
합계	72	63	65	200



앞의 표에서 여학생이 세 상품 A, B, C를 구매할 확률 p_A, p_B, p_C 는

$$p_A = \frac{26}{89}, \quad p_B = \frac{33}{89}, \quad p_C = \frac{30}{89}$$

이므로 상품 B를 구매할 확률이 가장 크다. 따라서 인공지능은 이 여학생이 상품 B를 구매할 것으로 예측한다.

처음에 이 쇼핑몰을 방문한 고등학생이 상품을 구매하는 경우에 인공지능은 이 학생이 상품 A를 구매할 것으로 예측하였다. 하지만 이 학생이 '1학년'인 경우에는 상품 A를, '여학생'인 경우에는 상품 B를 구매할 것으로 인공지능이 예측하였다. 즉, 조건에 따라 예측의 결과가 달라질 수 있음을 알 수 있다.

고등학교 3학년이라는 조건에 대한 조건부확률을 구하여 구매할 상품을 예측할 수 있게 한다.

문제 1

앞의 자료를 이용하여 이 쇼핑몰을 방문한 고등학생이 3학년이라면 세 상품 A, B, C 중에서 어느 것을 구매할 것인지 예측하시오. **상품 C**

$p_A = \frac{27}{84}, \quad p_B = \frac{25}{84}, \quad p_C = \frac{32}{84}$ 이므로 상품 C를 구매할 확률이 가장 크다.

예제 1

오른쪽 표는 어느 회사가 생산하는 독감 검사 키트의 정확도를 판정하기 위해 20명을 대상으로 감염 여부를 조사하여 나타낸 것이다. 준수가 이 독감 검사 키트로 검사를 했을 때 양성 반응이 나왔다고 한다. 이 검사 결과를 바탕으로 준수의 감염 여부를 예측하시오.

(단위: 명)

	양성 반응	음성 반응	합계
감염자	9	1	10
비감염자	3	7	10
합계	12	8	20

준수가 이 독감 검사 키트로 검사를 했을 때 양성 반응이 나왔으므로, 양성 반응이 나온 사람들 중에서 감염자일 확률을 p_1 , 비감염자일 확률을 p_2 라 하면

$$p_1 = \frac{9}{12} = \frac{3}{4}, \quad p_2 = \frac{1}{12} = \frac{1}{12}$$

따라서 $p_1 > p_2$ 이므로 준수는 독감에 감염되었다고 예측한다.

감염

주어진 조건에 따라 조건부확률을 구하여 선호 지역을 예측할 수 있게 한다.

문제 2

오른쪽 표는 어느 여행사에서 회원 40명을 대상으로 여행을 가고 싶은 지역을 조사하여 나타낸 것이다. 다음에 답하시오.

(단위: 명)

	경주	담양	합계
남자	16	6	22
여자	8	10	18
합계	24	16	40

(1) 이 여행사의 회원은 경주와 담양 중에서 어느 지역을 더 선호할지 예측하시오. **경주**

(2) 만약 여자 회원이라면 경주와 담양 중에서 어느 지역을 더 선호할지 예측하시오.

(1) 경주: $\frac{24}{40} = \frac{3}{5}$, 담양: $\frac{16}{40} = \frac{2}{5}$

담양

(2) 경주: $\frac{8}{18} = \frac{4}{9}$, 담양: $\frac{10}{18} = \frac{5}{9}$



여러 개의 조건이 주어진 사건의 자료의 수가 충분하지 않은 경우 조건부확률을 구하게 한다.

수업의 주안점

여러 개의 조건이 주어진 사건인 경우 각 조건이 서로 영향을 주지 않는 조건부확률을 직관적으로 구해 볼 수 있게 한다.

③ 빈도수가 적은 경우 어떻게 예측하는가?

여러 개의 조건이 주어진 경우에 자료의 수가 충분하지 않으면 자료로부터 직접 조건에 맞는 확률을 구하는 것은 적합하지 않다. 이처럼 자료의 수가 충분하지 않을 때, 인공지능이 예측하는 방법을 알아보자.

앞의 쇼핑몰을 방문한 고등학생이 1학년 여학생일 때, 세 상품 A, B, C 중에서 어느 것을 구매할지 예측해 보자.

전체 자료 중에서 1학년 여학생의 자료를 표로 정리하면 다음과 같다.

(단위: 명)

	상품 A	상품 B	상품 C	합계
1학년 여학생	1	2	2	5

이 표에서 1학년 여학생이 세 상품 A, B, C를 구매할 확률 p_A , p_B , p_C 는

$$p_A = \frac{1}{5}, \quad p_B = \frac{2}{5}, \quad p_C = \frac{2}{5}$$

이므로 상품 B 또는 C를 구매할 확률이 가장 크다. 따라서 인공지능은 이 1학년 여학생이 상품 B 또는 C를 구매할 것으로 예측한다.

하지만 주어진 자료에서 1학년 여학생의 수가 5명으로 충분히 많지 않기 때문에 자료로부터 구한 확률을 신뢰하기 어렵다. 이 경우에는 다음과 같이 충분히 많은 수의 고등학생이 상품 A를 구매한다고 할 때, 이 학생들 중에서 상품 A를 구매할 1학년 여학생의 수를 예상한다. 이때 상품 A를 구매한 학생이 '1학년 여학생'일 확률은 상품 A를 구매한 학생이 '1학년'일 확률과 상품 A를 구매한 학생이 '여학생'일 확률의 곱으로 계산한다.

※ 상품을 구매하는 학생의 학년과 성별은 서로 영향을 주지 않는다고 생각한다.

1000명의 고등학생이 세 상품 A, B, C를 구매할 때,

① 상품 A를 구매할 학생 수

$$1000 \times (\text{상품 A를 구매할 확률}) = 1000 \times \frac{72}{200} = 360 (\text{명})$$

② 상품 A를 구매할 1학년 학생 수

$$(\text{상품 A를 구매할 학생 수}) \times (\text{상품 A를 구매한 학생이 1학년일 확률}) = 360 \times \frac{16}{72} = 80 (\text{명})$$

③ 상품 A를 구매할 1학년 여학생 수

$$(\text{상품 A를 구매할 1학년 학생 수}) \times (\text{상품 A를 구매한 학생이 여학생일 확률}) = 80 \times \frac{26}{72} = 28. \times \times \times$$

즉, 29명

같은 방법으로 상품 B 또는 C를 구매할 것으로 예상되는 1학년 여학생의 수를 구하여 표로 정리하면 다음과 같다.

(단위: 명)

	상품 A	상품 B	상품 C	합계
1학년 여학생	29	29	33	91

이 표에서 1학년 여학생이 각각의 상품을 구매할 확률 p_A , p_B , p_C 는

$$p_A = \frac{29}{91}, \quad p_B = \frac{29}{91}, \quad p_C = \frac{33}{91}$$

이다. 따라서 인공지능은 이 1학년 여학생이 상품 C를 구매할 것으로 예측한다.

이와 같이 여러 개의 조건에 해당하는 자료의 수가 충분하지 않으면 각각의 조건을 분리하여 계산한 확률을 이용해 예측한다.

☑ 날씨와 온도가 서로 영향을 주지 않을 경우 주어진 조건에 따라 운동을 할 확률을 구해 볼 수 있게 한다.



활동

조건에 따른 확률의 계산과 예측

문제 해결

추론



다음은 윤희가 운동을 한 날과 하지 않은 날의 날씨와 온도를 조사한 자료이다.

날씨	온도	운동 여부	날씨	온도	운동 여부
맑음	더움	N	맑음	더움	N
맑음	더움	N	맑음	시원	Y
흐림	더움	Y	비	보통	Y
비	보통	Y	맑음	보통	Y
비	시원	Y	흐림	보통	Y
비	시원	N	흐림	더움	Y
흐림	시원	Y	비	보통	N

(1) $100 \times \frac{9}{14} = \frac{450}{7} = 64.\times\times\times$, 즉 65일
 $65 \times \frac{2}{9} \times \frac{4}{9} = \frac{520}{81} = 6.\times\times\times$, 즉 7일
 (2) $100 \times \frac{5}{14} = \frac{250}{7} = 35.\times\times\times$, 즉 36일
 $36 \times \frac{3}{5} \times \frac{1}{5} = \frac{108}{25} = 4.32$, 즉 5일

① 윤희가 운동을 한 날과 하지 않은 날의 일수를 정리하여 오른쪽 표를 완성하시오. 또, 윤희가 운동을 할 확률을 구하시오. $\frac{9}{14}$

운동 여부(일)		
Y	N	합계
9	5	14

② 날씨와 온도에 따라 윤희가 운동을 한 날과 하지 않은 날의 일수를 정리하여 다음 표를 완성하시오.

날씨	운동 여부(일)		
	Y	N	합계
맑음	2	3	5
흐림	4	0	4
비	3	2	5
합계	9	5	14

온도	운동 여부(일)		
	Y	N	합계
더움	2	3	5
보통	4	1	5
시원	3	1	4
합계	9	5	14

③ 윤희가 내일부터 100일 동안 날씨와 온도에 따라 운동을 한 날과 하지 않은 날의 일수를 기록한다고 하자.

- (1) 운동을 했을 때, 날씨가 맑고 온도가 보통일 것으로 예상되는 날의 일수를 구하시오.
- (2) 운동을 하지 않았을 때, 날씨가 맑고 온도가 보통일 것으로 예상되는 날의 일수를 구하시오.

④ 만약 내일 실제 날씨가 맑고 온도가 보통인 경우, 윤희의 운동 여부를 판단하시오.

윤희가 운동을 할 확률: $\frac{7}{100}$

윤희가 운동하지 않을 확률: $\frac{5}{100}$






MNIST 데이터 셋과 손 글씨 숫자 분류하기

손으로 쓴 우편번호 숫자를 보고 사람이 우편물을 분류하다 보면 실수도 잦고 비용도 많이 발생한다. 그래서 미국 국립표준기술연구소에서는 손 글씨 우편번호를 기계가 자동으로 인식하여 빠르게 분류할 수 있도록 하는 학습용 데이터 셋(data set)을 만들었는데, 이것을 MNIST 데이터 셋이라고 한다.


지도 방향

인공신경망을 이용하는 대표적인 사례가 손 글씨 인식으로, 읽기 자료를 통해 가볍게 알아두도록 한다.

MNIST 데이터 셋의 각 숫자 이미지는 오른쪽 그림처럼 가로와 세로 28개씩 모두 784개의 픽셀로 이루어져 있다. 각 픽셀마다 검은색은 0, 흰색은 255로 하여 광원의 세기에 따라 0부터 255까지의 수를 사용한다. 즉, 각 숫자 이미지는 모든 성분이 0부터 255까지의 수인 28×28 행렬로 표현된다.




이와 같은 MNIST 데이터 셋을 이용하여 입력값이 $28 \times 28 = 784$ (개)이고 출력값이 0부터 9까지 10개인 다층 퍼셉트론 구조의 인공신경망을 학습시킨다.




MNIST는 60000개의 트레이닝 셋과 10000개의 테스트 셋으로 구성되어 있는데, 트레이닝 셋은 학습 데이터로 사용하고 테스트 셋은 신경망을 검증하는 데 사용한다고 한다.

학습을 마친 인공신경망에 새로운 손 글씨 이미지를 입력하면 오른쪽과 같이 예측되는 숫자의 확률을 계산하는데, 이때 인공지능은 입력된 손 글씨를 확률이 가장 높은 숫자로 분류한다.

손 글씨 숫자를 분류하는 인공지능의 정확도는 꾸준히 증가하여 2002년에는 99.58 %, 2020년에는 99.84 %에 도달하였다.



즉, 10000개의 테스트 셋의 숫자 중에 16개만 분류를 잘못된 것이다. 그런데 잘못 분류된 숫자를 보면 다음 그림과 같이 사람이 직접 분류하더라도 판단하기 어려워 보인다.



(출처: Byerly, A. 외, 「A branching and merging convolutional network with homogeneous filter capsules」/
Liu, C. K. 외, 「Handwritten digit recognition using state-of-the-art techniques」)

자료의 경향성은 관련된 두 자료를 산점도로 나타내고 측정값과 함숫값 사이의 오차를 최소화하는 추세선을 나타내는 두 변량 사이의 관계식 $y=ax+b$ 를 찾아 새로운 x 의 값이 주어졌을 때, y 의 값을 예측하는 과정을 이해하게 한다.


02

자료의 경향성과 예측

개념 PPT

학습목표 ● 자료의 경향성을 추세선으로 나타내고, 예측에 이용할 수 있다.

다가서기



평가 방법 및 유의사항

자료의 예측에 대한 평가는 확률 계산이나 관계식 등 수치 계산에 치중하지 않도록 하고, 자료의 경향성을 추세선으로 나타내는 활동과 확률을 예측에 이용하는 과정에 중점을 둔다.

추세선은 y 의 측정값과 예측값 사이의 오차를 구하여 이를 최소화한다는 의미 정도로 간단히 다루고, 추세선을 구할 때 공학적 도구를 이용할 수 있다.

수업의 주안점

추세선이 무엇인지 알아보는 것이다.

1 추세선이란 무엇인가?

다음은 어느 반 학생 20명의 수학과 과학 점수를 조사하여 나타낸 것이다.

수학과 과학 점수


(단위: 점)

번호	수학	과학	번호	수학	과학	번호	수학	과학	번호	수학	과학
1	90	86	6	92	64	11	73	84	16	92	95
2	64	65	7	84	98	12	82	83	17	65	70
3	94	89	8	72	85	13	78	59	18	76	72
4	57	62	9	52	62	14	68	64	19	83	88
5	82	74	10	86	84	15	54	55	20	95	93


※ 산점도

어떤 자료에서 두 변량 x 와 y 의 순서쌍 (x, y) 를 좌표평면 위에 점으로 나타낸 그래프를 x 와 y 의 산점도라고 한다.

각 학생의 수학 점수를 x 점, 과학 점수를 y 점이라 할 때, 두 변량 x 와 y 의 산점도는 [그림 1]과 같다.



[그림 1]



[그림 2]

[그림 1]의 산점도에서는 점들이 불규칙하게 흩어져 있는 것처럼 보이지만, [그림 2]에서는 대체로 한 직선을 중심으로 그 주위에 가까이 분포되어 있음을 알 수 있다. 이로부터 수학 점수가 높을수록 대체로 과학 점수도 높아져, 수학 점수와 과학 점수 사이에 양의 상관관계가 있음을 알 수 있다.

자료의 산점도에서 두 변량 사이의 상관관계를 판단하려면 점들이 어떤 직선의 주위에 모여 있는지 봐야 한다.

이와 같이 자료의 경향을 나타내는 직선을 **추세선**이라 하고, 이것을

$$f(x) = ax + b \quad (a, b \text{는 상수})$$

와 같이 x 에 대한 일차함수로 나타낼 수 있다.

교수 · 학습 활동 - 공학적 도구를 이용하여 추세선 구하기

공학적 도구를 이용하여 자료의 경향성을 보여주는 추세선을 구하게 한다.

※ 통그라미 누리집

(https://tong.kostat.go.kr/tongramy_web/main.do)에서 통그라미를 실행할 수 있다.

수업의 주안점

수치 계산보다는 공학적 도구를 이용하여 추세선을 구해볼 수 있게 한다.

② 공학적 도구를 이용하여 추세선을 어떻게 그리는가?

이제 통그라미를 이용하여 추세선을 그리는 방법을 알아보자.

오른쪽 표는 어느 날 우리나라 여러 지점의 풍속과 최대 파고를 조사하여 나타낸 것이다.

지점	풍속(m/s)	최대 파고(m)
울릉도	12.7	5.8
덕적도	1.6	1.9
포항	13.1	3.8
외연도	2.0	2.7
거제도	7.3	1.7
서귀포	8.4	2.6
통영	9.0	2.0
인천	4.2	2.9
울산	9.7	3.6

① 통그라미를 실행하여 ‘풍속’과 ‘최대 파고’의 변량을 각각 차례대로 입력한다.


자료창

	V1	V2	V3	V4	V5	V6	V7	V8	V9	V10	V11
1		12.7	5.8								
2		1.6	1.9								
3		13.1	3.8								
4		2	2.7								
5		7.3	1.7								
6		8.4	2.6								
7		9	2								
8		4.2	2.9								
9		9.7	3.6								

(출처: 기상자료개방포털, 2021)


The screenshot shows the Tongrami web application interface. On the left is the '자료창' (Data Window) with a table of data. In the center is the '변수설정' (Variable Setting) window where 'V2' is selected as the '변수명' (Variable Name) and '최대 파고' (Maximum Wave Height) is entered. Below this, there are options for '변수값' (Variable Value) and '변수정보' (Variable Information), including a color-coded legend for values like 1.7, 1.9, 2, 2.6, 2.7, and 3.4. On the right is the '변수창' (Variable Window) showing a list of variables (V1 to V26) with their respective units and descriptions.

- ② 메뉴에서 '그래프 > 산점도'를 클릭하고, 가로축 변수에 '풍속', 세로축 변수에 '최대 파고'를 선택하여 넣은 후 '확인'을 클릭하면 풍속과 최대 파고의 산점도가 만들어진다.



※ 공학적 도구에서 나타낸 추세선은 두 변량의 상관관계를 가장 잘 나타내는 직선이다.

- ③ 산점도 팝업 창의 '옵션 선택'을 클릭하여 '추세선(선형) 표시'를 선택하면 다음과 같이 추세선이 나타난다.



각 지점의 풍속을 x m/s라 하고 최대 파고를 y m라 할 때, 추세선 $y=f(x)$ 의 관계식은 $f(x)=0.19x+1.55$ 로 나타난다.

이때 추세선의 기울기가 양수이므로 풍속과 최대 파고 사이에는 양의 상관관계가 있다. 즉, 풍속이 빠르면 최대 파고가 높다는 것을 알 수 있다.

- 공학적 도구를 이용하여 구한 추세선 식에서 두 자료 사이의 상관관계를 구할 수 있게 한다.

문제 1

오른쪽 표는 우리나라 여러 기상 관측 지점의 해발 고도와 7월 평년 최고 기온을 나타낸 것이다.

- (1) 통그라미를 이용하여 기상 관측 지점의 해발 고도와 7월 평년 최고 기온의 산점도를 그리고, 추세선의 식을 구하시오. **풀이 참조**, $y = -0.01x + 29.52$

- (2) 해발 고도와 7월 평년 최고 기온 사이에 어떤 상관관계가 있는지 말하시오.
음의 상관관계

관측 지점	해발 고도(m)	7월 평년 최고 기온(°C)
광주	70.3	29.6
대관령	772.4	22.8
대구	54.3	30.3
대전	70.2	29.0
부산	69.6	27.3
서울	85.7	28.6
울릉도	221.1	25.2
원주	150.1	29.3
장수	406.9	27.6
제주	20.8	29.0
추풍령	245.0	28.4

(출처: 기상자료개방포털, 2020)

- 추세선을 이용하여 새로운 x 의 값에 해당하는 y 의 값을 예측하게 한다.
- 측정값과 예측값의 오차를 구하게 한다.


수업의 주안점

추세선의 식을 이용하여 예측에 활용하고 해석하는 부분을 중점적으로 다룬다.

③ 추세선으로 예측값과 오차를 어떻게 구하는가?

자료의 경향을 나타내는 추세선을 이용하면 자료에 없는 변량 x 에 대응하는 측정값 y 를 예측하는 것이 가능하다.

예를 들어 최대 파고의 측정이 불가능한 어떤 지점의 풍속이 4 m/s인 경우, 추세선 $f(x) = 0.19x + 1.55$ 에 $x = 4$ 를 대입하여 얻은 $f(4) = 2.31(\text{m})$ 를 이 지점의 최대 파고로 예측할 수 있다.



일반적으로 자료의 두 변량 x 와 y 사이의 경향을 나타내는 추세선 $f(x) = ax + b$ 에서 변량 x 에 대한 추세선의 값 $f(x)$ 를 변량 y 의 **예측값**이라고 한다.

● 공학적 도구를 이용하여 구한 추세선 식을 이용하여 새로운 x 의 값에 대응하는 y 의 값을 예측할 수 있게 한다.

문제 2

문제 1에서 구한 추세선을 이용하여 해발 고도가 250 m와 600 m인 두 지점의 7월 평년 최고 기온을 예측하시오.
 해발 고도가 250 m인 지점: 27.02 °C
 해발 고도가 600 m인 지점: 23.52 °C

$$f(250) = -0.01 \times 250 + 29.52 = 27.02$$

$$f(600) = -0.01 \times 600 + 29.52 = 23.52$$

일반적으로 변량 x 에 대응하는 변량 y 의 값을 추세선 $f(x) = ax + b$ 를 이용하여 예측할 때, 측정값 y 에서 예측값 $f(x)$ 를 뺀 값을 변량 x 에서의 **오차**라고 한다. 즉,

$$\times (\text{오차}) = (\text{측정값}) - (\text{예측값})$$

$$(\text{오차}) = y - f(x) = y - ax - b$$

이다. 또, 오차의 절댓값을 **오차의 크기**라고 한다.

예를 들어 풍속이 9 m/s인 통영의 최대 파고를 추세선 $f(x) = 0.19x + 1.55$ 를 이용하여 구하면 예측값은 $f(9) = 3.26(\text{m})$ 이다. 이때 통영의 최대 파고의 측정값은 2 m이므로 풍속 9 m/s에서의 오차는


$$y - f(9) = 2.0 - 3.26 = -1.26(\text{m})$$

이고, 오차의 크기는 $|-1.26| = 1.26(\text{m})$ 이다.

이제 91쪽의 표에 있는 모든 지점에서 오차를 구하고, 추세선이 그려진 산점도에 오차를 나타내면 다음과 같다.

지점	풍속(m/s)	최대 파고(m)	예측값(m)	오차(m)
울릉도	12.7	5.8	3.963	1.837
덕적도	1.6	1.9	1.854	0.046
포항	13.1	3.8	4.039	-0.239
외연도	2.0	2.7	1.930	0.770
거제도	7.3	1.7	2.937	-1.237
서귀포	8.4	2.6	3.146	-0.546
통영	9.0	2.0	3.260	-1.260
인천	4.2	2.9	2.348	0.552
울산	9.7	3.6	3.393	0.207

※ 이 추세선에 따라 예측한 결과에서 오차의 크기가 가장 큰 지점은 울릉도이고, 오차의 크기가 가장 작은 지점은 덕적도이다.



예제 1

오른쪽 표는 어느 회사의 창립 이후 기간별 매출액을 나타낸 것이다. 창립 이후 기간을 x 년, 매출액을 y 억 원이라 하고, 추세선의 식을 $f(x) = x + 2$ 라 하자. 매출액의 측정값과 예측값 사이의 오차를 구하시오.

기간(년)	매출액(억 원)
1	2
2	6
3	4

풀이 측정값과 예측값 사이의 (오차) = (매출액) - (예측값)을 구하면 다음 표와 같다.

기간(년)	매출액(억 원)	예측값(억 원)	오차(억 원)
1	2	3	-1
2	6	4	2
3	4	5	-1

답 풀이 참조

❶ 측정값과 추세선을 이용하여 구한 예측값의 오차를 구할 수 있게 한다.

문제 3

오른쪽 표는 12만 원짜리 어느 제품의 사용 기간별 중고 가격을 나타낸 것이다. 사용 기간을 x 년, 중고 가격을 y 만 원이라 하고, 추세선의 식을 $f(x) = -2.5x + 110$ 이라 하자. 중고 가격의 측정값과 예측값 사이의 오차를 구하시오.

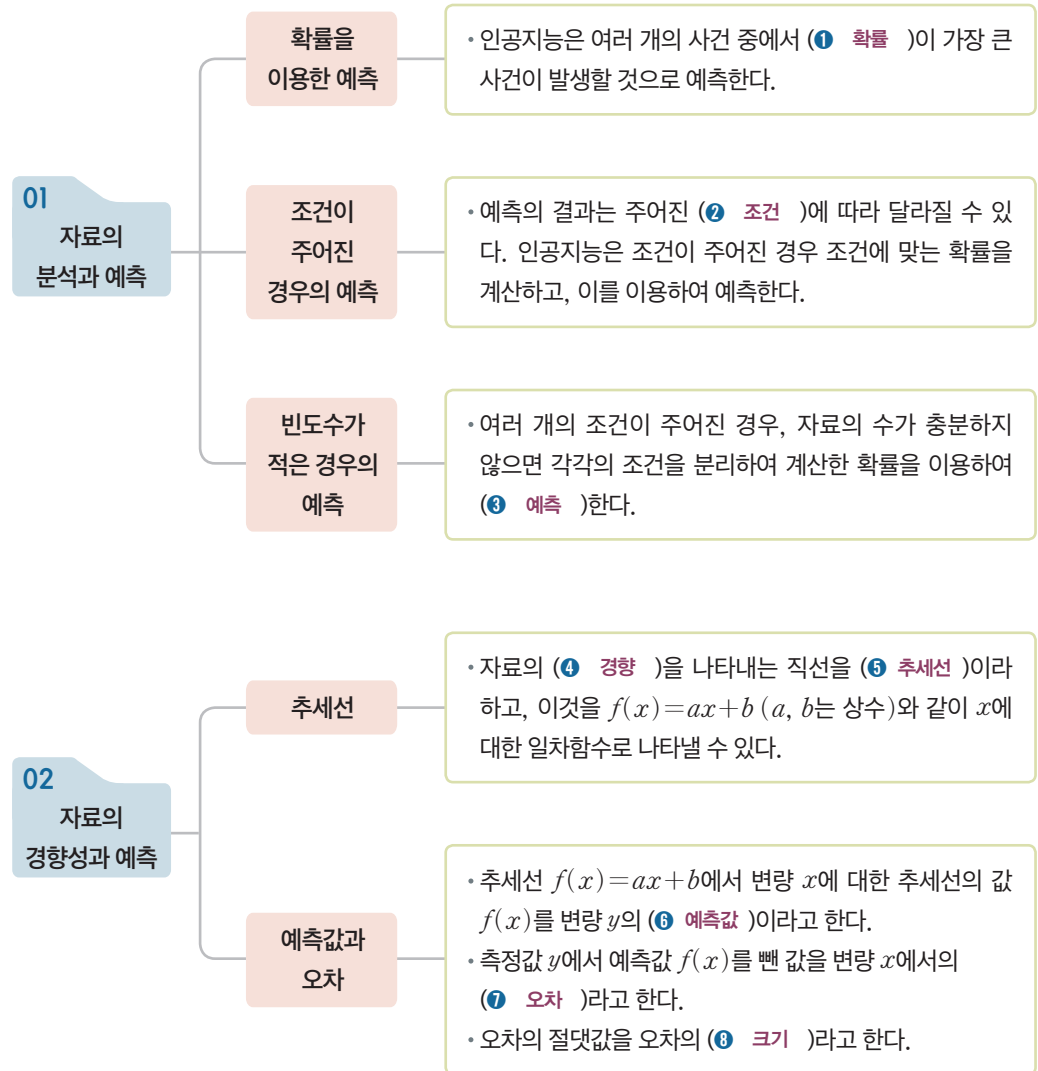
사용 기간(년)	중고 가격(만원)
1	9
2	5
3	4

0.5, -1.0, 0.5

사용 기간(년)	중고 가격(만원)	예측값(만원)	오차(만원)
1	9	8.5	0.5
2	5	6.0	-1.0
3	4	3.5	0.5



○ 배운 내용을 바탕으로 () 안에 알맞은 것을 **날말** **상자** 에서 골라 적어 보자.



경향 예측값	확률 크기	추세선 예측	오차	조건
-----------	----------	-----------	----	----

01

● 감성 사전을 이용하여 후기들의 감성 점수를 구할 수 있게 한다.

다음은 어느 스마트 TV의 구매 후기 중에서 4개를 골라 만든 말뭉치이다.

후기 A: 합리적인 가격의 TV이다.
후기 B: 배송과 설치 부분이 다소 불만이었다.
후기 C: 믿고 구매해도 좋은 제품입니다.
후기 D: 구매 추천합니다. 망설이면 후회할 제품입니다.

아래 감성 사전을 이용하여 다음에 답하시오.

감성 사전	
긍정 단어	부정 단어
합리적, 믿다, 좋다, 추천하다	불만, 부족, 어렵다, 망설이다, 후회

- 각 구매 후기를
(긍정 단어의 수, 부정 단어의 수, 중립 단어의 수)
와 같은 벡터로 나타내시오. **풀이 참조**
- 각 구매 후기에 대하여 감성 점수가 양수이면 ‘긍정’, 0이면 ‘중립’, 음수이면 ‘부정’으로 분류하시오.
(1) 후기 A: (1, 0, 2), 후기 B: (0, 1, 4), 후기 C: (2, 0, 2), 후기 D: (1, 2, 2)
(2) 후기 A: $1-0=1$ (긍정), 후기 B: $0-1=-1$ (부정), 후기 C: $2-0=2$ (긍정), 후기 D: $1-2=-1$ (부정)

● 단어 빈도수 벡터에서 유클리드, 코사인, 자카드 유사도를 각각 구하여 뉴스 기사를 분류할 수 있게 한다.

02

다음은 단어 사전 $U = \{\text{주의, 건조, 기록, 역대, 캠프}\}$ 에 대하여 날씨와 스포츠 분야의 뉴스 기사의 단어 빈도수를 나타낸 것이다.

	주의	건조	기록	역대	캠프
날씨	3	2	1	1	0
스포츠	1	0	2	2	1

동일한 단어 사전 U 에 대하여 새로운 뉴스 기사 A의 단어 빈도수가 아래와 같을 때, 다음에 주어진 유사도를 이용하여 기사 A를 날씨 또는 스포츠 기사로 분류하시오.

	주의	건조	기록	역대	캠프
기사 A	2	0	0	1	1

- 유클리드 유사도 **스포츠** (1) $L(P, A) = \sqrt{7}$, $L(Q, A) = \sqrt{6}$
(2) $C(P, A) = \frac{7\sqrt{10}}{30}$, $C(Q, A) = \frac{\sqrt{15}}{6}$
- 코사인 유사도 **날씨** (3) $J(P, A) = \frac{2}{5}$, $J(Q, A) = \frac{3}{4}$
- 자카드 유사도 **스포츠**

날씨와 스포츠 분야의 뉴스 기사를 각각 P, Q라 하면
 $\vec{P} = (3, 2, 1, 1, 0)$, $\vec{Q} = (1, 0, 2, 2, 1)$
 $\vec{A} = (2, 0, 0, 1, 1)$

03

☞ 선호도 벡터에서 코사인 유사도를 구하여 선호도가 가장 유사한 사람을 묶을 수 있게 한다.

다음 표는 희수, 영호, 명길이가 테마 여행지의 선호도를 강릉, 경주, 부여, 제주 중에서 순위를 매겨 1부터 4까지 나타낸 것이다.

	강릉	경주	부여	제주
희수	1	2	3	4
영호	2	3	1	4
명길	4	1	2	3

$$C(P, Q) = \frac{9}{10},$$

$$C(Q, R) = \frac{5}{6},$$

$$C(R, P) = \frac{4}{5}$$

세 명이 정한 네 지역의 선호도를

(강릉의 순위, 경주의 순위, 부여의 순위, 제주의 순위)

와 같은 벡터로 나타내고, 코사인 유사도를 이용하여 선호도가 가장 유사한 두 사람을 고르시오. **희수와 영호**

희수, 영호, 명길이의 테마 여행지의 선호도를 각각 P, Q, R라 하면

$$\vec{P} = (1, 2, 3, 4), \vec{Q} = (2, 3, 1, 4), \vec{R} = (4, 1, 2, 3)$$

04

☞ 주어진 입력값에 대한 퍼셉트론의 출력값을 구할 수 있게 한다.

입력값 x_1 과 x_2 에 대한 가중치가 $w_1 = 0.2$ 와 $w_2 = -0.5$ 이

고, 활성화함수가 $\sigma(x) = \begin{cases} 0 & (x < 0) \\ 2 & (x \geq 0) \end{cases}$ 인 퍼셉트론이 있다.

주어진 입력값에 대한 출력값 $\sigma(x)$ 를 각각 구하여 오른쪽

표를 완성하시오. **풀이 참조**

$$x = 0 \times 0.2 + 0 \times (-0.5) = 0, \sigma(0) = 2$$

$$x = 0 \times 0.2 + 1 \times (-0.5) = -0.5, \sigma(-0.5) = 0$$

$$x = 1 \times 0.2 + 0 \times (-0.5) = 0.2, \sigma(0.2) = 2$$

$$x = 1 \times 0.2 + 1 \times (-0.5) = -0.3, \sigma(-0.3) = 0$$

x_1	x_2	$\sigma(x)$
0	0	2
0	1	0
1	0	2
1	1	0

05

☞ 두 입력값이 모두 0인 경우에만 출력값이 1이 되는 활성화함수의 임계값을 구할 수 있게 한다.

입력값 x_1 과 x_2 에 대한 가중치가 $w_1 = -2$ 와 $w_2 = -3$ 이

고, 활성화함수가 $\sigma(x) = \begin{cases} 0 & (x < \theta) \\ 1 & (x \geq \theta) \end{cases}$ 인 퍼셉트론이 있다.

이 퍼셉트론에 대하여 입력값에 대한 출력값이 오른쪽 표와

같도록 하는 임계값 θ 의 값의 범위를 구하시오. **$-2 < \theta \leq 0$**

$$x = 0 \text{일 때, } \sigma(0) = 1 \quad \therefore \theta \leq 0$$

$$x = -3 \text{일 때, } \sigma(-3) = 0 \quad \therefore \theta > -3$$

$$x = -2 \text{일 때, } \sigma(-2) = 0 \quad \therefore \theta > -2$$

$$x = -5 \text{일 때, } \sigma(-5) = 0 \quad \therefore \theta > -5$$

x_1	x_2	$\sigma(x)$
0	0	1
0	1	0
1	0	0
1	1	0

☞ 주어진 입력값에 대한 다층 퍼셉트론의 출력값을 구할 수 있게 한다.

06

다음 그림과 같이 활성화함수가 $\sigma(x) = \begin{cases} 0 & (x < 0) \\ 1 & (x \geq 0) \end{cases}$ 이고, 두 개의 입력값으로


부터 출력값이 각각 z_1, z_2, y 인 퍼셉트론으로 만든 다층 퍼셉트론이 있다. 이 퍼셉트론에서 주어진 입력값에 대한 출력값 y 를 각각 구하여 표를 완성하시오. **풀이 참조**

x_1	x_2	x	z_1
-1	1	-1	0
-1	3	5	1
1	0	4	1
2	-3	-1	0

↓

z_1	z_2	x	y
0	1	-3	0
1	1	-1	0
1	0	2	1
0	0	0	1

x_1	x_2	y
-1	1	0
-1	3	0
1	0	1
2	-3	1




x_1	x_2	y
-1	1	0
-1	3	0
1	0	1
2	-3	1

07


● 해밍 거리를 이용하여 주어진 이미지와 숫자 3과 8의 유사도를 구하여 분류할 수 있게 한다.

오른쪽 그림은 전광판의 어떤 숫자 이미지에서 불이 켜진 픽셀을 흰 색, 불이 꺼진 픽셀을 검은색으로 하여 흑백 이미지로 나타낸 것이다. 이와 같은 방법으로 전광판의 숫자 3과 8의 이미지를 각각 흑백 이미지로 나타낸 것이 다음과 같을 때, 해밍 거리를 이용하여 이 숫자 이미지가 3 또는 8 중에서 어느 숫자로 분류되는지 구하시오. 3



두 숫자 3과 8의 이미지를 A와 B라 하면

$$A = \begin{pmatrix} 0 & 1 & 1 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 \end{pmatrix}, \quad B = \begin{pmatrix} 0 & 1 & 1 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 \end{pmatrix}$$



$$H(P, A) = 3, \quad H(P, B) = 4$$

주어진 숫자 이미지를 P라 하면

$$P = \begin{pmatrix} 0 & 1 & 1 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 \end{pmatrix}$$

08

● 주어진 조건에 따라 조건부확률을 구하여 예측할 수 있게 한다.

오른쪽 표는 어느 회사에서 직원 100명을 대상으로 보고 싶은 공연을 조사하여 나타낸 것이다. 이 회사에서 임의로 택한 한 명이 공연 B를 선택한 직원일 때, 그 직원이 남성일지 여성일지 예측하시오. 여성

(단위: 명)

	공연 A	공연 B	합계
남성	22	17	39
여성	26	35	61
합계	48	52	100

공연 B를 선택한 직원 중 남성 직원일 확률: $\frac{17}{52}$

공연 B를 선택한 직원 중 여성 직원일 확률: $\frac{35}{52}$

09

● 측정값과 추세선을 이용하여 구한 예측값의 오차를 구할 수 있게 한다.

오른쪽 표는 2015년부터 2020년까지의 자동차 등록 대수를 나타낸 것인데, 2019년의 자료가 누락되었다. 연도를 x 년, 등록 대수를 y 만 대라 하고 추세선의 식을 $f(x) = 67(x - 2015) + 2110$ 이라 하자. 다음에 답하시오.

연도(년)	등록 대수(만 대)
2015	2099
2016	2180
2017	2253
2018	2320
2019	
2020	2437

(1) 누락된 2019년의 자동차 등록 대수의 예측값을 구하시오. 2378대

(출처: 국토교통부 통계누리, 2021)

(2) 2020년의 자동차 등록 대수의 측정값과 예측값 사이의 오차를 구하시오. -8대

$$(1) f(2019) = 67 \times (2019 - 2015) + 2110 = 2378$$

$$(2) f(2020) = 2445 \text{이므로 (오차)} = (\text{등록 대수}) - (\text{예측값}) = 2437 - 2445 = -8$$

소스로
점검하기

문항 번호	관련 개념	성취도	복습
01 02 03	인공지능의 텍스트 분류	○ △ ×	65~72쪽
04 05 06	인공지능의 이미지 분류(1)	○ △ ×	73~77쪽
07	인공지능의 이미지 분류(2)	○ △ ×	78~82쪽
08	자료의 분석과 예측	○ △ ×	84~88쪽
09	자료의 경향성과 예측	○ △ ×	90~94쪽



인공지능을 이용한 범죄 예방

우리 주변에서 흔히 볼 수 있는 CCTV는 범죄가 발생한 후에 범인 추적과 증거 확보 등에 필요한 자료를 제공하지만 범죄를 사전에 예방할 수는 없다. 그런데 인공지능과 딥러닝을 바탕으로 개발된 지능형 CCTV는 범죄 수사의 효율성을 높일 뿐만 아니라 범죄 예방에도 활용되고 있다.

지능형 CCTV는 딥러닝을 통해 안면 인식 패턴을 찾아내면서 안면 식별 정확도가 높아졌으며, 촬영된 영상에서 특정 객체를 인식하고 이를 추적할 수 있다. 사람이나 차량 등의 객체 검출뿐만 아니라 휠체어, 유모차, 안전모 등과 같은 특정 사물에 대한 인식을 제공하기 때문에, 지능형 CCTV는 감시 현장에 최적화된 감시 시스템을 구축하는 데 이용되고 있다.

(출처: 『공학저널』, 2020년 1월 9일)



최근에는 인공지능이 범죄 유형을 스스로 학습한 후 범죄 혐의 정도를 확률적으로 계산하여 범죄 가능성을 예측하는 기술을 개발 중이라고 한다.

이때 중요하게 사용되는 안면 인식 기술은 콘볼루션 신경망(CNN, Convolutinoal Neural Network)이란 개념을 사용한다고 한다. 이와 같은 기술은 기존 데이터와 디지털화된 이미지를 비교하여 산출한 유사성 점수를 바탕으로 얼굴을 식별한다.

이와 같이 안면 인식 기술이 지능형 CCTV를 이용한 분석 기술과 접목되면서 범죄 수사의 효율성과 범죄 예방 효과를 함께 높이게 되었다.



한편, 범죄 수사과 예방에 인공지능을 도입함으로써 사생활 침해나 과도한 감시에 대한 부정적인 염려도 커지고 있다. 인공지능이 범죄를 잘못 판정할 가능성도 있기 때문에 기술 개량은 물론이고 사람이 직접 참여하여 분석과 판단의 정확성을 높이는 노력도 함께 이루어져야 할 것이다.

(출처: KISDI, 『AI Trend Watch』 / 사이언스온)