

고2학년 1학기 인공지능수학

텍스트 벡터화 연습

TF · IDF · TF-IDF

학년 반 번 이름

상황 영화 후기 3개를 수학적으로 분석해 봅시다.

아래 영화 후기에서 각 단어의 중요도를 TF-IDF로 계산하시오.

후기 A : 재미있는 영화. 영화 스토리가 정말 재미있고 좋아요.

후기 B : 연기가 좋아요. 음악도 좋습니다.

후기 C : 영화와 연기 모두 좋은 작품.

STEP 1 불용어 제거 + 단어 사전 U 만들기

불용어 제거: 조사(가, 도, 와), 어미(요, 습니다, 는, 은, 이) 등 제거

기본형 변환: 재미있는·재미있어요 → 재미있다 / 좋아요·좋습니다·좋은 → 좋다

후기 A 처리 결과 (예시): { 재미있다, 영화, 스토리 }

후기 B 처리 결과 :

후기 C 처리 결과 :

단어 사전 U : (총 개, $n = 3$)

STEP 2 TF 표 작성 (각 후기에서 단어가 등장한 횟수)

후기	영화	재미있다	스토리	연기	좋다	음악	작품
A	2	2	1				
B							
C							

STEP 3 DF와 IDF 계산 ($IDF = n \div DF$, $n = 3$)

DF: 해당 단어가 등장하는 후기의 수 | IDF: 전체 후기 수 ÷ DF — 희귀한 단어일수록 IDF가 큼.

단어	영화	재미있다	스토리	연기	좋다	음악	작품
DF							
IDF ($3 \div DF$)							

⇒ "좋다"의 IDF =

"재미있다"의 IDF =

더 희귀한(특정 후기만의) 단어는?

STEP 4 TF · IDF 계산 (후기 A) (= TF × IDF)

단어	영화	재미있다	스토리	연기	좋다	음악	작품
TF(A)	2	2	1	0	1	0	0
IDF	[†] Step3	↑	↑	↑	↑	↑	↑
TF · IDF							

⇒ 후기 A의 핵심어 (TF · IDF 최대): → 후기 A의 주제는 ” ”이다.

STEP 5 생각 정리

Q1. ”좋다”는 세 후기 모두에 등장한다. TF · IDF 관점에서 ”좋다”가 특정 후기의 핵심어가 되기 어려운 이유를 설명하시오.

Q2. TF만 사용했을 때의 한계는 무엇이고, TF · IDF가 이를 어떻게 보완하는가?

확인 체크리스트

- ☐ 불용어를 제거하고 기본형으로 변환할 수 있다.
- ☐ 단어 사전 U를 만들고 TF 표를 완성할 수 있다.
- ☐ DF와 IDF를 계산할 수 있다.
- ☐ TF · IDF로 후기의 핵심어를 찾을 수 있다.

정답 및 풀이

STEP 1 불용어 제거 + 단어 사전 U 만들기

불용어 제거: 조사(가, 도, 와), 어미(요, 습니다, 는, 은, 이) 등 제거
기본형 변환: 재미있는·재미있어요 → 재미있다 / 좋아요·좋습니다·좋은 → 좋다

후기 A 처리 결과 (예시): { 재미있다, 영화, 스토리 }

후기 B 처리 결과: { 연기, 좋다, 음악 }

후기 C 처리 결과: { 영화, 연기, 좋다, 작품 }

단어 사전 U: { 영화, 재미있다, 스토리, 연기, 좋다, 음악, 작품 } → 총 7개 (총 개, $n = 3$)

STEP 2 TF 표 작성 (각 후기에서 단어가 등장한 횟수)

후기	영화	재미있다	스토리	연기	좋다	음악	작품
A	2	2	1	0	1	0	0
B	0	0	0	1	2	1	0
C	1	0	0	1	1	0	1

STEP 3 DF와 IDF 계산 ($IDF = n \div DF$, $n = 3$)

DF: 해당 단어가 등장하는 후기의 수 | IDF: 전체 후기 수 ÷ DF — 희귀한 단어일수록 IDF가 큼.

단어	영화	재미있다	스토리	연기	좋다	음악	작품
DF	3	1	1	2	3	1	1
IDF ($3 \div DF$)	1	3	3	1.5	1	3	3

⇒ "좋다"의 IDF = "재미있다"의 IDF = 더 희귀한(특정 후기만의) 단어는?
"좋다" IDF = 1 / "재미있다" IDF = 3 / 더 희귀한 단어: 재미있다 (스토리, 음악, 작품도 IDF=3)

STEP 4 TF · IDF 계산 (후기 A) ($= TF \times IDF$)

단어	영화	재미있다	스토리	연기	좋다	음악	작품
TF(A)	2	2	1	0	1	0	0
IDF	¹ Step3	↑	↑	↑	↑	↑	↑
TF · IDF	2	6	3	0	1	0	0

⇒ 후기 A의 핵심어 (TF · IDF 최대): → 후기 A의 주제는 " "이다.
핵심어: 재미있다 (TF · IDF = 6으로 최대) → 주제: "재미" 또는 "재미있는 영화"

STEP 5 생각 정리

Q1. "좋다"는 세 후기 모두에 등장한다. TF·IDF 관점에서 "좋다"가 특정 후기의 핵심어가 되기 어려운 이유를 설명하시오.

"좋다"의 $DF=3$ (전체 후기 모두 등장)이므로 $IDF = 3 \div 3 = 1$ 로 낮다. $TF \cdot IDF = TF \times 1 = TF$ 에 불과해 가중치 효과가 없다. 즉, 모든 문서에 공통으로 나타나는 단어는 특정 문서를 구별하는 핵심어가 될 수 없다. **Q2. TF만 사용했을 때의 한계는 무엇이고, TF·IDF가**

이를 어떻게 보완하는가?

TF만 사용하면 "영화", "좋다" 같은 범용 단어가 높은 점수를 받아 문서의 고유 특징을 반영하지 못한다. TF-IDF는 IDF를 곱해 여러 문서에 공통으로 등장하는 단어의 가중치를 낮추고, 특정 문서에만 나타나는 단어의 가중치를 높여 각 문서의 핵심어를 구별한다.